



การพัฒนาระบบต้นแบบของสภาพแวดล้อมอัจฉริยะ สำหรับผู้ใช้อีกรถเข็น

โดย

นายวรพล แสงสระศรี

นายศุภวิชญ์ อัสวลาทยอง

โครงการนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
วิศวกรรมศาสตรบัณฑิต
สาขาวิศวกรรมไฟฟ้าและคอมพิวเตอร์
คณะวิศวกรรมศาสตร์ มหาวิทยาลัยธรรมศาสตร์
ปีการศึกษา 2568
ลิขสิทธิ์ของมหาวิทยาลัยธรรมศาสตร์

การพัฒนาระบบต้นแบบของสภาพแวดล้อมอัจฉริยะ สำหรับผู้ใช้อิธรีน

โดย

นายวรพล แสงสระศรี

นายศุภวิชญ์ อัครลาภทอง

โครงการนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
วิศวกรรมศาสตรบัณฑิต
สาขาวิศวกรรมไฟฟ้าและคอมพิวเตอร์
คณะวิศวกรรมศาสตร์ มหาวิทยาลัยธรรมศาสตร์
ปีการศึกษา 2568
ลิขสิทธิ์ของมหาวิทยาลัยธรรมศาสตร์

Prototyping Development of Smart Environment for Wheelchair User

BY

Mr. Worapon Saengsrasi

Mr. Supawit Ausawalaithong

A PROJECT SUBMITTED IN PARTIAL FULFILLMENT OF THE
REQUIREMENTS FOR THE DEGREE OF BACHELOR OF ENGINEERING
IN ELECTRICAL AND COMPUTER ENGINEERING
FACULTY OF ENGINEERING
THAMMASAT UNIVERSITY
ACADEMIC YEAR 2025
COPYRIGHT OF THAMMASAT UNIVERSITY

มหาวิทยาลัยธรรมศาสตร์

คณะวิศวกรรมศาสตร์

โครงการ

ของ

นายวรพล แสงสระศรี

นายศุภวิชญ์ อัครลาภทอง

เรื่อง

การพัฒนาระบบต้นแบบของสภาพแวดล้อมอัจฉริยะสำหรับผู้ใช้อัจฉริยะ

ได้รับการตรวจสอบและอนุมัติ ให้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
วิศวกรรมศาสตรบัณฑิต

เมื่อวันที่ 1 พฤษภาคม พ.ศ. 2569

อาจารย์ที่ปรึกษาโครงการ

(ผู้ช่วยศาสตราจารย์ ดร. ศุภชัย วรพจน์พิศุทธิ์)

หัวหน้าภาควิชาวิศวกรรมไฟฟ้าและคอมพิวเตอร์

(ผู้ช่วยศาสตราจารย์ ดร. ศุภชัย วรพจน์พิศุทธิ์)

หัวข้อโครงการ	การพัฒนาระบบต้นแบบของสภาพแวดล้อมอัจฉริยะสำหรับผู้ใช้อัจฉริยะ
ชื่อผู้เขียน	นายวรพล แสงสระศรี นายศุภวิชญ์ อัครลาภทอง
ชื่อปริญญา	วิศวกรรมศาสตรบัณฑิต
สาขาวิชา/คณะ/มหาวิทยาลัย	วิศวกรรมไฟฟ้าและคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ มหาวิทยาลัยธรรมศาสตร์
อาจารย์ที่ปรึกษาโครงการ	ผู้ช่วยศาสตราจารย์ ดร. ศุภชัย วรพจน์พิศุทธิ์
ปีการศึกษา	2568

บทคัดย่อ

โครงการนี้เสนอแพลตฟอร์ม WheelSense ระบบต้นแบบสภาพแวดล้อมอัจฉริยะสำหรับผู้ใช้อัจฉริยะในสถานดูแลผู้สูงอายุ โดยบูรณาการการรับรู้การเคลื่อนไหว การระบุตำแหน่งภายในอาคาร การบริหารงานเชิงปฏิบัติการ และการสนับสนุนการตัดสินใจของผู้ดูแล เข้าเป็นสายงานข้อมูลครบวงจร ภายใต้โครงสร้างพื้นฐานที่ติดตั้งและดูแลรักษาได้จริง เพื่อแก้ปัญหาความปลอดภัย การสื่อสารข้ามกะ และการบันทึกข้อมูลแบบกระจายในบ้านพักคนชราของประเทศไทย

สถาปัตยกรรมของระบบประกอบด้วยสี่ชั้นที่ทำงานประสานกัน ได้แก่ ชั้นอุปกรณ์ภาคสนามสำหรับตรวจจับการเคลื่อนที่และวัดสัญญาณชีพพื้นฐาน ชั้นโหนดภายในอาคารสำหรับแกนสัญญาณวิทยุ (BLE beacon) และเสริมภาพบริบท ชั้นเซิร์ฟเวอร์ภายในสถานดูแลสำหรับรับเข้า จัดเก็บ และให้บริการข้อมูลผ่าน API ที่มีการยืนยันตัวตน และชั้นส่วนติดต่อผู้ใช้ ประกอบด้วยแดชบอร์ดเว็บตามบทบาทและแอปพลิเคชันบนสมาร์ตโฟน ระบบระบุตำแหน่งใช้แนวทางลายนิ้วมือสัญญาณวิทยุ (RSSI fingerprinting) ร่วมกับอัลกอริทึมเพื่อนบ้านใกล้สุด (K-Nearest Neighbors) ในระดับโหนดและห้อง ส่วนผู้ช่วยปัญญาประดิษฐ์ (AI) แบบประมวลผลภายในเครื่อง (on-device) ถูกบูรณาการผ่าน Model Context Protocol (MCP) ภายใต้กระบวนการเสนอ-ยืนยัน-ดำเนินการ เพื่อให้การกระทำที่เปลี่ยนสถานะของระบบต้องได้รับการยืนยันก่อนเสมอ และเพื่อรักษาความเป็นส่วนตัวของข้อมูลผู้พักอาศัยภายในสถานดูแล

การประเมินระบบต้นแบบดำเนินการที่มหาวิทยาลัยธรรมศาสตร์ครอบคลุมสี่มิติ ได้แก่ ความทนทานของการจำแนกตำแหน่งจากชุดข้อมูลภาคสนาม; ความต่อเนื่องและเวลาแฝงของสายงานข้อมูลครบวงจร ความสอดคล้องในการเลือกเครื่องมือและเวลาแฝงของผู้ช่วย AI จากชุดสถานการณ์

ทดสอบ และประสบการณ์ผู้ใช้ตามบทบาทจากแบบสอบถามออนไลน์ นอกจากนี้ โครงการได้นำเสนอระบบต้นแบบต่อผู้บริหารและผู้ดูแลของบ้านพักคนชราवासนะเวศม์ เพื่อเก็บข้อเสนอแนะเชิงการใช้งานจริง โดยไม่มีการติดตั้งระบบ ณ สถานที่ดังกล่าว

ผลการพัฒนาสะท้อนความเป็นไปได้ของการบูรณาการหลายชั้นเทคโนโลยีเข้าเป็นสายงานเดียว ภายใต้ข้อจำกัดด้านต้นทุน ความซับซ้อนของการติดตั้ง และความเป็นส่วนตัวของข้อมูลประเด็นที่ต้องพัฒนาต่อยอด ได้แก่ การสอบเทียบเวลาระหว่างองค์ประกอบย่อย การขยายชุดกรณีทดสอบให้สะท้อนสภาพงานจริงมากยิ่งขึ้น และการปรับปรุงประสบการณ์ใช้งานให้เหมาะสมกับผู้ดูแลในบริบทที่หลากหลาย ซึ่งเป็นแนวทางสำคัญสำหรับการนำระบบไปประยุกต์ใช้ในที่พักอาศัย โรงพยาบาล และสถานดูแลผู้สูงอายุของประเทศไทยในระยะถัดไป

คำสำคัญ: สภาพแวดล้อมอัจฉริยะ, ผู้ใช้เก้าอี้รถเข็น, บลูทูธพลังงานต่ำ, ระบบระบุตำแหน่งในอาคาร, อินเทอร์เน็ตของสรรพสิ่ง

Title	Prototyping Development of Smart Environment for Wheelchair User
Author	Mr. Worapon Saengsrasi Mr. Supawit Ausawalaithong
Degree	Bachelor of Engineering
Major Field/Faculty/University	Electrical and Computer Engineering Faculty of Engineering Thammasat University
Advisor	Asst. Prof. Dr. Supachai Worapotphisut
Academic Year	2025

ABSTRACT

This project presents WheelSense, a prototype smart environment for wheelchair users in elderly care facilities. The system integrates motion sensing, indoor positioning, operational management, and caregiver decision support into an end-to-end data pipeline under deployable infrastructure. It aims to address safety limitations, cross-shift communication gaps, and paper-based recording practices prevalent in Thai nursing homes.

The architecture comprises four coordinated layers: (1) edge devices for motion detection and vital sign sensing; (2) indoor nodes for BLE beacon scanning and contextual enhancement; (3) a care-facility server for data ingestion, storage, and authenticated APIs; and (4) user interfaces including role-based web dashboards and mobile applications. Indoor positioning employs RSSI fingerprinting with K-Nearest Neighbors (KNN) for zone and room-level inference. An on-device AI assistant is integrated via the Model Context Protocol (MCP) under a propose-confirm-execute workflow, ensuring state-changing actions require prior confirmation while preserving resident data privacy.

System evaluation at Thammasat University covers four dimensions: positioning robustness from field data; end-to-end pipeline continuity and latency; AI tool-selection consistency and latency from template-based test scenarios; and

role-based user experience from online questionnaires. The prototype was also presented to administrators and caregivers at Vasanthawet Elderly Home to collect practical feedback without on-site installation.

Development results demonstrate the feasibility of integrating multi-layer technologies into a unified pipeline under cost, installation complexity, and data privacy constraints. Future work includes timestamp alignment across subsystems, expanding test cases to reflect real-world conditions, and improving user experience for caregivers in diverse contexts. These approaches are critical for deploying the system in residences, hospitals, and elderly care facilities in Thailand.

keyword: Smart environment, wheelchair user, Bluetooth Low Energy, indoor positioning, Internet of Things

กิตติกรรมประกาศ

คณะผู้จัดทำขอขอบพระคุณ ผู้ช่วยศาสตราจารย์ ดร. ศุภชัย วรพจน์พิศุทธิ์ อาจารย์ที่ปรึกษาโครงการ ที่ได้ให้คำแนะนำ ข้อเสนอแนะ และคำปรึกษาทางวิชาการอย่างต่อเนื่องตลอดการดำเนินงาน ทั้งในด้านการออกแบบระบบ การเลือกใช้เทคโนโลยี และการแก้ไขปัญหาทางเทคนิค จนโครงการสามารถพัฒนาได้อย่างเป็นระบบ

คณะผู้จัดทำขอขอบพระคุณ รองศาสตราจารย์ ดร. สายรัก สอาดไพร คณาจารย์ และเพื่อนร่วมงานจากคณะสหเวชศาสตร์ มหาวิทยาลัยธรรมศาสตร์ ที่ให้ความอนุเคราะห์ด้านข้อมูล คำแนะนำ และมุมมองการใช้งานจริงของผู้ใช้เก่าอีรธเซ็น ซึ่งเป็นประโยชน์อย่างยิ่งต่อการปรับปรุงระบบต้นแบบให้เหมาะสมและปลอดภัยมากยิ่งขึ้น

คณะผู้จัดทำขอขอบคุณทุกท่านที่ให้การสนับสนุนตลอดระยะเวลาการดำเนินโครงการ และหวังเป็นอย่างยิ่งว่าโครงการนี้จะเป็นส่วนหนึ่งในการพัฒนาเทคโนโลยีเพื่อยกระดับคุณภาพชีวิตของผู้ใช้เก่าอีรธเซ็นและผู้พิการในอนาคต

สารบัญ

บทคัดย่อภาษาไทย	หน้า (1)
บทคัดย่อภาษาอังกฤษ	(3)
กิตติกรรมประกาศ	(5)
สารบัญตาราง	(8)
สารบัญรูป	(10)
สัญลักษณ์และคำย่อ	16
บทที่ 1 บทนำ	17
1.1 ที่มาและความสำคัญของปัญหา	17
1.2 วัตถุประสงค์ของโครงการ	19
1.3 ขอบเขตของโครงการ	20
1.4 ประโยชน์ที่คาดว่าจะได้รับ	21
1.5 แผนการดำเนินงาน	22
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	23
2.1 แนวคิดระบบดูแลผู้สูงอายุและผู้ใช้รถเข็น	23
2.2 เทคโนโลยี IoT และ Sensor สำหรับระบบดูแล	24
2.3 อุปกรณ์ฮาร์ดแวร์หลักที่เกี่ยวข้อง	25
2.4 การระบุตำแหน่งภายในอาคารด้วย BLE RSSI	28
2.5 การประมวลผลข้อมูล IMU และการเคลื่อนไหว	30
2.6 Machine Learning สำหรับจำแนกพฤติกรรมหรือความเสี่ยง	32
2.7 Retrieval-Augmented Generation และ Retrieval Logic	33
2.8 Neuro-symbolic AI และ AI Pipeline แบบ Rule + Model	34
2.9 งานวิจัยที่เกี่ยวข้อง	35
2.10 ช่องว่างของงานวิจัยเดิม	36
บทที่ 3 วิธีการออกแบบและพัฒนาระบบ	38
3.1 ภาพรวมของระบบ	38
3.2 การเชื่อมต่ออุปกรณ์ภาคสนามและ Mobile Gateway	39
3.3 M5StickC Plus2 BLE Wheelchair Sensor	41
3.4 Polar Verity Sense และ Flutter Mobile Gateway	45
3.5 Indoor Localization	46
3.6 Server, API และ Database	49

3.7	Dashboard และ HMI ตามบทบาทผู้ใช้	51
3.8	ระบบ AI และ MCP Tool Pipeline	60
3.9	แนวทางการประเมินผลระบบ	64
บทที่ 4	ผลการทดลองและการประเมินผล	65
4.1	ภาพรวมการทดลอง	65
4.2	การทดสอบ Sensor และอุปกรณ์ภาคสนาม	66
4.3	การทดสอบ Indoor Localization ด้วย KNN	68
4.4	การทดสอบ Mobile Gateway และ Server	70
4.5	การประเมิน Dashboard/HMI และ SUS Score	73
4.6	การทดสอบ AI: Inter-Rater Reliability	74
4.7	การทดสอบ AI: Text-Distance / Cosine Similarity	74
4.8	การทดสอบ AI: Latency Analysis	75
4.9	สรุปผลการทดลอง	76
บทที่ 5	สรุปผล ข้อจำกัด และข้อเสนอแนะ	78
5.1	สรุปภาพรวมของระบบ	78
5.2	ข้อจำกัดของระบบ	80
5.3	ข้อเสนอแนะในการพัฒนาต่อ	82
	รายการอ้างอิง	84
	ภาคผนวก	87
	รายละเอียดบริบทโครงการ	88
ก.1	ปัญหาทางวิศวกรรมที่ซับซ้อน	89
ก.2	องค์ความรู้และเครื่องมืออุปกรณ์ที่ใช้	89
ก.3	มาตรฐาน กฎหมาย และข้อบังคับที่เกี่ยวข้อง	90
ก.4	ผู้มีส่วนได้ส่วนเสีย ผลกระทบ และความยั่งยืน	90
ก.5	การบริหารงานวิศวกรรมและโครงการ	90
	ตารางข้อมูลการทดลอง Sensor	92
	Raw data และ Summary ของ KNN	94
	ตัวอย่างชุดคำสั่ง AI Test	96
	ตัวอย่าง Schema, API และ MQTT Payload	100
	ภาพหน้าจอ Dashboard และ Mobile Gateway	103
	Flow Diagram และ Firmware Loop เพิ่มเติม	106
	แบบสอบถามประเมินความพึงพอใจ Google Form	109
	ภาพประกอบการสำรวจพื้นที่และการติดตั้งต้นแบบ	113
	เอกสาร PaperIEEE ประกอบการทดลอง RSSI	117

สารบัญตาราง

	หน้า
1.1 แผนการดำเนินงานของโครงการ	22
2.1 บทบาทของเทคโนโลยี IoT และ sensor ในระบบดูแล	26
2.2 ตัวอย่าง feature จาก IMU ที่ใช้กับการวิเคราะห์การเคลื่อนไหว	31
2.3 การแบ่งบทบาทระหว่าง neural และ symbolic component	34
2.4 การจัดกลุ่มงานวิจัยที่เกี่ยวข้องกับระบบต้นแบบ	36
3.1 หน้าที่หลักของเฟิร์มแวร์ M5StickC Plus2 ในระบบปัจจุบัน	42
3.2 กลุ่มข้อมูลที่ mobile gateway รวมก่อนส่งเข้าสู่ระบบ	46
3.3 บริการหลักของ platform services ในระบบ WheelSense	49
3.4 ตัวอย่างกลุ่มข้อมูลที่จัดเก็บใน PostgreSQL และ JSONB	51
3.5 บทบาทผู้ใช้ หน้าจอหลัก และหน้าที่ที่รองรับบน dashboard	52
3.6 แนวทางการประเมินผลที่ใช้ต่อเนื่องไปยังบทผลการทดลอง	64
4.1 ภาพรวมขอบเขตการทดลองของระบบ WheelSense	66
4.2 ผลสรุปการทดสอบอุปกรณ์ภาคสนาม	67
4.3 ผลการตรวจจับสถานะการเคลื่อนไหวจากหน้าต่างข้อมูล IMU	67
4.4 ผลการทดสอบ RSSI/KNN จากชุดข้อมูลที่มีหลักฐานประกอบ	69
4.5 ผลการทดสอบ mobile gateway และ latency ของ server path	71
4.6 ผลการทดสอบ latency ของ query ฐานข้อมูล	72
4.7 ผลสรุป usability ของ dashboard/HMI จากหลักฐานปัจจุบัน	73
4.8 ผลการทำภารกิจบน dashboard และ mobile gateway	73
4.9 ผลการทดสอบ AI Inter-Rater Reliability ตามระดับความกำกวม	74
4.10 ผลการทดสอบ Text-Distance / Cosine Similarity ของคำตอบ AI	75
4.11 ผลการทดสอบ latency ของ AI/MCP pipeline (n=30)	75

4.12	สรุปผลการทดลองตามส่วนของระบบ	77
ก.1	การจัดเข้ากลุ่มปัญหาทางวิศวกรรมที่ซับซ้อนตามกรอบ IEA	89
ข.1	ข้อมูลสรุปของ Wheelchair Sensor และการส่ง telemetry	92
ข.2	ข้อมูลหน้าตาการเคลื่อนไหวจาก IMU	92
ข.3	ข้อมูลสรุปของ Polar Verity Sense และ Mobile Gateway	93
ค.1	จำนวนข้อมูลที่ใช้ในชุดทดลอง RSSI/KNN	94
ค.2	ผลเปรียบเทียบ KNN และ XGBoost ในชุดทดลองเดียวกัน	94
ค.3	Confusion matrix ของ KNN ใน Case 1	94
ค.4	Confusion matrix ของ KNN ใน Case 2	95
ค.5	Confusion matrix รายตำแหน่งของ KNN ใน Case 3	95
ง.1	ผลสรุปชุดทดสอบ AI ตามระดับความกำกวม	96
ง.2	ตัวอย่างคำสั่งกลุ่ม No-ambiguous	97
ง.3	ตัวอย่างคำสั่งกลุ่ม Low-ambiguous	98
ง.4	ตัวอย่างคำสั่งกลุ่ม Medium-ambiguous	99
ง.5	ตัวอย่างคำสั่งกลุ่ม High-ambiguous	99
จ.1	กลุ่ม schema หลักของฐานข้อมูล	100
จ.2	ตัวอย่าง API และ MQTT topic ที่เกี่ยวข้อง	101
ฉ.1	ข้อมูลประกอบการประเมิน Dashboard/HMI และ SUS score	103
ช.1	ลำดับ firmware loop ของ M5StickC Plus2	106
ช.2	ลำดับการทำงานของ Flutter Mobile Gateway	107
ช.3	ลำดับ server ingest และการนำข้อมูลไปใช้	107
ช.4	ลำดับ AI/MCP pipeline แบบ 5 layer	108

สารบัญรูป

	หน้า	
1.1	บริบทการดูแลผู้สูงอายุและผู้พิการที่ใช้เก้าอี้รถเข็นในสถานดูแลของประเทศไทย	18
1.2	อาคารและพื้นที่บริการหลักของบ้านพักคนชราวาระสนะเวศม์ที่ใช้เป็นบริบทศึกษา	18
1.3	การใช้กระดานบันทึกข้อมูลแบบแอนะล็อกที่พบในหน่วยงานจริง	19
2.1	บริบทของสถานดูแลที่ทำให้ระบบติดตามตำแหน่ง sensor และ dashboard รวมศูนย์มีความสำคัญ	24
2.2	อุปกรณ์ฮาร์ดแวร์หลักที่เกี่ยวข้องกับระบบต้นแบบ	27
2.3	ตัวอย่าง การติดตั้งอุปกรณ์ภาคสนามที่เกี่ยวข้องกับการรับข้อมูลจากรถเข็น และ BLE node	27
2.4	กระบวนการระบุตำแหน่งภายในอาคารด้วย BLE RSSI และ fingerprinting	29
2.5	แนวคิด Retrieval Logic ในระบบ RAG	34
2.6	แนวคิด AI pipeline แบบ ผสม rule และ model สำหรับ ระบบ ที่ เรียก ใช้ เครื่องมือ	35
3.1	สถาปัตยกรรมโดยรวมของระบบ WheelSense จากอุปกรณ์ภาคสนามไปยัง mobile gateway, platform services, dashboard และ AI	38
3.2	ลำดับการปรับแนวทางการเชื่อมต่ออุปกรณ์ภาคสนามจากการทดลองภายในพื้นที่ทดสอบ	40
3.3	วงรอบเฟิร์มแวร์ Node T-SimCam สำหรับ config portal, HTTP status, MQTT control และการส่งภาพ	41
3.4	ขั้นตอนการเชื่อมต่อรวมระหว่างอุปกรณ์ภาคสนาม mobile gateway และ บริการส่วนกลาง	41

3.5	ตัวอย่าง ติดตั้ง M5StickC Plus2 บนรถเข็นสำหรับอ่านค่าการเคลื่อนไหวและส่งข้อมูล ผ่าน BLE ไปยังโทรศัพท์	ตำแหน่ง 43
3.6	แผนผัง วง รอบ การ ทำ งาน ของ เฟิร์มแวร์ M5StickC Plus2 แบบ BLE wheelchair sensor	44
3.7	การใช้งาน Polar Verity Sense ร่วมกับสมาร์ทโฟนที่ทำหน้าที่เป็น mobile gateway	45
3.9	หน้าจอ /WheelSensor สำหรับตรวจสอบสถานะ BLE, Polar, M5StickC Plus2 และการส่งข้อมูลขึ้น server	46
3.8	วงรอบการทำงานของ Flutter mobile gateway สำหรับรวมข้อมูล Polar, M5StickC Plus2, RSSI และ step counter	47
3.10	แผนผัง พื้นที่ ทดลอง 4 zone พร้อม ตำแหน่ง BLE node กึ่งกลาง แต่ละ พื้นที่ สำหรับเก็บค่า RSSI	48
3.11	Flowchart การ ส่ง ข้อมูล RSSI และ การ ประเมิน ตำแหน่ง ด้วย KNN หรือ max-RSSI fallback	48
3.12	ลำดับ ประมวลผลข้อมูลฝั่ง server ตั้งแต่ ingest, validate, store, query ไปจนถึง dashboard และ AI	การ 50
3.13	แผนภาพ schema ฐาน ข้อมูล ที่ ใช้ เชื่อม workspaces, users, patients, devices และข้อมูล telemetry	50
3.14	HMI role flow ของ ระบบ WheelSense แสดง การ ผ่าน สิทธิ บริบท workspace และ service ที่ dashboard เรียกใช้งาน	53
3.15	ภาพ หน้า จอ ระบบ ใน มุม มอง Admin ครอบคลุม overview, task, profile, device, facility, alert, message, support, setting และ EaseAI	54
3.16	ภาพ หน้า จอ ระบบ ใน มุม มอง Head Nurse สำหรับติดตามผู้พักอาศัย alert, task, device, floorplan และช่องทางสื่อสาร	55

3.17	ภาพหน้าจอระบบในมุมมอง Supervisor และ Observer สำหรับการติดตามงานและสถานะตามสิทธิ์	56
3.18	ภาพหน้าจอ Patient dashboard สำหรับผู้ใช้รายบุคคล แสดงข้อมูล care plan สถานะรถเข็น และช่องทางขอความช่วยเหลือ	57
3.19	ภาพหน้าจอระบบในมุมมอง Patient ครอบคลุม personal dashboard, schedule, pharmacy, room controls, services, messages, support และ settings	58
3.20	ภาพหน้าจอ EaseAI ใน dashboard สำหรับถามข้อมูลหรือเตรียม action ภายใต้ role permission และ MCP execution gate	59
3.21	โครงสร้าง AI pipeline 5 layer โดย Layer 3 ทำหน้าที่ เตรียม behavioral context นอกเส้นทาง execute หลัก	61
3.22	Layer 1 Intent Router สำหรับ จับ เจตนา แบบ deterministic ก่อน ใช้ semantic matching และ clarification	61
3.23	Layer 2 Context Assembler สำหรับดึงและจัดแพ็คเกจบริบทก่อนส่งเข้า LLM	61
3.24	Layer 4 Constrained LLM สำหรับสังเคราะห์คำตอบหรือ execution candidate ภายใต้ schema ที่กำหนด	62
3.25	Layer 5 Execution Gate สำหรับตรวจ schema, policy และยืนยันการส่งงานผ่าน MCP tool	62
3.26	Layer 3 Behavioral State สำหรับ เตรียม บริบท พฤติกรรม จาก ข้อมูล sensor และเหตุการณ์ของผู้ใช้	63
3.27	Context Window Management สำหรับ จำกัด บริบท ให้มีขนาดเหมาะสม และตรวจสอบย้อนกลับได้	63
4.1	การ ติด ตั้ง M5StickC Plus2 บน รถ เข็น สำหรับ ทดสอบ ข้อมูล IMU และ telemetry	67

4.2	ตัวอย่างหน้าจอ mobile gateway ที่ใช้ตรวจสอบสถานะตำแหน่งและข้อมูลจาก BLE node	68
4.3	ตัวอย่างสัญญาณ RSSI ต่อเนื่องจากชุดทดลอง Case 1, Case 2 และ Case 3	69
4.4	หน้าจอ mobile gateway สำหรับ ตรวจสอบ การ เชื่อม ต่อ Polar Verity Sense และสถานะส่งข้อมูล	71
4.5	ตัวอย่าง การ ตรวจสอบ บริการ บน Raspberry Pi 5 และ Docker runtime ระหว่างการทดสอบ server	72
4.6	กราฟสรุปการกระจายของ latency ในเส้นทาง MQTT ระหว่างการทดสอบ	72
4.7	กราฟประกอบการวิเคราะห์เวลาแฝงของการประมวลผล LLM ใน pipeline	76
ฉ.1	หน้าจอ dashboard สำหรับ head nurse ในการ ติดตาม สถานะ ผู้พัก อาศัย และ alert	103
ฉ.2	หน้าจอ observer/mobile view สำหรับตรวจสอบ alert และข้อมูลสถานะพื้นที่	104
ฉ.3	หน้าจอ head nurse dashboard สำหรับ workflow การ ดูแล และ ติดตาม สถานะ	105
ช.1	หน้าแรกและคำชี้แจงของแบบสอบถามประเมินความพึงพอใจ	109
ช.2	ส่วนคำถามประเมินความพึงพอใจของแบบสอบถาม	110
ช.3	ส่วนคำถามประเมินความพึงพอใจเพิ่มเติม	111
ช.4	ส่วนข้อเสนอแนะและหน้าขอบคุณของแบบสอบถาม	112
ฅ.1	ตัวอย่างอาคารและพื้นที่บริการหลักของสถานดูแล	113
ฅ.2	ตัวอย่างการติดตั้ง node อ้างอิงสัญญาณภายในอาคาร	113
ฅ.3	ตัวอย่างตำแหน่งติดตั้ง node ภายในอาคารอีกมุมมองหนึ่ง	114
ฅ.4	ตัวอย่างการติดตั้งอุปกรณ์กับเก้าอี้รถเข็นสำหรับเก็บข้อมูลการเคลื่อนไหว	114
ฅ.5	ตัวอย่างบริบทผู้สูงอายุในสถานดูแล	115
ฅ.6	ตัวอย่างการใช้งานอุปกรณ์ในบริบทการทดลองต้นแบบ	115
ฅ.7	ภาพประกอบการสรุปแนวคิดและ workflow ระหว่างการออกแบบระบบ	115
ฅ.8	ตัวอย่างการอธิบายแนวทางใช้งานระบบและรับฟังความคิดเห็นจากผู้ดูแล	116
ฅ.9	ภาพประกอบการลงพื้นที่และการพูดคุยกับผู้เกี่ยวข้อง	116

สัญลักษณ์และคำย่อ

สัญลักษณ์/คำย่อ	ความหมาย
AAL	Ambient Assisted Living (สภาพแวดล้อมช่วยเหลือนการดำรงชีวิต)
ABAC	Attribute-Based Access Control (การควบคุมการเข้าถึงตามคุณลักษณะ)
ACID	Atomicity, Consistency, Isolation, Durability
ACL	Access Control List (รายการควบคุมการเข้าถึง)
API	Application Programming Interface
BLE	Bluetooth Low Energy (บลูทูธพลังงานต่ำ)
HTTP	Hypertext Transfer Protocol
IMU	Inertial Measurement Unit (หน่วยวัดความเร่ง-หมุน)
IoT	Internet of Things (อินเทอร์เน็ตของสรรพสิ่ง)
IRB	Institutional Review Board (คณะกรรมการจริยธรรมการวิจัย)
IRR	Inter-Rater Reliability (ความสอดคล้องระหว่างผู้ประเมิน)
JSON	JavaScript Object Notation
JSONB	JSON Binary (ของ PostgreSQL)
JWT	JSON Web Token
KNN / k -NN	k -Nearest Neighbors (เพื่อนบ้านใกล้สุด k ตัว)
LLM	Large Language Model (แบบจำลองภาษาขนาดใหญ่)
MCP	Model Context Protocol (โพรโทคอลบริบทสำหรับเครื่องมือของโมเดล)
MQTT	Message Queuing Telemetry Transport
NASA-TLX	NASA Task Load Index
OAuth	Open Authorization (มาตรฐานการอนุญาตแบบเปิด)
PPG	Photoplethysmography (การตรวจวัดสัญญาณชีพด้วยแสง)
QoS	Quality of Service (คุณภาพการบริการของ MQTT)
RBAC	Role-Based Access Control (การควบคุมการเข้าถึงตามบทบาท)
REST	Representational State Transfer
RSSI	Received Signal Strength Indicator (ค่าความแรงสัญญาณที่ได้รับ)
SSE	Server-Sent Events
SUS	System Usability Scale (มาตรวัดความสามารถในการใช้งาน)
TLS	Transport Layer Security

บทที่ 1

บทนำ


1.1 ที่มาและความสำคัญของปัญหา

ประเทศไทยกำลังเผชิญการเปลี่ยนแปลงโครงสร้างประชากรเข้าสู่สังคมสูงวัยอย่างต่อเนื่อง ซึ่งทำให้ความต้องการระบบสนับสนุนการดูแลผู้สูงอายุและผู้ที่มีข้อจำกัดด้านการเคลื่อนไหวเพิ่มขึ้นตามไปด้วย [1], [2] ขณะเดียวกันสถานการณ์คนพิการในประเทศไทย ปี พ.ศ. 2567 พบว่ามีประชากรผู้พิการกว่า 2.2 ล้านคน โดยผู้พิการทางการเคลื่อนไหวเป็นกลุ่มที่ต้องอาศัยอุปกรณ์ช่วยเคลื่อนที่และการดูแลจากบุคลากรหรือญาติอย่างใกล้ชิด [3] แนวคิดการดูแลแบบ Ambient Assisted Living จึงถูกนำมาใช้เป็นกรอบในการออกแบบสภาพแวดล้อมที่ช่วยลดภาระการดูแลและสนับสนุนการใช้ชีวิตอย่างปลอดภัยมากขึ้น [4]

ผู้ใช้เก้าอี้รถเข็นและผู้สูงอายุในสถานดูแล เช่น บ้านพักคนชราวาระสนะเวศม์ ซึ่งเป็นบริบทศึกษาของโครงการนี้ ต้องพึ่งพาผู้ดูแลในการติดตามตำแหน่ง การเคลื่อนที่ และสภาพร่างกายเบื้องต้น ปัญหาดังกล่าวไม่ได้เกิดจากการขาดการดูแลเพียงอย่างเดียว แต่เกิดจากข้อมูลที่กระจายอยู่คนละส่วน เช่น ตำแหน่งผู้พักอาศัย การเคลื่อนไหวนบนเก้าอี้รถเข็น สัญญาณชีพจากอุปกรณ์สวมใส่ และบันทึกเวอร์ของผู้ดูแล เมื่อข้อมูลเหล่านี้ไม่ถูกรวมไว้ในระบบเดียว ผู้ดูแลจึงต้องตรวจสอบหลายช่องทางและอาจตอบสนองต่อเหตุการณ์ผิดปกติดำเนินการช้ากว่าที่ควร

จากการลงพื้นที่สำรวจอาคารและพื้นที่บริการหลัก พบว่าผู้พักอาศัยและจุดให้บริการกระจายอยู่ในหลายอาคาร การติดตามด้วยสายตาหรือการเดินตรวจเพียงอย่างเดียวจึงไม่เพียงพอในทุกช่วงเวลา โดยเฉพาะผู้ใช้เก้าอี้รถเข็นที่อาจเคลื่อนที่ออกจากโซนเดิมหรือหยุดนิ่งเป็นเวลานานโดยไม่มีผู้ดูแลสังเกตเห็นทันที สถานการณ์ลักษณะนี้อาจเพิ่มความเสี่ยงต่ออุบัติเหตุ เช่น การหกล้ม หรือการไม่ได้รับความช่วยเหลือเมื่อเกิดเหตุผิดปกติ [5]

นอกจากนี้ การทำงานของผู้ดูแลยังมีข้อจำกัดจากการบันทึกข้อมูลแบบแอนะล็อก เช่น กระดานหรือกระดาด ซึ่งสะดวกต่อการใช้งานเฉพาะหน้าแต่ยากต่อการค้นย้อนหลังและการวิเคราะห์แนวโน้ม ข้อมูลที่แยกจากกันยังทำให้ผู้ดูแลต้องเป็นผู้รวบรวมและตีความเองเป็นส่วนใหญ่ หากมีการแจ้งเตือนจำนวนมากโดยไม่มีบริบทประกอบก็อาจนำไปสู่ความล้าจากการแจ้งเตือน (alert fatigue)



รูปที่ 1.1: บริบทการดูแลผู้สูงอายุและผู้พิการที่ใช้เก้าอี้รถเข็นในสถานดูแลของประเทศไทย



รูปที่ 1.2: อาคารและพื้นที่บริการหลักของบ้านพักคนชราวาสนะเวศม์ที่ใช้เป็นบริบทศึกษา

และทำให้การจัดลำดับความสำคัญของงานยากขึ้น [6]

สถานที่	จำนวน	หมายเหตุ
มอดูล	11 (A)	กลุ่ม 1
คอมพิวเตอร์	9 (A)	
มือถือ	9 (A)	
อุปกรณ์เสริม	13 (B)	กลุ่ม 2
เซ็นเซอร์	8 (B)	
เครื่องพิมพ์	6 (B)	
อุปกรณ์	9 (A)	กลุ่ม 3
อุปกรณ์	10 (A)	
อุปกรณ์ - พว	65 (C)	
สิ่งประดิษฐ์	11 (C)	รวม
งานประดิษฐ์	15 (C)	
งานประดิษฐ์	9 (C)	
รวมทั้งหมด	176	
รวม	19	
รวม	39	
รวม	55	

รูปที่ 1.3: การใช้กระดานบันทึกข้อมูลแบบแอนะล็อกที่พบในหน่วยงานจริง

แม้ปัจจุบันจะมีระบบอัตโนมัติในบ้านและระบบระบุตำแหน่งภายในอาคารหลายรูปแบบ [7], [8], [9] แต่ระบบเหล่านี้มักแยกเป็นส่วนเฉพาะทาง เช่น ระบบติดตามตำแหน่ง ระบบสัญญาณเตือน หรือระบบบันทึกข้อมูลสุขภาพ ทำให้ยังไม่ตอบโจทย์การดูแลที่ต้องเห็นตำแหน่ง การเคลื่อนไหว สัญญาณชีพ และสถานะงานของผู้ดูแลในภาพรวมเดียว โครงการนี้จึงเสนอการพัฒนาระบบต้นแบบ WheelSense เพื่อรวมข้อมูลจากเซ็นเซอร์บนเก้าอี้รถเข็น อุปกรณ์สวมใส่ และ mobile gateway เข้าสู่ backend และ dashboard ส่วนกลาง พร้อมใช้ AI/MCP เป็นเครื่องมือช่วยค้นข้อมูล วิเคราะห์ บริบท และเสนอแนวทางการดำเนินการให้ผู้ดูแลตรวจสอบก่อนใช้งานจริง โดยระบบยังคงอยู่ในระดับต้นแบบเพื่อสนับสนุนการเฝ้าระวังเบื้องต้น ไม่ใช่ระบบวินิจฉัยหรือเครื่องมือแพทย์ที่ได้รับการรับรอง

1.2 วัตถุประสงค์ของโครงการ

1. เพื่อพัฒนาระบบต้นแบบ WheelSense สำหรับสนับสนุนการดูแลผู้ใช้เก้าอี้รถเข็นและผู้สูงอายุในสภาพแวดล้อมแบบ smart environment
2. เพื่อเก็บข้อมูลจาก wheelchair sensor อุปกรณ์สวมใส่ และ mobile gateway ได้แก่ ข้อมูลการเคลื่อนไหว สัญญาณชีพเบื้องต้น ตำแหน่งภายในอาคาร และข้อมูลการก้าวเดินของผู้ใช้ที่ไม่ได้จับคู่กับเก้าอี้รถเข็น
3. เพื่อพัฒนา backend และฐานข้อมูลสำหรับรับ ส่ง จัดเก็บ และเรียกดูข้อมูล telemetry จาก

อุปกรณ์ภาคสนามและแอปพลิเคชันบนอุปกรณ์เคลื่อนที่

4. เพื่อแสดงผลข้อมูลผู้พักอาศัยและสถานะระบบผ่าน dashboard ตามบทบาทของผู้ใช้งาน เช่น ผู้ดูแล หัวหน้าพยาบาล ผู้สังเกตการณ์ และผู้ป่วย
5. เพื่อบูรณาการ AI/MCP สำหรับช่วยค้นข้อมูล วิเคราะห์บริบท และเสนอ action ภายใต้อินเตอร์เฟซให้ผู้ดูแลตรวจสอบและยืนยันก่อนดำเนินการ
6. เพื่อประเมินระบบต้นแบบในด้านการทำงานของเซ็นเซอร์ การระบุตำแหน่งภายในอาคาร ความเสถียรของ mobile gateway/server การใช้งาน dashboard และประสิทธิภาพของ AI pipeline

1.3 ขอบเขตของโครงการ

1. ด้านฮาร์ดแวร์ ครอบคลุมการใช้ M5StickC Plus2 เป็นเซ็นเซอร์บนเก้าอี้รถเข็น การใช้ Polar Verity Sense สำหรับอ่านสัญญาณชีพผ่าน BLE และการใช้ Raspberry Pi 5 RAM 8GB เป็น local/edge server สำหรับบริการหลักของระบบ
2. ด้านการสื่อสาร ครอบคลุมการเชื่อมต่อ BLE ระหว่างอุปกรณ์ภาคสนามกับ mobile gateway และการส่งข้อมูลเข้าสู่ระบบผ่าน MQTT หรือ REST API ตามบทบาทของข้อมูลที่รับส่ง
3. ด้านซอฟต์แวร์ ครอบคลุม Flutter mobile gateway, FastAPI backend, PostgreSQL 16 พร้อม JSONB, Next.js dashboard, Docker และ MQTT broker สำหรับรับ ส่ง จัดเก็บ และแสดงผลข้อมูล
4. ด้านการระบุตำแหน่งภายในอาคาร ครอบคลุมการใช้ค่า BLE RSSI จากโหนดอ้างอิง ร่วมกับแนวคิด fingerprinting, KNN และ max-RSSI fallback ในระดับโซนหรือห้อง
5. ด้าน AI ครอบคลุม pipeline แบบ 5 ชั้น ได้แก่ Intent Router, Context Assembler, Behavioral State, Constrained LLM และ Execution Gate รวมถึงแนวคิด RAG และ MCP tool execution ภายใต้อินเตอร์เฟซด้านสิทธิ์และการยืนยันก่อนดำเนินการ

6. ด้านการประเมินผล ครอบคลุมการทดสอบระดับระบบต้นแบบ เช่น sensor test, KNN localization, mobile gateway reliability, dashboard/HMI, Inter-Rater Reliability, cosine similarity, latency และ SUS Score ในกรณีที่มีข้อมูลแบบประเมินรองรับ
7. โครงการนี้ไม่มุ่งหมายให้เป็นระบบวินิจฉัยทางการแพทย์ ระบบเฝ้าระวังที่ผ่านการรับรองเป็น medical device หรือการทดลองทางคลินิกกับผู้ป่วยจริง ผลการทดสอบจึงใช้เพื่อประเมินความเป็นไปได้ของระบบต้นแบบเท่านั้น

1.4 ประโยชน์ที่คาดว่าจะได้รับ

ประโยชน์ต่อสังคม

1. ช่วยลดภาระการตรวจสอบซ้ำของผู้ดูแล โดยรวมข้อมูลตำแหน่ง การเคลื่อนไหว สัญญาณชีพ เบื้องต้น และสถานะอุปกรณ์ไว้ในระบบส่วนกลาง
2. ช่วยให้ผู้ดูแลเห็นข้อมูลผู้พักอาศัยผ่าน dashboard ตามบทบาท ทำให้สามารถติดตามสถานะ และค้นย้อนหลังได้สะดวกกว่าการใช้บันทึกแบบแยกส่วน
3. ช่วยใช้ข้อมูลจาก sensor เป็นข้อมูลประกอบการประเมินสถานะเบื้องต้น เช่น การหยุดนิ่ง นานผิดปกติ การเคลื่อนที่ออกจากโซน หรือค่าสัญญาณชีพที่ควรตรวจสอบเพิ่มเติม
4. ช่วยเป็นแนวทางสำหรับการพัฒนาระบบดูแลผู้สูงอายุแบบ smart environment ที่สามารถนำไปต่อยอดกับ workflow การแจ้งเตือนและการจัดการงานของผู้ดูแลในอนาคต

องค์ความรู้ที่ได้รับ

1. ได้องค์ความรู้ด้านการออกแบบระบบ IoT ที่เชื่อม wheelchair sensor, wearable sensor, mobile gateway, backend และ dashboard ในระบบต้นแบบเดียว
2. ได้องค์ความรู้ด้านการใช้ BLE RSSI และ KNN สำหรับการระบุตำแหน่งภายในอาคารระดับโซนหรือห้อง
3. ได้องค์ความรู้ด้านการออกแบบ AI/MCP pipeline ที่แยกการค้นข้อมูล การจัดบริบท การใช้ LLM และการตรวจสอบสิทธิ์ก่อนส่งงาน

1.5 แผนการดำเนินงาน

การดำเนินงานวิจัยครอบคลุมระยะเวลา 12 เดือน โดยแบ่งเป็นช่วงการวิเคราะห์ปัญหา การศึกษาเอกสารที่เกี่ยวข้อง การออกแบบและสร้างระบบต้นแบบ การบูรณาการและทดสอบ ตลอดจนการวิเคราะห์ผลและจัดทำเล่มวิทยานิพนธ์ ดังรายละเอียดในตารางที่ 1.1

ตารางที่ 1.1: แผนการดำเนินงานของโครงการ

กิจกรรม	เดือนที่											
	1	2	3	4	5	6	7	8	9	10	11	12
1. วิเคราะห์ปัญหาและเก็บบริบทหน้างาน	→	→										
2. ศึกษาวรรณกรรมและทฤษฎีที่เกี่ยวข้อง	→	→	→									
3. ออกแบบสถาปัตยกรรมระบบและ data flow		→	→	→								
4. พัฒนา wheelchair sensor และ wearable gateway			→	→	→	→						
5. พัฒนาระบบระบุตำแหน่งภายในอาคาร				→	→	→	→					
6. พัฒนา backend, database และ MQTT service				→	→	→	→	→				
7. พัฒนา dashboard และ HMI ตามบทบาทผู้ใช้					→	→	→	→	→			
8. บูรณาการ AI/MCP pipeline และ execution gate						→	→	→	→			
9. ทดสอบ sensor, localization, gateway และ server								→	→	→		
10. ประเมิน dashboard, AI และสรุปผลการทดลอง									→	→	→	
11. จัดทำและปรับปรุงวิทยานิพนธ์										→	→	→

หมายเหตุ: → หมายถึงช่วงเวลาที่ยังดำเนินกิจกรรม

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

บทนี้รวบรวมแนวคิด ทฤษฎี และงานวิจัยที่เกี่ยวข้องกับระบบดูแลผู้สูงอายุและผู้
ใช้รถเข็นในสภาพแวดล้อมอัจฉริยะ โดยเน้นเฉพาะพื้นฐานที่จำเป็นต่อการออกแบบระบบ ได้แก่
แนวคิด Ambient Assisted Living, เทคโนโลยี IoT และเซ็นเซอร์, การระบุตำแหน่งภายในอาคาร
ด้วย BLE RSSI, การประมวลผลข้อมูล IMU, Machine Learning สำหรับจำแนกพฤติกรรม,
Retrieval-Augmented Generation และแนวคิด Neuro-symbolic AI แบบผสมระหว่างกฎกับ
โมเดลภาษา

2.1 แนวคิดระบบดูแลผู้สูงอายุและผู้ใช้รถเข็น

การดูแลผู้สูงอายุและผู้ใช้รถเข็นเป็นงานที่ต้องติดตามหลายมิติพร้อมกัน ทั้งตำแหน่งของ
ผู้พักอาศัย การเคลื่อนไหว ความผิดปกติของสัญญาณชีพ การตอบสนองต่อเหตุฉุกเฉิน และภาระงาน
ของบุคลากรดูแล ในบริบทของสังคมสูงวัย จำนวนผู้สูงอายุที่ต้องพึ่งพาผู้ดูแลมีแนวโน้มเพิ่มขึ้นต่อเนื่อง
ขณะที่บุคลากรในสถานดูแลมีข้อจำกัดด้านเวลาและจำนวนคน การออกแบบระบบช่วยดูแลจึงควร
ช่วยลดงานตรวจสอบซ้ำ ๆ ของผู้ดูแล และทำให้ข้อมูลสำคัญถูกรวบรวมอยู่ในจุดที่สามารถมองเห็นและ
ตัดสินใจได้เร็วขึ้น [2], [10]

แนวคิด Ambient Assisted Living (AAL) เป็นแนวคิดที่ใช้เทคโนโลยีสารสนเทศและ
สภาพแวดล้อมอัจฉริยะเพื่อสนับสนุนการใช้ชีวิตประจำวันของผู้สูงอายุหรือผู้ที่มีข้อจำกัดด้านร่างกาย
ระบบในกลุ่มนี้มักประกอบด้วยเซ็นเซอร์ อุปกรณ์สื่อสาร ฐานข้อมูล และกลไกแจ้งเตือน เพื่อช่วยให้ผู้
ดูแลรับรู้เหตุการณ์สำคัญได้ทันเวลาโดยไม่ต้องตรวจด้วยตนเองตลอดเวลา [4] ในงานด้านผู้ใช้อรถเข็น
ข้อมูลตำแหน่งและการเคลื่อนไหวมีความสำคัญมากเป็นพิเศษ เพราะสามารถสะท้อนรูปแบบกิจกรรม
ความเสี่ยงในการหยุดนิ่งนานผิดปกติ หรือการเคลื่อนที่ออกจากบริเวณที่กำหนด

Smart environment เป็นการขยายแนวคิด AAL ไปสู่ระดับพื้นที่ โดยทำให้อุปกรณ์
และบริการภายในอาคารเชื่อมโยงกัน เช่น เซ็นเซอร์ประจำตัวผู้ใช้ อุปกรณ์สวมใส่ จุดอ้างอิงสัญญาณ
ภายในอาคาร ระบบแจ้งเตือน และ dashboard สำหรับผู้ดูแล จุดสำคัญไม่ใช่เพียงการเก็บข้อมูลให้ได้

มากที่สุด แต่เป็นการจัดข้อมูลให้มีบริบท เช่น ใครอยู่ที่ไหน กำลังเคลื่อนไหวหรือหยุดนิ่ง มีสัญญาณชีพ ผิดปกติหรือไม่ และควรส่งต่อเหตุการณ์ใดให้ผู้ดูแลตรวจสอบก่อน



(a) บริบทผู้สูงอายุในสถานดูแล



(b) ตัวอย่างพื้นที่บริการภายในสถานดูแล

รูปที่ 2.1: บริบทของสถานดูแลที่ทำให้ระบบติดตามตำแหน่ง sensor และ dashboard รวมศูนย์มีความสำคัญ

จากแนวคิดดังกล่าว ระบบดูแลผู้สูงอายุและผู้ใช้รถเข็นจึงควรมีคุณสมบัติหลัก 4 ประการ ได้แก่ การรับข้อมูลจากเซ็นเซอร์ที่สัมพันธ์กับสถานะจริงของผู้ใช้ การส่งข้อมูลเข้าสู่ระบบกลางอย่างต่อเนื่อง การจัดเก็บและแสดงผลข้อมูลในรูปแบบที่ผู้ดูแลอ่านได้เร็ว และการมีกลไกช่วยจัดลำดับความสำคัญของเหตุการณ์ก่อนส่งให้มนุษย์ตรวจสอบ ทั้งหมดนี้เป็นพื้นฐานของการออกแบบระบบต้นแบบในงานนี้ แต่ในบทนี้จะอธิบายในระดับทฤษฎีเพื่อไม่ให้ซ้ำกับรายละเอียดการพัฒนาในบทถัดไป

2.2 เทคโนโลยี IoT และ Sensor สำหรับระบบดูแล

Internet of Things (IoT) หมายถึงการเชื่อมต่ออุปกรณ์กายภาพเข้ากับระบบสารสนเทศเพื่อเก็บ ส่ง และประมวลผลข้อมูลจากสภาพแวดล้อมจริง อุปกรณ์ IoT ในระบบดูแลผู้สูงอายุอาจเป็นเซ็นเซอร์ติดรถเข็น อุปกรณ์สวมใส่ โทรศัพท์มือถือ หรือ gateway ภายในพื้นที่ทดลอง จุบรวมของอุปกรณ์เหล่านี้คือมีข้อจำกัดด้านพลังงาน ขนาด หน่วยความจำ และคุณภาพสัญญาณ จึงต้องเลือก protocol และโครงสร้างข้อมูลให้เหมาะกับงาน [11]

Bluetooth Low Energy (BLE) เป็นเทคโนโลยีสื่อสารระยะใกล้ที่เหมาะสมกับอุปกรณ์ใช้พลังงานต่ำ BLE รองรับทั้งการโฆษณาแพ็กเก็ตแบบ advertising และการเชื่อมต่อผ่าน Generic Attribute Profile (GATT) ทำให้อุปกรณ์สามารถส่งข้อมูลสั้น ๆ เช่น RSSI, battery, IMU หรือค่าจาก sensor ไปยัง gateway ได้ โดยค่า Received Signal Strength Indicator (RSSI) สามารถนำไปใช้เป็นข้อมูลประกอบการประเมินระยะหรือห้องที่อุปกรณ์อยู่ได้ แม้ค่า RSSI จะมีความผันผวนจาก

สิ่งกีดขวาง การสะท้อนของสัญญาณ และตำแหน่งของอุปกรณ์ [12]

MQTT เป็น protocol แบบ publish/subscribe ที่นิยมในระบบ IoT เพราะ payload มีขนาดเล็กและแยกผู้ส่งกับผู้รับออกจากกัน อุปกรณ์หรือ gateway สามารถ publish telemetry ไปยัง topic ที่กำหนด ขณะที่ server หรือ dashboard subscribe เฉพาะ topic ที่ต้องใช้ หลักการนี้เหมาะกับระบบที่มีข้อมูลหลายชนิด เช่น ตำแหน่ง สัญญาณชีพ และสถานะอุปกรณ์ เพราะทำให้เพิ่มแหล่งข้อมูลใหม่ได้โดยไม่ต้องผูกทุก service เข้าหากันโดยตรง [13], [14]

เซ็นเซอร์ IMU และ wearable sensor เป็นแหล่งข้อมูลสำคัญในงานดูแลผู้สูงอายุ IMU มักประกอบด้วย accelerometer และ gyroscope สำหรับวัดความเร่งและอัตราการหมุน ส่วน wearable sensor เช่นอุปกรณ์วัดแสงสะท้อนจากผิวหนังด้วยหลักการ Photoplethysmography (PPG) สามารถใช้ติดตาม heart rate, pulse-to-pulse interval หรือข้อมูลสัญญาณชีพที่สัมพันธ์กับภาวะร่างกายได้ [15], [16] อย่างไรก็ตาม ข้อมูลเหล่านี้ควรถูกใช้เป็นข้อมูลประกอบการประเมินเบื้องต้น ไม่ใช่การวินิจฉัยทางการแพทย์

ในระบบที่ต้องประมวลผลภายในพื้นที่ทดลอง แนวคิด edge หรือ local server มีบทบาทในการลดการพึ่งพา cloud ภายนอก ทำให้ข้อมูลส่วนบุคคลไม่จำเป็นต้องออกนอกระบบ และช่วยให้ dashboard หรือระบบแจ้งเตือนทำงานได้แม้ internet ภายนอกไม่เสถียร โครงสร้างทั่วไปมักประกอบด้วย gateway ที่รับข้อมูลจากอุปกรณ์ภาคสนาม server ที่ตรวจสอบและจัดเก็บข้อมูล ฐานข้อมูลสำหรับ telemetry และ frontend/dashboard สำหรับแสดงผล

2.3 อุปกรณ์ฮาร์ดแวร์หลักที่เกี่ยวข้อง

M5StickC Plus2 เป็นบอร์ดไมโครคอนโทรลเลอร์ขนาดเล็กที่มี ESP32, หน้าจอ, ปุ่ม, แบตเตอรี่ และ IMU ในตัว จึงเหมาะกับการทดลองเป็น sensor ดิทรถเซ็นเพื่ออ่านค่าการเคลื่อนไหว และสถานะแบตเตอรี่ ข้อดีของอุปกรณ์ลักษณะนี้คือมีขนาดเล็ก ติดตั้งง่าย และสามารถส่งข้อมูลผ่าน BLE ไปยังอุปกรณ์กลางได้ ในบริบทของงานนี้ M5StickC Plus2 ถูกพิจารณาในฐานะ wheelchair sensor ที่อ่านข้อมูล IMU/battery และส่ง payload ไปยัง mobile gateway ไม่ใช่อุปกรณ์ที่ต้องทำหน้าที่เป็น gateway หลักของระบบทั้งหมด [17]

LilyGO T-SimCam เป็นบอร์ดที่มีความสามารถด้าน cellular และ camera module จึงเคยเหมาะกับแนวคิด node หรือ camera node ในต้นแบบช่วงแรก โดยเฉพาะการทดลอง

ตารางที่ 2.1: บทบาทของเทคโนโลยี IoT และ sensor ในระบบดูแล

เทคโนโลยี	หลักการสำคัญ	เหตุผลที่เกี่ยวข้องกับระบบดูแล
BLE	สื่อสารระยะใกล้ ใช้พลังงานต่ำ รองรับ advertising และ GATT	ใช้เชื่อม sensor กับ mobile gateway และใช้ RSSI เป็นข้อมูลตำแหน่งภายในอาคาร
MQTT	publish/subscribe ผ่าน broker	ส่ง telemetry หลายชนิดไปยัง server โดยไม่ผูกอุปกรณ์เข้ากับ service โดยตรง
IMU	วัดความเร่งและอัตราการหมุนหลายแกน	ใช้วิเคราะห์การเคลื่อนไหวของรถเข็นหรือกิจกรรมพื้นฐาน
Wearable sensor	วัดข้อมูลชีวสัญญาณ เช่น HR, RR interval และ PPG	เพิ่มข้อมูลสถานะร่างกายเพื่อประกอบการเฝ้าระวัง
Edge/local server	ประมวลผลและจัดเก็บข้อมูลในพื้นที่	ลด latency และลดการพึ่งพาระบบ cloud ภายนอก

โครงข่ายที่ต้องส่งข้อมูลหรือภาพผ่าน node ภาคสนาม อย่างไรก็ตาม อุปกรณ์ประเภทนี้มีความซับซ้อนด้านการติดตั้ง พลังงาน และการจัดเส้นทางข้อมูลมากกว่า sensor ขนาดเล็ก ในระบบสุดท้ายจึงควรถูกอธิบายในฐานะอุปกรณ์ที่เคยใช้ในต้นแบบหรือแนวคิด node เดิม ไม่ใช่แกนหลักของ architecture ปัจจุบัน [18]


Polar Verity Sense เป็นอุปกรณ์สวมใส่แบบ optical armband สำหรับอ่านข้อมูล heart rate และข้อมูลที่เกี่ยวข้องกับ PPG ผ่านการเชื่อมต่อ BLE และ Polar SDK อุปกรณ์นี้มีบทบาทในการเพิ่มข้อมูลด้านสัญญาณชีพให้ระบบดูแล เช่น HR, RR interval หรือ PPG stream โดยการอ่านค่าระดับลึกต้องอาศัย SDK ที่ผู้ผลิตเตรียมไว้ ข้อมูลจากอุปกรณ์สวมใส่จึงช่วยเสริมข้อมูลการเคลื่อนไหวจากรถเข็น แต่ยังคงถูกตีความอย่างระมัดระวังในฐานะข้อมูลประกอบ ไม่ใช่ผลวินิจฉัย [15], [19]

Raspberry Pi 5 RAM 8 GB เป็น single-board computer ที่มีพลังประมวลผลเพียงพอสำหรับบทบาท local/edge server ในระบบต้นแบบ เช่น API service, database, MQTT broker, dashboard และ AI runtime ขนาดเล็ก การใช้เครื่องลักษณะนี้ช่วยให้ระบบทดลองสามารถทำงานในพื้นที่ได้โดยไม่ต้องพึ่ง cloud ทั้งหมด และยังเปิดโอกาสให้ทดสอบการ deploy ด้วย Docker, การจัดเก็บข้อมูลใน PostgreSQL และการเรียกใช้ AI/MCP ภายในระบบเดียวกัน [20]

นอกจากอุปกรณ์หลักข้างต้น ระบบดูแลยังอาจมีอุปกรณ์รอง เช่น BLE beacon หรือ



(a) M5StickC Plus2



(b) LilyGO T-SimCam



(c) Polar Verity Sense



(d) Raspberry Pi 5

รูปที่ 2.2: อุปกรณ์ฮาร์ดแวร์หลักที่เกี่ยวข้องกับระบบต้นแบบ



(a) ตัวอย่างการติดตั้งอุปกรณ์กับรถเข็น



(b) ตัวอย่างการติดตั้ง node อัจฉริยะสัญญาณ

รูปที่ 2.3: ตัวอย่างการติดตั้งอุปกรณ์ภาคสนามที่เกี่ยวข้องกับการรับข้อมูลจากรถเข็นและ BLE node

node อ่างอิงสัญญาณ โทรศัพท์มือถือที่ทำหน้าที่ gateway เครื่องชาร์จ แหล่งจ่ายไฟสำรอง และ อุปกรณ์เครือข่ายภายในอาคาร อุปกรณ์เหล่านี้มีผลต่อความเสถียรของระบบ แต่ในเชิงทฤษฎีสามารถ จัดเป็นส่วนสนับสนุนของ sensor layer, network layer และ edge layer ตามบทบาทที่กล่าวไว้ ก่อนหน้า

2.4 การระบุตำแหน่งภายในอาคารด้วย BLE RSSI

การระบุตำแหน่งภายในอาคารมีความแตกต่างจากการระบุตำแหน่งกลางแจ้ง เนื่องจาก GPS ทำงานได้ไม่ดีในอาคารที่มีผนัง เพดาน และสัญญาณสะท้อนจำนวนมาก ระบบภายในอาคาร จึงมักใช้สัญญาณวิทยุจาก WiFi, BLE, UWB หรือ RFID แทน สำหรับระบบดูแลผู้สูงอายุ BLE เป็น ตัวเลือกที่เหมาะสมกับต้นแบบเพราะอุปกรณ์มีราคาต่ำ ใช้พลังงานน้อย และสามารถวัด RSSI ได้จาก อุปกรณ์รับสัญญาณทั่วไป

แนวคิดพื้นฐานของ RSSI คือความแรงของสัญญาณที่ตัวรับวัดได้จะลดลงเมื่อระยะห่าง จากตัวส่งเพิ่มขึ้น แบบจำลองที่ใช้บ่อยคือ log-distance path loss model ดังสมการ (2.1) [21]

$$d = d_0 \times 10^{\frac{P(d_0) - P(d)}{10n}} \quad (2.1)$$

เมื่อ d คือระยะที่ต้องการประมาณ, d_0 คือระยะอ้างอิง, $P(d_0)$ คือ RSSI ที่ระยะอ้างอิง, $P(d)$ คือ RSSI ที่วัดได้ และ n คือ path loss exponent ของสภาพแวดล้อม แม้สมการนี้ช่วยอธิบาย ความสัมพันธ์ระหว่าง RSSI กับระยะทางได้ แต่ในอาคารจริง RSSI มีความผันผวนสูงจาก multipath, สิ่งกีดขวาง และทิศทางของเสาอากาศ ดังนั้นการคำนวณระยะตรง ๆ แล้วหาจุดตัดแบบ trilateration จึงไม่ใช่แกนหลักที่เหมาะสมกับระบบนี้

วิธี fingerprinting แก้ปัญหาดังกล่าวโดยแบ่งงานเป็นสองช่วง ช่วงแรกคือ offline phase ที่วัดค่า RSSI จากตำแหน่งอ้างอิงหลายจุดและบันทึกเป็น radio map ช่วงที่สองคือ online phase ที่นำ RSSI ที่วัดได้จริงมาเปรียบเทียบกับ radio map เพื่อหาตำแหน่งที่มีรูปแบบสัญญาณใกล้เคียงที่สุด แนวคิดนี้ถูกใช้ในงาน indoor localization อย่างแพร่หลายตั้งแต่งานกลุ่ม RADAR และ ต่อยอดมาในระบบ BLE RSSI หลายรูปแบบ [22]

K-Nearest Neighbors (KNN) เป็นวิธีพื้นฐานที่ใช้กับ fingerprinting ได้ตรงไปตรงมา โดยแทนค่า RSSI ที่วัดได้เป็นเวกเตอร์ $\mathbf{x}$ และเปรียบเทียบกับ fingerprint ที่เก็บไว้เป็น $\mathbf{r}_j$ ระยะห่าง

ระหว่างเวกเตอร์คำนวณได้ตามสมการ (2.2) [23]

$$D_j = \sqrt{\sum_{i=1}^m (x_i - r_{j,i})^2} \quad (2.2)$$

เมื่อ m คือจำนวน beacon หรือ node อ้างอิง, x_i คือ RSSI ที่วัดได้จาก node ที่ i และ $r_{j,i}$ คือค่า RSSI ของ fingerprint ลำดับที่ j จากนั้นเลือก fingerprint ที่มีระยะน้อยที่สุดจำนวน K จุด เพื่อนำมาประเมินห้องหรือพิกัด การใช้ distance-weighted KNN ช่วยให้น้ำหนักของจุดที่ใกล้กว่าใน feature space มากกว่าจุดที่อยู่ไกลกว่า ดังสมการ (2.3)

$$w_j = \frac{1}{D_j + \varepsilon}, \quad \hat{c} = \arg \max_c \sum_{j \in N_K} w_j \cdot I(c_j = c) \quad (2.3)$$

เมื่อ N_K คือชุด fingerprint ใกล้เคียงที่สุดจำนวน K จุด, c_j คือคลาสหรือห้องของ fingerprint จุดที่ j , $I(\cdot)$ คือ indicator function และ ε เป็นค่าขนาดเล็กเพื่อป้องกันการหารด้วยศูนย์

ในกรณีที่ข้อมูล fingerprint ไม่ครบหรือค่า RSSI ไม่เหมาะกับการคำนวณ KNN ระบบสามารถใช้ max-RSSI เป็น baseline หรือ fallback ได้ แนวคิดคือเลือก node ที่มีค่า RSSI สูงที่สุดแล้วใช้ตำแหน่งหรือห้องของ node นั้นเป็นค่าประมาณ ดังสมการ (2.4)

$$i^* = \arg \max_i P_i, \quad \hat{c}_{\max} = c_{i^*} \quad (2.4)$$

วิธี max-RSSI มีความเรียบง่ายและเหมาะเป็น fallback แต่โดยทั่วไปจะไวต่อสัญญาณสะท้อนหรือการบังสัญญาณมากกว่า fingerprinting ดังนั้นในระบบต้นแบบจึงควรใช้ KNN เป็นวิธีหลักเมื่อมีข้อมูลเพียงพอ และใช้ max-RSSI ในกรณีที่ข้อมูลไม่ครบหรือโมเดลไม่สามารถประเมินได้อย่างมั่นใจ



รูปที่ 2.4: กระบวนการระบุตำแหน่งภายในอาคารด้วย BLE RSSI และ fingerprinting

2.5 การประมวลผลข้อมูล IMU และการเคลื่อนไหว

IMU เป็นเซ็นเซอร์ที่ใช้วัดการเคลื่อนไหวเชิงกล โดย accelerometer วัดความเร่งเชิงเส้นในแกน x, y, z และ gyroscope วัดอัตราการหมุนรอบแกนต่าง ๆ ข้อมูลทั้งสองชนิดสามารถใช้ตรวจสอบการเปลี่ยนแปลงสถานะของรถขึ้นหรือกิจกรรมของผู้ใช้ได้ เช่น การเริ่มเคลื่อนที่ การหยุดนิ่ง การเคลื่อนที่ต่อเนื่อง หรือการสั่นผิดปกติ หลักการประมวลผลข้อมูล IMU จึงมักเริ่มจากการลด noise การคำนวณ feature ในช่วงเวลา และการสรุปสถานะจาก feature เหล่านั้น [24]

สำหรับ accelerometer สามารถคำนวณ magnitude ของความเร่งรวมได้ตามสมการ (2.5) เพื่อรวมข้อมูลสามแกนให้เป็นค่าเดียวที่อ่านง่ายขึ้น

$$|\mathbf{a}_t| = \sqrt{a_{x,t}^2 + a_{y,t}^2 + a_{z,t}^2} \quad (2.5)$$

ข้อมูลที่วัดต่อเนื่องมักถูกแบ่งเป็น sliding window ความยาว W ตัวอย่าง แล้วคำนวณค่าสถิติ เช่น ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน ดังสมการ (2.6)

$$\mu = \frac{1}{W} \sum_{t=1}^W x_t, \quad \sigma = \sqrt{\frac{1}{W-1} \sum_{t=1}^W (x_t - \mu)^2} \quad (2.6)$$

อีก feature หนึ่งที่ใช้บ่อยคือจำนวนครั้งที่สัญญาณเปลี่ยนเครื่องหมายหรือ zero-crossing ซึ่งสะท้อนความถี่ของการสั่นหรือการเปลี่ยนทิศทางในช่วงเวลานั้น ดังสมการ (2.7)

$$ZC = \sum_{t=2}^W I(x_t x_{t-1} < 0) \quad (2.7)$$

ในงานที่นำ IMU ไปติดตั้งกับล้อรถขึ้น ข้อมูลจาก gyroscope สามารถใช้ประมาณความเร็วและระยะทางของล้อได้ หากให้ ω_t เป็นอัตราการหมุนที่ผ่านการกรองแล้วในหน่วย rad/s และ R เป็นรัศมีล้อ ความเร็วเชิงเส้นโดยประมาณคำนวณได้จากสมการ (2.8)

$$v_t = R\omega_t \quad (2.8)$$

จากนั้นสามารถประมาณความเร็วและระยะทางสะสมได้ตามสมการ (2.9)

$$a_t = \frac{v_t - v_{t-1}}{\Delta t}, \quad s_t = s_{t-1} + v_t \Delta t \quad (2.9)$$

ในทางปฏิบัติ ข้อมูล gyroscope ต้องผ่านการชดเชย offset และตัวกรอง เช่น Exponential Moving Average (EMA) เพื่อให้ค่าที่ใช้คำนวณความเร็วไม่แกว่งมากเกินไป สมการทั่วไปของ EMA แสดงในสมการ (2.10)

$$\hat{\omega}_t = \alpha \omega_t + (1 - \alpha) \hat{\omega}_{t-1} \quad (2.10)$$

เมื่อ α เป็นค่าปรับแต่งของตัวกรอง และ $\hat{\omega}_t$ คือสัญญาณหลังกรอง นอกจากนี้มักกำหนด deadband เพื่อตัด drift ขนาดเล็กขณะรถเซ็นหยุดนิ่ง ดังสมการ (2.11)

$$\omega'_t = \begin{cases} 0, & |\hat{\omega}_t| < \tau \\ \hat{\omega}_t, & |\hat{\omega}_t| \geq \tau \end{cases} \quad (2.11)$$

โดย τ คือ threshold ของ deadband ที่ต้องปรับให้เหมาะกับอุปกรณ์และตำแหน่งติดตั้ง การนำสูตรเหล่านี้ไปใช้จึงต้องประเมินร่วมกับการทดสอบจริง เพราะ IMU มี drift, noise, การสั่นจากพื้น และความคลาดเคลื่อนจากการติดตั้ง

ตารางที่ 2.2: ตัวอย่าง feature จาก IMU ที่ใช้กับการวิเคราะห์การเคลื่อนไหว

Feature	ข้อมูลที่ใช้	ความหมายเชิงพฤติกรรม
Acceleration magnitude	a_x, a_y, a_z	ระดับแรงสั่นหรือการเปลี่ยนแปลงการเคลื่อนไหวโดยรวม
Mean และ standard deviation	ค่าใน sliding window	ความเข้มข้นและความแปรปรวนของการเคลื่อนไหว
Zero-crossing	สัญญาณหลังกรองในแต่ละแกน	ความถี่ของการสลับทิศทางหรือการสั่น
Velocity และ distance	Gyroscope และรัศมีล้อ	ความเร็วและระยะทางโดยประมาณของรถเซ็น

2.6 Machine Learning สำหรับจำแนกพฤติกรรมหรือความเสี่ยง

Machine Learning ในระบบดูแลผู้สูงอายุทำหน้าที่แปลงข้อมูล sensor ที่มีความถี่สูง และอ่านยากให้เป็นสถานะหรือความเสี่ยงที่ผู้ดูแลเข้าใจได้ง่ายขึ้น ตัวอย่างเช่น แปลงข้อมูล IMU เป็นสถานะกำลังเคลื่อนที่ หยุดนิ่ง หรือมีการสั่นผิดปกติ หรือรวมข้อมูลการเคลื่อนไหวกับข้อมูลสัญญาณชีพเพื่อช่วยจัดลำดับความสำคัญของเหตุการณ์ ขั้นตอนสำคัญคือ feature engineering ซึ่งนำข้อมูลดิบมาสรุปเป็นตัวแปร เช่น mean, standard deviation, magnitude, zero-crossing, velocity, distance, heart rate และ RR interval

XGBoost เป็นอัลกอริทึม gradient tree boosting ที่ได้รับความนิยมเพราะรองรับ feature หลายชนิด จัดการความสัมพันธ์ไม่เชิงเส้นได้ดี และให้ผลลัพธ์ที่ดีความเชิง feature importance ได้ระดับหนึ่ง โมเดลประกอบด้วย decision tree หลายต้น โดยผลทำนายเกิดจากผลรวมของต้นไม้ทั้งหมด ดังสมการ (2.12) [25]

$$\hat{y}_i = \sum_{m=1}^M f_m(\mathbf{x}_i), \quad f_m \in \mathcal{F} \quad (2.12)$$

เมื่อ $\mathbf{x}_i$ คือ feature vector ของตัวอย่างที่ i , f_m คือ decision tree ต้นที่ m และ M คือจำนวนต้นไม้ทั้งหมด โดยการฝึกโมเดลจะพยายามลด loss ของข้อมูลฝึกพร้อมกับ regularization เพื่อลด overfitting ดังสมการ (2.13)

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{m=1}^M \Omega(f_m) \quad (2.13)$$

หากโมเดลให้ผลลัพธ์เป็น score ของแต่ละคลาส สามารถแปลงเป็นความน่าจะเป็นด้วย softmax ได้ตามสมการ (2.14)

$$p(y = c|\mathbf{x}) = \frac{\exp(z_c)}{\sum_{q=1}^C \exp(z_q)} \quad (2.14)$$

การประเมินโมเดล classification ควรพิจารณามากกว่า accuracy เพียงค่าเดียว เพราะข้อมูลพฤติกรรมหรือความเสี่ยงอาจไม่สมดุลระหว่างคลาส ค่า precision, recall และ F1-score จึงใช้ประกอบกันตามสมการ (2.15) [26]

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \quad Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN} \quad (2.15)$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2.16)$$

สำหรับระบบดูแล ความผิดพลาดของโมเดลมีความหมายเชิงความปลอดภัยต่างกัน

False negative อาจทำให้ระบบพลาดเหตุการณ์สำคัญ ขณะที่ false positive อาจเพิ่มภาระผู้ดูแลจาก alert ที่ไม่จำเป็น ดังนั้นการใช้โมเดลควรถูกออกแบบให้เป็นตัวช่วยคัดกรองเบื้องต้นและให้มนุษย์ตรวจสอบ ไม่ใช่กลไกตัดสินใจแทนผู้ดูแลทั้งหมด

2.7 Retrieval-Augmented Generation และ Retrieval Logic

Retrieval-Augmented Generation (RAG) เป็นแนวคิดที่ให้โมเดลภาษาใช้ข้อมูลจากแหล่งความรู้ภายนอกก่อนสร้างคำตอบ แทนที่จะตอบจากความรู้ที่อยู่ในพารามิเตอร์ของโมเดลเพียงอย่างเดียว ขั้นตอนทั่วไปคือรับ query, ค้นหาเอกสารหรือข้อมูลที่เกี่ยวข้อง, จัดแฟกบริบทให้กระชับและส่งบริบทนั้นให้ LLM สังเคราะห์คำตอบ วิธีนี้ช่วยลดปัญหาการตอบจากข้อมูลที่ไม่อยู่ในบริบทและทำให้ระบบสามารถอ้างอิงข้อมูลที่เปลี่ยนแปลงได้ง่ายขึ้น [27]

ในเชิงทฤษฎี RAG-Sequence สามารถเขียนแบบย่อได้ตามสมการ (2.17) โดย x คือ query, z คือเอกสารหรือบริบทที่ retrieve ได้ และ y คือคำตอบที่โมเดลสร้าง

$$p_{\text{RAG-Seq}}(y|x) \approx \sum_{z \in \text{top-}k(p_\eta(\cdot|x))} p_\eta(z|x) \prod_{i=1}^N p_\theta(y_i|x, z, y_{<i}) \quad (2.17)$$

เมื่อ $p_\eta(z|x)$ คือความน่าจะเป็นของ retriever ที่เลือกบริบท z จาก query และ p_θ คือ generator หรือ LLM ที่สร้างคำตอบจาก query และบริบทที่ได้ จุดสำคัญคือคุณภาพของคำตอบไม่ได้ขึ้นกับ LLM เพียงอย่างเดียว แต่ขึ้นกับการเลือกบริบท การจัดลำดับข้อมูล และการตัดข้อมูลที่ไม่จำเป็นออกจาก context window ด้วย

ในระบบที่เกี่ยวข้องกับข้อมูลผู้ป่วยหรือผู้พักอาศัย retrieval logic ควรมีข้อจำกัดชัดเจน



รูปที่ 2.5: แนวคิด Retrieval Logic ในระบบ RAG

เช่น ดึงเฉพาะข้อมูลที่มีผู้ใช้มีสิทธิ์เห็น ดึงเฉพาะช่วงเวลาที่เกี่ยวข้อง และไม่ส่งข้อมูลดิบมากเกินไปเข้าไปใน context window การแยกขั้นตอน retrieval ออกจากขั้นตอน generation ยังช่วยให้ตรวจสอบได้ว่าคำตอบหนึ่งเกิดจากบริบทใด ซึ่งสำคัญต่อความโปร่งใสและการแก้ไขข้อผิดพลาด


2.8 Neuro-symbolic AI และ AI Pipeline แบบ Rule + Model

Neuro-symbolic AI คือแนวคิดที่รวมความสามารถของ neural model เช่น deep learning หรือ LLM เข้ากับ symbolic component เช่น กฎ ตรรกะ schema knowledge graph หรือ policy ที่ตรวจสอบได้ งานวิจัยในสาขานี้มองว่าการใช้โมเดลเรียนรู้เพียงอย่างเดียวอาจมีข้อจำกัดด้านความโปร่งใสและการควบคุม ขณะที่ระบบ rule-based เพียงอย่างเดียวอาจไม่ยืดหยุ่นพอสำหรับภาษาธรรมชาติและบริบทที่ซับซ้อน การผสมทั้งสองส่วนจึงมีเป้าหมายเพื่อให้ระบบเข้าใจข้อมูลไม่เป็นโครงสร้างได้ดีขึ้น แต่ยังคงอยู่ภายใต้ข้อจำกัดที่ตรวจสอบได้ [28], [29]

สำหรับระบบดูแลที่ใช้ LLM และเครื่องมือภายนอก แนวคิดนี้สามารถนำมาใช้ในลักษณะ neuro-symbolic-inspired ได้ กล่าวคือ neural component ทำหน้าที่เข้าใจภาษา สรุบบริบท และสร้างคำตอบภาษาธรรมชาติ ส่วน symbolic component ทำหน้าที่กำหนด intent schema, policy, role permission, tool contract และ execution gate เพื่อป้องกันคำสั่งที่ไม่ผ่านเงื่อนไข ระบบลักษณะนี้ไม่ควร claim ว่าเป็น neuro-symbolic system เต็มรูปแบบ แต่สามารถอธิบายได้ว่าได้รับแรงบันดาลใจจากการแยกหน้าที่ระหว่าง model reasoning และ rule-based control

ตารางที่ 2.3: การแบ่งบทบาทระหว่าง neural และ symbolic component

ส่วนประกอบ	ตัวอย่างหน้าที่	ประโยชน์ต่อระบบดูแล
Neural	เข้าใจภาษาธรรมชาติ จัดกลุ่มความหมาย สังเคราะห์คำตอบ	รองรับคำถามหรือคำสั่งของผู้ดูแลที่มีรูปแบบหลากหลาย
Symbolic	intent rule, schema, policy, permission, tool contract	จำกัดขอบเขตการเข้าถึงข้อมูลและการสั่งงานให้ตรวจสอบได้
Execution gate	ตรวจ payload ก่อนเรียกใช้ tool หรือ MCP server	ลดความเสี่ยงจาก hallucination หรือคำสั่งที่ไม่ตรงสิทธิ์



รูปที่ 2.6: แนวคิด AI pipeline แบบผสม rule และ model สำหรับระบบที่เรียกใช้เครื่องมือ

Model Context Protocol (MCP) เป็นแนวทางหนึ่งในการกำหนดรูปแบบการเชื่อมต่อระหว่าง AI client กับเครื่องมือหรือ resource ภายนอก โดยช่วยให้ tool มี contract ชัดเจนและสามารถควบคุมการเข้าถึงผ่าน server ได้ [30], [31] เมื่อใช้ร่วมกับ execution gate ระบบสามารถแยกขั้นตอน “เสนอคำสั่ง” ออกจาก “อนุญาตให้สั่งงานจริง” ได้ชัดเจน ซึ่งเหมาะกับงานดูแลผู้สูงอายุ ที่การทำงานผิดพลาดอาจส่งผลกระทบต่อความปลอดภัยหรือความเป็นส่วนตัวของข้อมูล

2.9 งานวิจัยที่เกี่ยวข้อง

งานวิจัยด้าน indoor localization ด้วย BLE RSSI และ fingerprinting แสดงให้เห็นว่า RSSI สามารถใช้เป็นสัญญาณประกอบการระบุตำแหน่งภายในอาคารได้ แต่มีความผันผวนสูงและต้องอาศัยวิธีลดผลกระทบจากสภาพแวดล้อม งานของ Bahl และ Padmanabhan ในระบบ RADAR เป็นตัวอย่างสำคัญของการใช้ radio map และ fingerprinting เพื่อหาตำแหน่งภายในอาคาร [22] ส่วนงานวิเคราะห์ RSSI ในอาคารชี้ให้เห็นว่าค่า RSSI ได้รับผลกระทบจากตำแหน่งอุปกรณ์ สิ่งกีดขวาง และการสะท้อนของสัญญาณ [21] ทำให้การใช้ KNN และ fallback เช่น max-RSSI มีความเหมาะสมกับ prototype ที่ต้องรองรับความไม่แน่นอนของข้อมูล

งานวิจัยด้าน Human Activity Recognition (HAR) จาก wearable sensor และ IMU มักใช้กระบวนการแบ่งสัญญาณเป็น window แล้วคำนวณ feature เชิงสถิติ เช่น mean, variance, energy, magnitude และ zero-crossing ก่อนป้อนเข้าสู่โมเดลจำแนกพฤติกรรม [24] แนวทางนี้สอดคล้องกับการใช้ข้อมูลจาก accelerometer และ gyroscope บนรถเข็น เพราะข้อมูลดิบอ่านตีความยาก แต่เมื่อแปลงเป็น feature แล้วสามารถใช้จำแนกสถานะการเคลื่อนไหวหรือความผิดปกติได้ชัดเจนขึ้น

งานด้าน wearable health และ PPG สนับสนุนการใช้ sensor สวมใส่เพื่อติดตามข้อมูลชีวสัญญาณ เช่น heart rate, RR interval, PPG และข้อมูลการเคลื่อนไหว แต่ข้อจำกัดสำคัญคือคุณภาพสัญญาณขึ้นกับตำแหน่งสวมใส่ การเคลื่อนไหวของร่างกาย และ algorithm ของผู้ผลิต [15], [16] ดังนั้นการใช้ข้อมูล wearable ในระบบดูแลจึงควรเป็นข้อมูลประกอบการเฝ้าระวังและแจ้ง

เดือน ไม่ใช่การวินิจฉัยทางการแพทย์

งานด้าน Retrieval-Augmented Generation แสดงให้เห็นว่าการดึงบริบทจากแหล่งข้อมูลภายนอกก่อนให้โมเดลภาษาตอบ สามารถเพิ่มความเฉพาะเจาะจงและความสอดคล้องของคำตอบในงานที่ต้องใช้ความรู้จำนวนมาก [27] สำหรับระบบดูแล แนวคิดนี้นำมาประยุกต์ได้กับการดึงข้อมูลผู้พักอาศัย ข้อมูล sensor ล่าสุด ประวัติการแจ้งเตือน หรือ policy ก่อนสร้างคำตอบให้ผู้ดูแล

งานด้าน neuro-symbolic และ tool-use AI เน้นการผสมความสามารถของโมเดลกับกฎหรือ schema ที่ตรวจสอบได้ เพื่อเพิ่มความน่าเชื่อถือและลดความเสี่ยงจากการตัดสินใจแบบ black box [28], [29] เมื่อระบบต้องเรียกใช้เครื่องมือผ่าน MCP หรือ API ภายนอก การมี execution gate และ tool contract จึงเป็นกลไกสำคัญที่ทำให้การใช้ AI อยู่ในขอบเขตที่ปลอดภัยกว่า LLM ที่สามารถสั่งงานได้โดยไม่มีขั้นตรวจสอบ

ตารางที่ 2.4: การจัดกลุ่มงานวิจัยที่เกี่ยวข้องกับระบบต้นแบบ

กลุ่มงานวิจัย	ประเด็นสำคัญ	การเชื่อมโยงกับงานนี้
Indoor localization / BLE RSSI / KNN	RSSI ผันผวน ต้องใช้ fingerprinting หรือวิธี fallback	ใช้ KNN และ max-RSSI เพื่อประเมินพื้นที่ในอาคาร
Human activity recognition / IMU	แปลงสัญญาณเป็น feature ก่อนจำแนกพฤติกรรม	ใช้ feature จาก IMU และข้อมูลการเคลื่อนไหวของรถเข็น
Wearable health / PPG	วัด HR, RR interval และ PPG แต่ต้องระวัง noise	ใช้ข้อมูล wearable เป็นบริบทประกอบ ไม่ใช่ผลวินิจฉัย
RAG	ดึงบริบทก่อนให้ LLM ตอบ	ลดการตอบนอกข้อมูลและควบคุม context ของผู้พักอาศัย
Neuro-symbolic / tool-use AI	ใช้ rule, schema และ policy ควบคู่กับโมเดล	ใช้ execution gate และ MCP tool contract ก่อนสั่งงานจริง

2.10 ช่องว่างของงานวิจัยเดิม

จากการทบทวนทฤษฎีและงานวิจัยที่เกี่ยวข้อง พบว่างานจำนวนมากมักพัฒนาเฉพาะส่วนใดส่วนหนึ่งของระบบ เช่น งาน indoor localization ที่เน้นตำแหน่งจาก RSSI, งาน HAR ที่เน้นจำแนกกิจกรรมจาก IMU, งาน wearable health ที่เน้นสัญญาณชีพ, งาน dashboard ที่เน้นการแสดงผล หรือระบบ AI ที่เน้นการตอบคำถามและการเรียกใช้เครื่องมือ แต่ในบริบทการดูแลผู้สูงอายุ หรือผู้ใช้รถเข็น ผู้ดูแลต้องการภาพรวมที่เชื่อมข้อมูลเหล่านี้เข้าด้วยกันมากกว่าผลลัพธ์แยกส่วน

ช่องว่างสำคัญคือการรวม wheelchair sensor, wearable sensor, mobile gateway, indoor localization, dashboard ตามบทบาทผู้ใช้ และ AI/MCP tool pipeline ไว้ใน prototype เดียว โดยยังคงขอบเขตว่าเป็นระบบต้นแบบเพื่อสนับสนุนการดูแล ไม่ใช่เครื่องมือแพทย์ที่ผ่านการรับรอง การออกแบบลักษณะนี้ต้องจัดสมดุลระหว่างความสามารถด้าน sensor, ความเสถียรของการส่งข้อมูล, ความชัดเจนของ dashboard, และความปลอดภัยของ AI ที่อาจเข้าถึงข้อมูลหรือเครื่องมือในระบบ

ดังนั้น บทถัดไปจะนำแนวคิดจากบทนี้ไปออกแบบระบบในรูปแบบปัญหาไปสู่แนวทางแก้ไข โดยอธิบายว่าระบบถูกปรับจากข้อจำกัดของ prototype เดิมอย่างไร เหตุใด mobile gateway จึงกลายเป็นแกนหลักของการส่งข้อมูล และ AI pipeline ถูกแยกเป็นชั้นต่าง ๆ เพื่อควบคุม latency, context, hallucination และการส่งงานผ่าน MCP ได้อย่างไร


บทที่ 3

วิธีการออกแบบและพัฒนาระบบ

3.1 ภาพรวมของระบบ

ระบบต้นแบบ WheelSense ถูกออกแบบเป็นระบบดูแลและติดตามสถานะผู้ใช้งานและผู้สูงอายุในสภาพแวดล้อมภายในอาคาร โดยรวมข้อมูลจากเซ็นเซอร์รถเข็น อุปกรณ์สวมใส่ สมาร์ทโฟนที่ทำหน้าที่เป็น mobile gateway เซิร์ฟเวอร์ส่วนกลาง แดชบอร์ดตามบทบาทผู้ใช้ และระบบผู้ช่วย AI/MCP ให้อยู่ในโครงสร้างเดียวกัน จุดสำคัญของการออกแบบคือการลดภาระของผู้ดูแลที่ต้องตรวจสอบข้อมูลจากหลายแหล่งด้วยตนเอง และทำให้ข้อมูลตำแหน่ง การเคลื่อนไหว สัญญาณชีพ และเหตุการณ์ที่เกี่ยวข้องถูกส่งเข้าสู่ backend เดียวกันก่อนแสดงผลหรือใช้ประกอบการวิเคราะห์

แนวทางของระบบไม่ได้เริ่มจากการนำไปใช้งานจริงในสถานดูแลผู้สูงอายุทันที แต่ปรับรูปแบบจากการทดสอบภายในพื้นที่ทดลองของโครงการ เมื่อพบข้อจำกัดของการติดตั้งโหนด การเชื่อมต่อ Wi-Fi การรับค่า RSSI และความล่าช้าของการเรียกใช้ AI จึงปรับสถาปัตยกรรมให้สมาร์ทโฟนเป็น gateway หลักแทนการให้อุปกรณ์ภาคสนามส่งข้อมูลขึ้นระบบโดยตรงทั้งหมด สถาปัตยกรรมที่ใช้ในเล่มนี้จึงแยกภาระงานออกเป็น 4 ส่วน คือ field devices, mobile gateway, platform services และ dashboard/AI ดังรูปที่ 3.1



รูปที่ 3.1: สถาปัตยกรรมโดยรวมของระบบ WheelSense จากอุปกรณ์ภาคสนามไปยัง mobile gateway, platform services, dashboard และ AI

ข้อมูลในระบบเริ่มจาก M5StickC Plus2 ที่ติดตั้งบนรถเข็นและทำหน้าที่เป็น BLE sensor สำหรับอ่านข้อมูล IMU และแบตเตอรี่ อุปกรณ์ Polar Verity Sense ส่งข้อมูลสัญญาณชีพ

ผ่าน Polar SDK และสมาร์ตโฟนอ่าน RSSI จาก BLE node สำหรับใช้ประกอบการระบุตำแหน่งภายในอาคาร ข้อมูลเหล่านี้ถูกรวมที่แอป Flutter gateway ก่อนส่งเข้าสู่ MQTT broker หรือ REST API ตามชนิดข้อมูล จากนั้น FastAPI จะตรวจสอบรูปแบบข้อมูล บันทึกลง PostgreSQL และเปิดให้ dashboard หรือ AI pipeline ดึงไปใช้งานต่อ

3.2 การเชื่อมต่ออุปกรณ์ภาคสนามและ Mobile Gateway


การออกแบบส่วนเชื่อมต่ออุปกรณ์ภาคสนามผ่านการทดลองหลายรูปแบบเพื่อหาจุดสมดุลระหว่างความง่ายในการติดตั้ง ความต่อเนื่องของข้อมูล และภาระของ backend ในระยะแรกของแนวคิด ผู้พัฒนาเคยใช้โครงสร้าง Wi-Fi mesh โดยให้ Node T-SimCam รับข้อมูลจาก Xiao nRF52840 ที่โฆษณาสัญญาณ BLE แล้วส่งต่อข้อมูลเป็นทอด ๆ ไปยัง gateway node ที่มีอินเทอร์เน็ต ขณะเดียวกันฝั่งเว็บเริ่มจาก Vite ร่วมกับ React เพราะตอบสนองเร็วและพัฒนา UI ได้ง่าย แต่เมื่อระบบต้องรับ telemetry หลายชนิดและมี workflow เพิ่มขึ้น backend ต้องรับภาระจัดรูปแบบข้อมูลจำนวนมากเกินไป ข้อจำกัดที่พบในระยะนี้คือการติดตั้ง mesh ใช้เวลานาน การหา route ในพื้นที่จริงทำได้ยากเมื่อสภาพแวดล้อมเปลี่ยนแปลง และ delay สูงเกินกว่าจะใช้ติดตามสถานะผู้ใช้แบบต่อเนื่องได้ดี

แนวทางต่อมาคือย้ายภาระ gateway บางส่วนมาไว้ที่ M5StickC Plus2 โดยให้อุปกรณ์เชื่อมต่อ Wi-Fi และส่งค่า RSSI จาก node รวมถึงข้อมูลเซ็นเซอร์ของรถเข็นขึ้น server เอง เมื่อไม่มี Wi-Fi จึงเพิ่ม Wi-Fi Manager ให้ M5StickC เปิดเป็น access point เพื่อให้โทรศัพท์เข้าไปตั้งค่าและใช้ hotspot ได้ ส่วน node ที่ต้องส่งภาพหรือข้อมูลจากอาคารยังใช้เครือข่ายของพื้นที่และสื่อสารผ่าน MQTT/HTTP เพื่อส่งสถานะ คำสั่งควบคุม และภาพจากกล้องเข้าสู่ server ในช่วงนี้ frontend ถูกย้ายไปใช้ Next.js เพื่อรองรับ routing, server-side data และโครงสร้าง dashboard ที่ซับซ้อนขึ้น วิธีนี้ลดการพึ่งพา mesh ลง แต่ยังมีข้อจำกัดสำคัญคือเมื่อเครือข่าย Wi-Fi ไม่พร้อมใช้งาน การส่งข้อมูลจะหยุดชะงัก

เมื่อเพิ่ม Polar Verity Sense เข้ามาในระบบ ข้อมูล heart rate, RR interval และ PPG ต้องอ่านผ่าน Polar SDK ทำให้โทรศัพท์เริ่มมีบทบาทสำคัญมากขึ้น มีการพัฒนา mobile app ต้นแบบด้วย React Native และ Expo ซึ่งสามารถเชื่อมต่อ sensor และส่งข้อมูลผ่าน MQTT ได้ แต่การ build และ debug บนอุปกรณ์จริงใช้เวลานาน อีกทั้ง M5StickC Plus2 ยังทำหน้าที่ทั้งรับ

RSSI จาก node และส่งข้อมูลผ่าน Wi-Fi ทำให้ตำแหน่งของผู้ใช้มีข้อมูลซ้ำจากสองแหล่ง คือ RSSI ที่ M5StickC รับได้และ RSSI ที่โทรศัพท์รับได้ การจัดการข้อมูลจึงเริ่มซับซ้อนและเสี่ยงต่อการตีความตำแหน่งผิด


จากข้อจำกัดดังกล่าว ระบบที่ใช้ในต้นแบบปัจจุบันจึงให้สมาร์ทโฟนเป็น mobile gateway หลักเพียงจุดเดียว โดย M5StickC Plus2 ลดบทบาทเหลือเป็น BLE wheelchair sensor ที่ส่งข้อมูลไปยังโทรศัพท์โดยตรง Polar Verity Sense เชื่อมต่อกับโทรศัพท์ผ่าน Polar SDK และโทรศัพท์ยังอ่านจำนวนก้าวจาก step counter เพื่อรองรับผู้ใช้งานที่ไม่ได้อยู่บนรถเข็นตลอดเวลา การจัดวางนี้ทำให้ข้อมูลภาคสนามถูกรวมและจัดรูปแบบก่อนขึ้น server ลดปัญหาการมีข้อมูล RSSI ซ้ำจากหลายแหล่ง และช่วยให้ผู้ดูแลตรวจสอบสถานะการเชื่อมต่อจากหน้า gateway ได้ง่ายขึ้น



รูปที่ 3.2: ลำดับการปรับแนวทางการเชื่อมต่ออุปกรณ์ภาคสนามจากการทดลองภายในพื้นที่ทดสอบ

ในต้นแบบ Node T-SimCam ถูกใช้เป็นตัวอย่างของ camera/BLE node ภาคสนาม โค้ดเฟิร์มแวร์ใน `firmware/Node_Tsimcam` เริ่มจากโหลด configuration จากหน่วยความจำ ตั้งค่า camera และเริ่ม BLE beacon ด้วยชื่อ node ที่กำหนดไว้ หากยังไม่ได้ตั้งค่าหรือผู้ใช้กดปุ่ม boot ระหว่างเริ่มต้น อุปกรณ์จะเข้าสู่ config portal ผ่าน Wi-Fi access point เพื่อรับค่า device id, node id, Wi-Fi และ MQTT server แต่ถ้ามี configuration แล้วจะเชื่อมต่อ Wi-Fi เปิดหน้า HTTP status/config และเชื่อมต่อ MQTT broker จากนั้น loop หลักจะรับคำสั่งผ่าน MQTT/HTTP ส่ง


registration, status, ack และภาพถ่ายหรือ frame ตามคำสั่งที่ได้รับ



รูปที่ 3.3: วงรอบเฟิร์มแวร์ Node T-SimCam สำหรับ config portal, HTTP status, MQTT control และการส่งภาพ

ข้อจำกัดที่พบจากแนวทางนี้คือการเชื่อมต่อ Wi-Fi มีช่วงเวลารอที่ทำให้การเริ่มต้นช้าได้ และการ stream ภาพผ่าน HTTP client ต่อเนื่องอาจกินรอบการทำงานของ node มากกว่าการส่ง telemetry ขนาดเล็ก จึงเหมาะเป็นองค์ประกอบเสริมของต้นแบบมากกว่าการเป็น gateway หลักของระบบสุดท้าย การตัดสินใจย้าย gateway หลักไปไว้ที่โทรศัพท์จึงลดทั้งความซับซ้อนของ route และลดปัญหาความล่าช้าจาก node ที่ต้องทำงานหลายหน้าที่พร้อมกัน

จากลำดับดังกล่าว สถาปัตยกรรมปัจจุบันจึงย้ายจุดรวมข้อมูลมาอยู่ที่โทรศัพท์เป็นหลัก การส่งข้อมูลไม่ให้ไหลจากหลาย gateway พร้อมกันช่วยลดความซับซ้อนของ RSSI และทำให้ backend รับข้อมูลจากแหล่งเดียวที่จัดรูปแบบแล้ว ก่อนจะส่งต่อเข้าสู่ MQTT, REST API, ฐานข้อมูล และ dashboard ดังแสดงในรูปที่ 3.4



รูปที่ 3.4: ขั้นตอนการเชื่อมต่อรวมระหว่างอุปกรณ์ภาคสนาม mobile gateway และบริการส่วนกลาง

หากมีคำสั่ง config หรือ command ย้อนกลับจากฝั่ง dashboard หรือ AI ระบบจะไม่ส่งคำสั่งลงอุปกรณ์โดยตรงจาก LLM แต่ให้ backend และ mobile gateway ตรวจสอบเงื่อนไขก่อน แล้วจึงเขียนค่าไปยัง BLE characteristic หรือ config ที่เกี่ยวข้อง วิธีนี้ทำให้เส้นทางคำสั่งแยกจากเส้นทาง telemetry หลักและลดความเสี่ยงจากคำสั่งที่เกิดจากบริบทไม่ครบถ้วน

3.3 M5StickC Plus2 BLE Wheelchair Sensor

M5StickC Plus2 ถูกใช้เป็นเซ็นเซอร์ประจำรถเข็นเพื่อตรวจจับการเคลื่อนไหวของตัวรถ ไม่ได้ทำหน้าที่เป็น gateway หลักในสถาปัตยกรรมปัจจุบัน เฟิร์มแวร์ถูกออกแบบให้ทำงานเป็น BLE

peripheral พร้อม custom GATT service เพื่อให้แอป Flutter บนโทรศัพท์เชื่อมต่อ อ่านค่า และรับ notification ได้อย่างต่อเนื่อง ข้อมูลที่ส่งออกประกอบด้วยค่า IMU สถานะแบตเตอรี่ metadata ของอุปกรณ์ และค่าที่ประมวลผลแล้ว เช่น ความเร็ว ระยะทาง และความเร่งในช่วงเวลาปัจจุบัน

เมื่อเริ่มทำงาน เฟิร์มแวร์จะโหลด configuration ที่บันทึกไว้ เช่น ชื่ออุปกรณ์ ค่า room หรือค่าจับคู่ จากนั้นเริ่ม BLE advertising เพื่อประกาศ service UUID และรอ mobile gateway เชื่อมต่อ หลังเชื่อมต่อแล้วอุปกรณ์จะอ่านค่า IMU และแบตเตอรี่ตามรอบเวลา ประมวลผล gyro offset เพื่อลด bias ของแกนหมุน ใช้ exponential moving average (EMA) เพื่อลดสัญญาณรบกวน และใช้ deadband เพื่อตัดค่าการเคลื่อนไหวขนาดเล็กที่อาจเกิดจาก noise ก่อนคำนวณความเร็ว ระยะทาง และความเร่งของรถเซ็น


ตารางที่ 3.1: หน้าที่หลักของเฟิร์มแวร์ M5StickC Plus2 ในระบบปัจจุบัน

ส่วนการทำงาน	รายละเอียดการออกแบบ
Configuration	โหลดชื่ออุปกรณ์ สถานะจับคู่ ค่า room และค่าที่จำเป็นต่อการเชื่อมต่อ BLE
BLE GATT service	advertise service และเปิด characteristic สำหรับ telemetry, command, config และ time sync
Sensor sampling	อ่านค่า acceleration, angular velocity และ battery จากฮาร์ดแวร์ภายใน M5StickC Plus2
Signal processing	ชดเชย gyro offset ใช้ EMA และ deadband เพื่อลด noise ก่อนคำนวณ motion
Telemetry notify	ส่ง JSON payload ผ่าน BLE notification ไปยังโทรศัพท์ที่จับคู่ไว้
Command receiver	รับคำสั่ง start, stop, identify, pair, calibrate, reset distance, config และ time sync จากโทรศัพท์

โครงสร้างข้อมูลที่ส่งไปยังโทรศัพท์ถูกกำหนดให้เป็น JSON เพื่อให้ mobile gateway สามารถ normalize และส่งต่อเข้าระบบได้โดยไม่ต้องผูกกับรูปแบบ binary ของเฟิร์มแวร์โดยตรง ตัวอย่างกลุ่มข้อมูลหลัก ได้แก่ timestamp, device identifier, ค่า IMU, motion summary, battery level และสถานะการเชื่อมต่อ การกำหนดข้อมูลเป็น schema ลักษณะนี้ช่วยให้ backend ตรวจสอบและจัดเก็บข้อมูลใน PostgreSQL/JSONB ได้ง่ายขึ้น



รูปที่ 3.5: ตัวอย่างตำแหน่งติดตั้ง M5StickC Plus2 บนรถเข็นสำหรับอ่านค่าการเคลื่อนไหวและส่งข้อมูลผ่าน BLE ไปยังโทรศัพท์



รูปที่ 3.6: แผนผังวงจรการทำงานของเฟิร์มแวร์ M5StickC Plus2 แบบ BLE wheelchair sensor

3.4 Polar Verity Sense และ Flutter Mobile Gateway

อุปกรณ์ Polar Verity Sense ถูกเพิ่มเข้ามาเพื่อให้ระบบมีข้อมูลสัญญาณชีพประกอบกับข้อมูลการเคลื่อนไหวของรถเข็น การอ่านข้อมูลจาก Polar ไม่ได้ใช้เพียง BLE GATT มาตรฐานทั่วไปเท่านั้น แต่ใช้ Polar SDK เพื่ออ่านข้อมูลที่ละเอียดขึ้น เช่น heart rate, RR interval และ PPG stream จากนั้นแอป Flutter จะรวมข้อมูลของ Polar เข้ากับข้อมูลจาก M5StickC Plus2 และข้อมูล step counter ของโทรศัพท์


แอป Flutter ทำหน้าที่เป็น gateway หลักในระบบ เพราะเป็นจุดที่มีทั้ง BLE สำหรับเชื่อมต่ออุปกรณ์ภาคสนามและอินเทอร์เน็ตผ่าน Wi-Fi หรือเครือข่ายเซลลูลาร์ หน้าการทำงานที่เกี่ยวข้องกับการติดตั้งภาคสนามคือหน้า /WheelSensor ซึ่งใช้ตรวจสอบสถานะการเชื่อมต่อ BLE, Polar, M5StickC Plus2, MQTT และการส่งข้อมูลขึ้น server จุดนี้ช่วยให้ผู้ดูแลหรือผู้พัฒนาสามารถแยกปัญหาได้ว่าข้อมูลหายจากระดับ pairing, sensor stream, network publish หรือ backend ingest



รูปที่ 3.7: การใช้งาน Polar Verity Sense ร่วมกับสมาร์ทโฟนที่ทำหน้าที่เป็น mobile gateway

ตารางที่ 3.2: กลุ่มข้อมูลที่ mobile gateway รวมก่อนส่งเข้าสู่ระบบ

แหล่งข้อมูล	ข้อมูลที่รับเข้า gateway	การส่งต่อเข้าสู่ระบบ
M5StickC Plus2	IMU, motion summary, battery, device metadata	รวมเป็น telemetry ของรถเข็น และ publish ผ่าน MQTT/REST
Polar Verity Sense	HR, RR interval, PPG และสถานะแบตเตอรี่ตามที่ SDK รองรับ	normalize เป็นข้อมูลสัญญาณชีพของผู้ใช้และส่งพร้อม timestamp
Phone sensor	step counter และสถานะเครือข่ายของเครื่อง	ใช้ประกอบบริบทผู้ใช้ที่ไม่ได้อยู่บนรถเข็นตลอดเวลา
BLE RSSI nodes	รายการ beacon ที่พบและค่า RSSI	ส่งเป็นข้อมูลตำแหน่งให้ backend ประเมินห้องหรือโซน




รูปที่ 3.9: หน้าจอ /WheelSensor สำหรับตรวจสอบสถานะ BLE, Polar, M5StickC Plus2 และการส่งข้อมูลขึ้น server

3.5 Indoor Localization


การระบุตำแหน่งภายในอาคารของระบบใช้ค่า RSSI จาก BLE node ที่ติดตั้งตามพื้นที่อ้างอิง โดย mobile gateway สแกนสัญญาณจาก node รอบตัวและส่งรายการค่า RSSI พร้อม timestamp ไปยัง server สำหรับประเมินห้องหรือโซนของผู้ใช้ การออกแบบในบทนี้ไม่ลงรายละเอียดสมการซ้ำจากบทที่ 2 แต่เน้นกระบวนการนำข้อมูล RSSI เข้าระบบและการเลือกกลยุทธ์ที่ backend รองรับ

ในเชิง implementation ระบบรองรับทั้งการเทียบกับ fingerprint ด้วย KNN และการ




รูปที่ 3.8: วงรอบการทำงานของ Flutter mobile gateway สำหรับรวมข้อมูล Polar, M5StickC Plus2, RSSI และ step counter

ใช้ max-RSSI เป็น baseline หรือ fallback เมื่อข้อมูล fingerprint ยังไม่พร้อมหรือความมั่นใจต่ำ การใช้ KNN ต้องมีชุดข้อมูลอ้างอิงของแต่ละตำแหน่ง เช่น room, beacon alias, ค่า RSSI และข้อมูลผู้ใช้หรืออุปกรณ์ที่จับคู่ไว้ ส่วน max-RSSI เลือกตำแหน่งจาก beacon ที่มีสัญญาณแรงที่สุดในรอบปัจจุบัน จึงใช้งานง่ายกว่าแต่ไวต่อการสะท้อนและการเปลี่ยนแปลงของสภาพแวดล้อม



เส้นแบ่งแทนฉากกั้นหรือขอบเขตพื้นที่ที่ทดลอง
หมายเลข 1-4 คือ BLE node ที่วางบริเวณกึ่งกลางของแต่ละ zone

รูปที่ 3.10: แผนผังพื้นที่ทดลอง 4 zone พร้อมตำแหน่ง BLE node กึ่งกลางแต่ละพื้นที่สำหรับเก็บค่า RSSI



รูปที่ 3.11: Flowchart การส่งข้อมูล RSSI และการประเมินตำแหน่งด้วย KNN หรือ max-RSSI fallback

การเขียนข้อมูลตำแหน่งกลับเข้าสู่ระบบทำเป็นข้อมูลที่ตรวจสอบย้อนกลับได้ โดยเก็บทั้ง raw RSSI reading และผล room prediction แยกกัน เพื่อให้สามารถวิเคราะห์ภายหลังได้ว่าความคลาดเคลื่อนเกิดจากสัญญาณต้นทาง การตั้งค่า fingerprint หรือการเลือกกลยุทธ์ของ localization ในช่วงเวลานั้น การแยก raw data กับ prediction ยังช่วยให้ Chapter 4 สามารถประเมินความแม่นยำของ KNN และ fallback ได้อย่างเป็นระบบ

3.6 Server, API และ Database

ส่วน server ของ WheelSense ประกอบด้วย MQTT broker, FastAPI backend, PostgreSQL 16 และบริการที่เกี่ยวข้องกับ dashboard/AI โดยออกแบบให้รองรับข้อมูลทั้งแบบ structured และ semi-structured ข้อมูล structured เช่น users, patients, devices, workspaces, rooms และ assignments ใช้สำหรับกำหนดความสัมพันธ์หลักของระบบ ส่วนข้อมูล semi-structured เช่น telemetry payload, AI trace, device configuration และ event metadata เก็บใน JSONB เพื่อรองรับ payload จากอุปกรณ์ที่อาจเปลี่ยนรายละเอียดระหว่างการทดลอง

MQTT broker รับ telemetry จาก mobile gateway และ topic ที่เกี่ยวกับอุปกรณ์ภาคสนาม ส่วน FastAPI รับทั้งข้อมูลจาก gateway, dashboard และ AI/MCP pipeline ผ่าน REST endpoint หรือ internal service การออกแบบ backend ใช้ async I/O เพื่อให้รับข้อมูลจากหลายอุปกรณ์พร้อมกันได้โดยไม่บล็อกการทำงานของ API หลัก เมื่อข้อมูลเข้ามา server จะทำขั้นตอน ingest, validate, store, query และส่งต่อไปยัง dashboard หรือ AI ตามลำดับ


ตารางที่ 3.3: บริการหลักของ platform services ในระบบ WheelSense

บริการ	เทคโนโลยี	หน้าที่ในระบบ
MQTT broker	Eclipse Mosquitto	รับ telemetry จาก mobile gateway และใช้ส่ง config หรือสถานะบางส่วนกลับไปยังอุปกรณ์
Backend API	FastAPI	ตรวจสอบข้อมูล จัดการสิทธิ์ ประมวลผล request จาก dashboard/gateway และเปิด API ให้ AI ใช้ข้อมูล
Database	PostgreSQL 16 + JSONB	เก็บ schema หลักของระบบ telemetry, RSSI, room prediction, AI trace และข้อมูลตั้งค่า
Frontend	Next.js	แสดงผล dashboard ตามบทบาทผู้ใช้และเรียกข้อมูลจาก backend ผ่าน API
AI/MCP runtime	Agent runtime + MCP server	จัดเตรียมบริบท ใช้ LLM แบบมีข้อจำกัด และควบคุมการเรียก tool ผ่าน execution gate



รูปที่ 3.12: ลำดับการประมวลผลข้อมูลฝั่ง server ตั้งแต่ ingest, validate, store, query ไปจนถึง dashboard และ AI

schema หลักของระบบสามารถแบ่งได้เป็น 5 กลุ่ม ได้แก่ กลุ่ม workspace และสิทธิ์ผู้ใช้ กลุ่ม patient และ assignment กลุ่ม device และ room binding กลุ่ม telemetry/localization และกลุ่ม AI/runtime log ตารางเช่น users, patients, devices, workspaces, rooms, imu_telemetry, rssi_readings, room_predictions, mobile_device_telemetry, pipeline_events และ behavioral_states ช่วยให้ข้อมูลจากหลายส่วนถูกอ้างอิงกลับไปยังผู้ใช้ อุปกรณ์ และพื้นที่ได้อย่างเป็นระบบ



แผนภาพความสัมพันธ์ของเอนทิตี (ER Diagram) เบื้องต้นในฐานข้อมูล

รูปที่ 3.13: แผนภาพ schema ฐานข้อมูลที่ใช้เชื่อม workspaces, users, patients, devices และข้อมูล telemetry

ตารางที่ 3.4: ตัวอย่างกลุ่มข้อมูลที่จัดเก็บใน PostgreSQL และ JSONB

กลุ่มข้อมูล	ตารางหรือ entity ตัวอย่าง	เหตุผลในการออกแบบ
User/workspace	users, workspaces, roles	แยกขอบเขตองค์กรและสิทธิ์การเข้าถึงข้อมูลของผู้ใช้แต่ละบทบาท
Patient/device	patients, devices, assignments	เชื่อมผู้พักอาศัยกับอุปกรณ์ รถเข็น และห้องที่เกี่ยวข้อง
Telemetry	imu_telemetry, mobile_device_telemetry	เก็บข้อมูลจาก M5, Polar, phone และ gateway พร้อม timestamp
Localization	rss_i_readings, room_predictions, training data	แยก raw RSSI ออกจากผลทำนายเพื่อประเมินย้อนหลังได้
AI runtime	pipeline_events, behavioral_states	เก็บ trace ของแต่ละ layer และ behavioral context สำหรับตรวจสอบการทำงานของ AI


3.7 Dashboard และ HMI ตามบทบาทผู้ใช้

Dashboard ของ WheelSense พัฒนาด้วย Next.js เพื่อเป็นหน้าจอหลักสำหรับผู้ดูแลและผู้ใช้งานตามบทบาท การออกแบบ HMI ไม่ได้ให้ผู้ใช้ทุกกลุ่มเห็นข้อมูลเท่ากัน แต่กำหนด permission และมุมมองตามหน้าที่จริงในระบบ เพื่อให้ผู้ใช้แต่ละกลุ่มเห็นเฉพาะข้อมูลที่จำเป็นต่อการตัดสินใจหรือติดตามสถานะ ขณะที่ mobile app ทำหน้าที่เป็น gateway ภาคนามสำหรับ pairing sensor และส่งข้อมูล ไม่ใช่ dashboard หลักของทุกบทบาท

ตารางที่ 3.5: บทบาทผู้ใช้ หน้าจอหลัก และหน้าที่ที่รองรับบน dashboard


บทบาท	หน้าจอหลักที่ใช้	งานที่ทำได้ในระบบ
Admin	Dashboard overview, task operations, facility, floorplans, devices, personnel, alerts, messages, support, settings, EaseAI	จัดการ workspace, ผู้ใช้, อุปกรณ์, ห้อง, floorplan, task, profile ของผู้พักอาศัย และ staff รวมถึงตรวจสอบสถานะของ platform และเรียกใช้ AI assistant ภายใต้อิทธิพลของผู้ดูแลระบบ
Head Nurse	Dashboard overview, alerts, patient profile, task operations, devices, floorplans, personnel, staff, messages, support	ติดตามผู้พักอาศัยหลายคน ตรวจสอบ alert จัดลำดับความสำคัญ มอบหมายงาน และดูข้อมูลสัญญาณชีพ/ตำแหน่งในระดับที่เกี่ยวข้องกับการดูแล
Supervisor	Dashboard overview, emergency, task operations, floorplans, personnel, prescriptions, patient profile, messages, support	ตรวจภาพรวมงานและเหตุการณ์ในพื้นที่ ติดตาม emergency/task ที่ต้องส่งต่อ และตรวจสอบข้อมูลผู้พักอาศัยหรือบุคลากรในขอบเขตการกำกับดูแล
Observer	Dashboard overview, alerts, floorplans, prescriptions, task operations, patient profile, personnel, messages, support	เฝ้าดูสถานะและเหตุการณ์แบบจำกัดสิทธิ์ ใช้ข้อมูลเพื่อสังเกตการณ์หรือรายงานต่อผู้ดูแล โดยไม่แก้ไขข้อมูลสำคัญของระบบ
Patient	Personal dashboard, schedule, pharmacy, room controls, services, messages, support, settings	ดูข้อมูลส่วนตัวของตนเอง เช่น care plan, schedule, medication/service request, room control และช่องทางขอความช่วยเหลือหรือสื่อสารกับผู้ดูแล

ตารางบทบาทข้างต้นถูกแปลงเป็น role flow เพื่อให้เห็นว่าแต่ละกลุ่มผู้ใช้ไม่ได้เข้าถึงข้อมูลชุดเดียวกันทั้งหมด แต่ทุกคำขอจะผ่าน permission และ visibility layer ก่อนเรียกข้อมูลจาก FastAPI หรือ telemetry/AI context รูปที่ 3.14 แสดงลำดับการไหลของหน้าจอจากบทบาทผู้ใช้ไปยัง service หลักของระบบ โดยไม่รวม mobile gateway เพราะ mobile gateway อยู่ในเส้นทางรับส่งข้อมูล sensor ที่อธิบายไว้ก่อนหน้านี้




รูปที่ 3.14: HMI role flow ของระบบ WheelSense แสดงการผ่านสิทธิ์ บริบท workspace และ service ที่ dashboard เรียกใช้งาน

การใช้งานที่ซ้ำกันหลายบทบาท เช่น task operations, patient profile, staff profile, messages และ support ถูกอธิบายจากสิทธิ์ของ Admin ก่อน เนื่องจาก Admin เห็นภาพรวมมากที่สุดและใช้ตรวจสอบความครบถ้วนของข้อมูลระบบได้ หน้าจอ task operations ใช้ติดตามงานหรือเหตุการณ์ที่ต้องมอบหมายให้ผู้ดูแล ส่วน patient/staff profile ใช้ดูรายละเอียดรายบุคคลและสถานะที่เกี่ยวข้อง เช่น ข้อมูลผู้พักอาศัย อุปกรณ์ที่ผูกไว้ การแจ้งเตือน และข้อมูลบุคลากรใน workspace เมื่อบทบาทอื่นใช้งานหน้าจอกลุ่มเดียวกัน ระบบจะลดข้อมูลหรือ action ตาม permission ไม่ใช่แยก logic ใหม่ทั้งหมด



รูปที่ 3.15: ภาพหน้าจอระบบในมุมมอง Admin ครอบคลุม overview, task, profile, device, facility, alert, message, support, setting และ EaseAI


ในมุมมอง Head Nurse ระบบเน้นข้อมูลที่ต้องใช้ดูแลผู้ป่วยอาศัยโดยตรง เช่น alert, patient profile, task operations, device status และ floorplan เพราะเหตุการณ์หนึ่งอาจมาจากอาการหรือพฤติกรรมของผู้พักอาศัย หรืออาจมาจากอุปกรณ์ขาดการเชื่อมต่อ ภาพที่ 3.16 จึงแสดง workflow หลักที่ Head Nurse ใช้ตรวจสอบสถานะก่อนตัดสินใจส่งงานหรือแจ้งผู้ดูแลคนอื่น



รูปที่ 3.16: ภาพหน้าจอระบบในมุมมอง Head Nurse สำหรับติดตามผู้พักอาศัย alert, task, device, floorplan และช่องทางสื่อสาร

บทบาท Supervisor และ Observer มีหน้าจอหลายส่วนร่วมกับผู้ดูแล แต่ขอบเขตต่างกัน Supervisor ใช้ dashboard เพื่อดูภาพรวมงาน เหตุการณ์ฉุกเฉิน และข้อมูลที่ต้องส่งต่อไป

ระดับปฏิบัติการ ส่วน Observer ใช้สำหรับเฝ้าดูสถานะหรือบันทึกเหตุการณ์โดยลด action ที่มีผลต่อข้อมูลหลักของระบบ ภาพที่ 3.17 แสดงหน้าจอที่ใช้ในสองบทบาทนี้ โดยคงโครงสร้าง navigation ใกล้เคียงกันเพื่อให้ผู้ใช้เปลี่ยนบทบาทหรือฝึกใช้งานได้ง่ายขึ้น




(a) มุมมอง Supervisor


(b) มุมมอง Observer

รูปที่ 3.17: ภาพหน้าจอระบบในมุมมอง Supervisor และ Observer สำหรับการติดตามงานและสถานะตามสิทธิ์

หน้าจอ Patient ถูกออกแบบให้เห็นเฉพาะข้อมูลของผู้ใช้รายนั้น เช่น care plan, schedule, medication, room control, service request และช่องทางติดต่อผู้ดูแล ไม่แสดงรายการผู้พักอาศัยคนอื่นหรือข้อมูลบุคลากรที่ไม่เกี่ยวข้อง ภาพที่ 3.18 เป็นภาพหน้าจอของ Patient dashboard ที่ใช้ในการตรวจสอบรอบปัจจุบัน ส่วนภาพที่ 3.19 แสดงหน้าจออื่นใน portal ของผู้ป่วย เช่น schedule, pharmacy, room controls, services, messages, support และ settings



รูปที่ 3.18: ภาพหน้าจอ Patient dashboard สำหรับผู้ใช้รายบุคคล แสดงข้อมูล care plan สถานะรถเข็น และช่องทางขอความช่วยเหลือ



รูปที่ 3.19: ภาพหน้าจอระบบในมุมมอง Patient ครอบคลุม personal dashboard, schedule, pharmacy, room controls, services, messages, support และ settings

EaseAI เป็น assistant ที่เปิดจาก dashboard เพื่อช่วยผู้ดูแลค้นข้อมูล สรุปรีบติ หรือเตรียม action candidate จากข้อมูลในระบบอนุญาตให้เข้าถึง การใช้งานเริ่มจากผู้ใช้เปิดแผง EaseAI เลือกคำถามตัวอย่างหรือพิมพ์คำถามเอง จากนั้นระบบส่งข้อความพร้อม role, workspace และบริบทที่จำเป็นเข้าสู่ AI pipeline ในหัวข้อ 3.8 หากคำตอบเป็นเพียงการสรุปข้อมูล ระบบจะแสดงผลกลับในหน้าต่างสนทนา แต่ถ้าเกี่ยวข้องกับการสั่งงานจริงจะต้องผ่าน execution gate และเงื่อนไขการยืนยันก่อนเสมอ ภาพที่ 3.20 แสดงตัวอย่างหน้าจอ EaseAI บนมุมมอง Admin

WheelSense Smart Care Platform

ADMIN SYSTEM OVERVIEW

System Overview

Desktop-first governance, setup, and health monitoring. System status is separated from configuration and daily care operations.

Export CSV Alerts Work Support Users

Devices Audit Settings

Realtime facility map
Open room status, active alerts, and device presence without leaving the dashboard.

Emergency: 0 People: 12 Find:

Open map →

System health
Service health is tracked separately from menu access and configuration.

Service	Status	Detail	Open
HEALTHY SERVICES	4/4		
FLEET ONLINE	6/31		
SMART BRIDGE	6/6		
RECENT EVENTS	1		
API	Healthy	Request layer and workspace scoping are available.	Open →
Database	Healthy	Admin and fleet records are readable.	Open →
MQTT Broker	Healthy	31 registered device(s) and recent signals are present.	Open →
Automation pipeline	Healthy	Platform automation services are available for admin operations.	Open →
Devices	Needs review	6/31 online	Open →
Smart bridge	Healthy	6/6 online	Open →

EaseAI
Role assistant

Summarize system risks today. What should I audit right now?

Ask about patients, alerts, workflows, or ward operations.

Message...

Device health → Broker signal is healthy.

Operations 3 destination(s)

- Alerts** → SystemAlerts, audit issues trail, and demo control escalations
- Audit** → 1 recent event(s)
- Demo control** → Reset and scenario control

System 1 destination(s)

- Settings** → Integrate platform security settings and governance configuration

Fleet detail
Device management stays in a detail table instead of being mixed into the overview controls.

Hardware	Total	Online	Offline	Open
Wheelchairs	6	6	0	Open →
Nodes	16	0	16	Open →
Polar Sense	7	0	7	Open →
Mobile phones	2	0	2	Open →
Smart devices	6	6	0	Open →

Recent governance activity
Audit trail and recent device changes are kept as a compact detail list.

Event	Summary	Time
registry_deleted	Device wheelsense-mobile-mpa2b9it removed from workspace registry	5/18/2026, 1:10:02 AM

View full audit →


รูปที่ 3.20: ภาพหน้าจอ EaseAI ใน dashboard สำหรับถามข้อมูลหรือเตรียม action ภายใต role permission และ MCP execution gate

3.8 ระบบ AI และ MCP Tool Pipeline

ส่วน AI ของระบบถูกออกแบบใหม่จากปัญหาของแนวทางเดิมที่ให้ LLM และ MCP agent จัดการงานส่วนใหญ่ในเส้นทางเดียว เมื่อระบบมี tool หลายกลุ่ม เช่น การค้นข้อมูลผู้พักอาศัย การอ่านข้อมูล sensor การสรุปสถานะ และการเตรียม action ให้ผู้ดูแลตรวจสอบ prompt ต้องบรรจุคำอธิบาย tool, schema, policy และบริบทจำนวนมาก ส่งผลให้เกิด token overhead สูง และ latency เพิ่มขึ้นมาก จากบันทึกการพัฒนาระบบเดิมพบว่าโมเดลขนาด 7B บางรอบใช้เวลาประมาณ 30–45 นาที หรือมากกว่านั้นเมื่อต้อง reasoning กับ tool หลายขั้นตอน แม้ภายหลังจะลดขนาดโมเดลและปรับ prompt แล้ว เวลาตอบสนองยังไม่เหมาะกับ dashboard ที่ผู้ดูแลต้องรอผลในรอบการทำงานสั้นกว่าเดิม


หลังการทดสอบรอบแรก ระบบถูกปรับเป็นแนวทางที่แยก logic เชิงสัญลักษณ์ออกจาก การสังเคราะห์ภาษาของ LLM โดยให้ deterministic rule, schema, policy และ tool contract ทำงานร่วมกับ LLM แทนการปล่อยให้โมเดลตัดสินใจทุกขั้นตอน แนวทางนี้เป็นการออกแบบแบบ neuro-symbolic-inspired กล่าวคือใช้ LLM สำหรับความเข้าใจเชิงภาษาและการเรียบเรียงคำตอบ ส่วนเงื่อนไขเชิงระบบและการสั่งงานจริงยังถูกควบคุมด้วยกฎและ schema ที่ตรวจสอบได้ จึงไม่กล่าวอ้างว่าเป็นระบบ neuro-symbolic เต็มรูปแบบ แต่ใช้หลักการดังกล่าวเพื่อลด hallucination และ ลดคำสั่งที่อยู่นอกขอบเขต

pipeline หลักของระบบแบ่งเป็น 5 layer ได้แก่ Layer 1 Intent Router, Layer 2 Context Assembler, Layer 3 Behavioral State, Layer 4 Constrained LLM และ Layer 5 Execution Gate อย่างไรก็ตาม Layer 3 ไม่ได้อยู่ใน execute path หลักแบบ synchronous เสมอไป เส้นทางหลักของคำสั่งคือ Layer 1 → Layer 2 → Layer 4 → Layer 5 ส่วน Layer 3 ทำหน้าที่เตรียมและเก็บ behavioral context จากข้อมูลผู้ใช้หรือเหตุการณ์ เพื่อให้ระบบนำบริบทนี้กลับมาใช้ในคำถามหรือการประเมินรอบถัดไปได้




รูปที่ 3.21: โครงสร้าง AI pipeline 5 layer โดย Layer 3 ทำหน้าที่เตรียม behavioral context นอกเส้นทาง execute หลัก

Layer 1 Intent Router ทำหน้าที่รับคำสั่งจากผู้ใช้แล้วจัดกลุ่มเจตนาเบื้องต้นก่อนให้ LLM ทำงาน ระบบเริ่มจาก deterministic matching เช่น keyword, route, role และ schema ที่คาดหวัง หาก confidence เพียงพอจะส่ง query พร้อม intent ไปยัง Layer 2 ได้ทันที หากยังไม่ชัดเจนจึงใช้ semantic matching เพื่อวัดความใกล้เคียงเชิงความหมาย และหากยังขาดข้อมูลสำคัญ เช่น ไม่ระบุผู้ป่วยอาศัย ห้อง หรือ action ที่ต้องการ ระบบจะหยุด pipeline แล้วถามกลับแทนการเดาคำสั่ง



รูปที่ 3.22: Layer 1 Intent Router สำหรับจับเจตนาแบบ deterministic ก่อนใช้ semantic matching และ clarification

Layer 2 Context Assembler รับ intent จาก Layer 1 แล้วเลือกบริบทที่เกี่ยวข้องกับคำสั่ง เช่น ข้อมูลผู้ป่วยอาศัย สถานะ sensor ล่าสุด ประวัติ telemetry สรุปเชิงพฤติกรรม หรือเอกสารใน RAG ขั้นตอนไม่ได้ดึงข้อมูลทั้งหมดเข้า prompt แต่เริ่มจากการวางแผนว่าคำสั่งต้องใช้หัวข้อใด จากนั้น fetch และ rank เฉพาะ chunk ที่อนุญาตตาม role และ policy ก่อนแพ็กบริบทให้สั้น ไม่ซ้ำ และตรวจย้อนกลับได้



รูปที่ 3.23: Layer 2 Context Assembler สำหรับดึงและจัดแพ็กบริบทก่อนส่งเข้า LLM


บริบทที่ถูกส่งต่อจะประกอบด้วยข้อมูลที่จำเป็นต่อคำตอบหรือการสั่งงานเท่านั้น เช่น patient id, device id, ค่า telemetry ล่าสุด, สิทธิ์ของผู้ใช้ และข้อความอ้างอิงที่ถูกดึงจาก

retrieval logic วิธีนี้ทำให้ Layer 4 ไม่ต้องรับ prompt ขนาดใหญ่ทุกครั้ง และลดโอกาสที่ LLM จะเห็นข้อมูลที่ไม่เกี่ยวข้องจนสรุปผิด



รูปที่ 3.24: Layer 4 Constrained LLM สำหรับสังเคราะห์คำตอบหรือ execution candidate ภายใต้ schema ที่กำหนด

Layer 4 Constrained LLM เป็นชั้นที่ใช้ LLM สังเคราะห์คำตอบภายใต้ prompt และ schema ที่จำกัดไว้ ระบบใช้ schema-bound prompting เพื่อระบุรูปแบบผลลัพธ์ที่ต้องการ เช่น ต้องตอบเป็นข้อความสรุป ต้องคืนค่า action candidate หรือไม่ควรเรียก tool ใดในสถานการณ์นั้น หากคำสั่งเกี่ยวข้องกับ MCP ระบบจะให้ LLM สร้าง execution candidate ที่มี argument ตาม schema เท่านั้น ยังไม่ให้ดำเนินการกับระบบจริงในขั้นนี้



รูปที่ 3.25: Layer 5 Execution Gate สำหรับตรวจสอบ schema, policy และยืนยันการส่งงานผ่าน MCP tool

Layer 5 Execution Gate เป็นชั้นป้องกันก่อนส่งคำสั่งไปยัง MCP server หรือ backend tool โดยตรวจสอบ schema, policy, role, allowlist และเงื่อนไขด้านความปลอดภัยของ action อีกครั้ง หาก argument ไม่ครบ สิทธิ์ไม่ตรง หรือ action เสี่ยงเกินขอบเขต ระบบจะไม่ execute และส่งผลกลับเป็นคำถามหรือคำอธิบายให้ผู้ดูแลตรวจสอบ วิธีนี้ทำให้ LLM ไม่สามารถส่งงานจริงได้โดยลำพัง แม้จะสร้างข้อความที่ดูเหมือนคำสั่งถูกต้อง

Layer 3 Behavioral State ทำงานเป็นกระบวนการเตรียมบริบทจากข้อมูล biometrics, movement, resident id และ timestamp ที่ระบบรับมาอย่างต่อเนื่อง ข้อมูลรายวันถูกบีบให้เป็นสัญญาณที่อ่านได้ เช่น ค่าเฉลี่ย ส่วนเบี่ยงเบนมาตรฐาน rolling window แนวโน้มจาก linear regression และจำนวนเหตุการณ์ผิดปกติ จากนั้นระบบใช้ rule หรือ model เช่น XGBoost ในระดับต้นแบบเพื่อจัดกลุ่มความเร่งด่วนและแกนปัญหาที่ควรเฝ้าดู ผลลัพธ์ถูกเก็บเป็น behavioral database เพื่อให้ Layer 2 ดึงกลับไปประกอบคำตอบรอบถัดไป ไม่ใช่การวินิจฉัยทางการแพทย์หรือการตัดสินใจแทนผู้ดูแล



รูปที่ 3.26: Layer 3 Behavioral State สำหรับเตรียมบริบทพฤติกรรมจากข้อมูล sensor และ เหตุการณ์ของผู้ใช้

ส่วน Edge AI ที่เกี่ยวข้องกับ Layer 3 ยังอยู่ในระดับ proof of concept โดยแนวคิด ด้าน motion anomaly ใช้ข้อมูล IMU เช่น gyro magnitude, acceleration magnitude และ rolling standard deviation เพื่อสังเกตการเคลื่อนไหวที่ต่างจากรูปแบบปกติ ส่วนแนวคิดด้าน health anomaly ใช้ HR, RR interval และ PPG จาก Polar Verity Sense เป็นบริบทประกอบ หากพบเหตุการณ์ที่เข้าข่ายผิดปกติ ระบบจะสร้าง event หรือ context ให้ผู้ดูแลตรวจสอบผ่าน dashboard หรือใช้ประกอบการตอบของ AI ต่อไป ไม่ได้ใช้เป็นผลตัดสินใจทางคลินิก



รูปที่ 3.27: Context Window Management สำหรับจำกัดบริบทให้มีขนาดเหมาะสมและตรวจสอบย้อนกลับได้

Context Window Management เป็นส่วนสนับสนุนที่ช่วยให้การสนทนาและผลลัพธ์จาก tool ไม่โตจนเกินขอบเขตของโมเดล แต่ยังย้อนกลับได้ว่าแต่ละคำตอบใช้ข้อมูลใด ระบบจึง tag payload ตาม session และ I/O turn เก็บ embedding signal สำหรับใช้ rank ร่วมกับความใหม่ของข้อมูล และมี policy จำกัดจำนวน active session หรือ bundle ที่เก็บใน context เมื่อข้อมูลเก่าเกินจำเป็นจะถูกลดความสำคัญหรือถอดออกจาก prompt แต่ยังคงบันทึกในฐานข้อมูลหรือ log เพื่อการตรวจสอบภายหลัง

MCP ทำหน้าที่เป็นสัญญาณระหว่าง AI runtime กับระบบจริง โดยฝั่ง agent runtime เป็นผู้ประกอบเจตนา บริบท และ schema ก่อนส่ง execution candidate ไปยัง execution gate ส่วน MCP server เปิด resources, prompts และ tools ที่ผ่านการควบคุมสิทธิ์แล้ว การแยกเช่นนี้ช่วยลดโอกาสที่ LLM จะเรียกใช้คำสั่งนอกขอบเขต เพราะ tool ที่รันจริงต้องผ่านทั้ง schema validation, allowlist ตามบทบาท และ execution gate ก่อนเสมอ

3.9 แนวทางการประเมินผลระบบ

การประเมินผลระบบถูกออกแบบให้เชื่อมกับองค์ประกอบหลักของสถาปัตยกรรมที่อธิบายในบทนี้ โดยไม่สรุปผลเกินกว่าข้อมูลทดลองที่มี ในบทที่ 4 แต่ละหัวข้อจึงระบุสภาพแวดล้อม การทดสอบ วิธีทดสอบ ผลที่ได้ และการวิเคราะห์ในรูปแบบย่อหน้าต่อเนื่อง เพื่อให้ผู้อ่านแยกได้ว่า ปัญหาหรือข้อจำกัดเกิดจาก sensor, gateway, server, dashboard หรือ AI pipeline

ตารางที่ 3.6: แนวทางการประเมินผลที่ใช้ต่อเนื่องไปยังบทผลการทดลอง

ส่วนที่ประเมิน	สิ่งที่ทดสอบ	ตัวชี้วัดหรือผลที่ต้องรายงาน
Sensor และอุปกรณ์ภาคสนาม	M5StickC Plus2 IMU, battery, Polar HR/RR/PPG, BLE connection	ความต่อเนื่องของข้อมูล ความถูกต้องเชิงสังเกต และความเสถียรของการเชื่อมต่อ
Indoor localization	การเก็บ fingerprint, KNN, max-RSSI fallback และการส่งผล prediction	accuracy, error หรือความคลาดเคลื่อนรายจุด พร้อมวิเคราะห์ RSSI fluctuation
Mobile gateway และ server	BLE pairing, MQTT/REST publish, reconnect/offline handling, backend ingest	อัตราการส่งข้อมูลสำเร็จ latency และการแสดงผลบน dashboard
Dashboard/HMI	workflow ของ Admin, Head Nurse, Supervisor, Observer และ Patient	task completion, ข้อสังเกตจากการใช้งาน และ SUS Score สำหรับ usability
AI/MCP pipeline	Intent routing, context retrieval, constrained LLM, execution gate และ trace ต่อ layer	IRR, cosine similarity, latency ต่อ layer และความปลอดภัยของ tool execution

การเพิ่ม SUS Score ในการประเมินช่วยให้ส่วน HMI ไม่ได้ประเมินจากภาพหน้าจอหรือความเห็นทั่วไปเพียงอย่างเดียว แต่มีคะแนนมาตรฐานด้าน usability ประกอบกับ task scenario ของผู้ใช้ ขณะที่การประเมิน AI ใช้ทั้งความเห็นของมนุษย์ต่อคำตอบ ความใกล้เคียงเชิงข้อความ และ latency ราย layer เพื่อแสดงให้เห็นว่าการแยก logic ออกจาก LLM ช่วยให้ระบบตรวจสอบและปรับปรุงได้เป็นส่วน ๆ

บทที่ 4

ผลการทดลองและการประเมินผล

4.1 ภาพรวมการทดลอง

การประเมินผลระบบต้นแบบ WheelSense ในบทนี้จัดทำเพื่อดูว่าองค์ประกอบหลักที่พัฒนาไว้สามารถทำงานร่วมกันได้ในระดับต้นแบบหรือไม่ โดยแบ่งการทดสอบออกเป็น ส่วนที่สอดคล้องกับสถาปัตยกรรมในบทที่ 3 ได้แก่ อุปกรณ์ sensor และอุปกรณ์ภาคสนาม การระบุตำแหน่งภายในอาคารด้วย RSSI/KNN การทำงานของ mobile gateway และ server การใช้งาน dashboard/HMI พร้อมการประเมิน SUS และการทดสอบ AI/MCP pipeline ในด้านความสอดคล้องของการเลือกเครื่องมือ ความสม่ำเสมอของคำตอบ และเวลาแฝงของแต่ละ layer

การทดลองทั้งหมดเป็นการทดสอบในพื้นที่ทดลองและสภาพแวดล้อมของโครงการ ไม่ใช่การนำระบบไปใช้งานจริงในสถานดูแลผู้สูงอายุแบบต่อเนื่อง ดังนั้นผลที่รายงานจึงเป็นผลเพื่อยืนยันความเป็นไปได้ของระบบต้นแบบและเพื่อระบุข้อจำกัดที่ต้องพัฒนาต่อ ไม่ใช่การรับรองความพร้อมใช้งานทางการแพทย์หรือการใช้งานจริงในทุกสภาพแวดล้อม ตารางที่ 4.1 แสดงขอบเขตการทดลองที่ใช้ในบทนี้

จากตารางที่ 4.1 การรายงานผลจะไม่แยกเป็นคำอธิบายเชิงทฤษฎีซ้ำกับบทที่ 2 หรือ บทที่ 3 แต่จะเน้นว่าทดสอบในเงื่อนไขใด ใช้วิธีใด ผลที่ได้เป็นอย่างไร และผลนั้นสะท้อนข้อจำกัดของระบบส่วนใด การจัดรูปแบบนี้ยึดแนวทางเดียวกับรายงานรุ่นพี่ที่อธิบายเงื่อนไขการทดลองก่อน แล้วจึงอ้างตารางหรือรูปเพื่อสรุปผลที่วัดได้

ตารางที่ 4.1: ภาพรวมขอบเขตการทดลองของระบบ WheelSense

ส่วนที่ทดสอบ	ประเด็นที่ประเมิน	หลักฐานที่ใช้ประกอบผล
Sensor และอุปกรณ์ภาคสนาม	ความถี่ IMU, ความครบถ้วนของ telemetry, การจำแนก motion state, การเชื่อมต่อ Polar	ตารางสรุป sensor, ตาราง motion state, ภาพอุปกรณ์ และผล mobile gateway
Indoor localization	ผลของ RSSI fingerprint, KNN และ max-RSSI fallback เมื่อสัญญาณผันผวน	ตารางผล RSSI/KNN ในภาคผนวก และการวิเคราะห์ข้อจำกัดของสัญญาณ
Mobile gateway และ server	BLE connection, MQTT/REST publish, reconnect, database latency และ dashboard update	ตาราง gateway, ตาราง server/database latency และภาพ runtime
Dashboard/HMI และ SUS	การทำงานตามบทบาทผู้ใช้ task completion และ usability score ที่มีหลักฐานประกอบ	ตาราง task result และ usability summary โดยระบุสถานะของ SUS score อย่างระมัดระวัง
AI/MCP pipeline	IRR, cosine similarity และ latency ของ Layer 1, 2, 4 และ 5	ชุดทดสอบ AI 36 กรณี และการวัด latency 30 รอบ


4.2 การทดสอบ Sensor และอุปกรณ์ภาคสนาม

การทดสอบส่วนนี้ตรวจสอบการทำงานของ M5StickC Plus2 ที่ติดตั้งกับรถเข็นเพื่ออ่านค่า IMU และ battery ร่วมกับ Polar Verity Sense ที่อ่านข้อมูลสัญญาณชีพผ่าน mobile gateway การทดสอบทำในพื้นที่ทดลองโดยกำหนดลักษณะการเคลื่อนไหวของรถเข็นเป็น 4 กลุ่ม ได้แก่ หยุดนิ่ง เคลื่อนที่ปกติ เลี้ยวแรง และเหตุการณ์ลักษณะกระแทก เพื่อดูว่าข้อมูล sensor มีความต่อเนื่องเพียงพอและสามารถใช้จำแนกสถานะเบื้องต้นได้หรือไม่

ขั้นตอนการทดลองเริ่มจากการให้ M5StickC Plus2 อ่านค่า IMU ด้วยรอบเวลาที่กำหนด จากนั้นส่งข้อมูล telemetry ผ่าน mobile gateway ไปยัง broker และ backend ส่วนข้อมูลการเคลื่อนไหวถูกแบ่งเป็นหน้าต่างข้อมูลเพื่อเปรียบเทียบกับ การสังเกตระหว่างทดลอง ผลสรุปเชิงระบบแสดงในตารางที่ 4.2

เมื่อพิจารณาข้อมูล motion state การจำแนกสถานะหยุดนิ่งและการเคลื่อนที่ปกติให้ผลดีกว่าสถานะเลี้ยวแรงและเหตุการณ์ลักษณะกระแทก เนื่องจากสองสถานะหลังเกิดในช่วงเวลาสั้น และขึ้นกับแรงที่ผู้ทดสอบกระทำต่อรถเข็น ตารางที่ 4.3 แสดงจำนวนหน้าต่างข้อมูลและผลที่ตรวจจับได้

ผลการทดสอบแสดงว่า M5StickC Plus2 สามารถอ่านและส่งข้อมูล IMU ได้ใกล้เคียง



รูปที่ 4.1: การติดตั้ง M5StickC Plus2 บนรถเข็นสำหรับทดสอบข้อมูล IMU และ telemetry

ตารางที่ 4.2: ผลสรุปการทดสอบอุปกรณ์ภาคสนาม

ตัวชี้วัด	ค่าเฉลี่ย	P95	หมายเหตุ
IMU sampling rate	19.6 Hz	20.3 Hz	ใกล้เคียงเป้าหมาย 20 Hz
telemetry completeness	98.4%	99.1%	คิดจาก packet ที่รับได้ เทียบกับจำนวนที่คาดหวัง
device/gateway to broker latency	41 ms	156 ms	ทดสอบภายใต้เครือข่ายปกติของพื้นที่ทดลอง
Polar connection success	94.4%	–	พบการ re-pairing บางรอบ


ตารางที่ 4.3: ผลการตรวจจับสถานะการเคลื่อนไหวจากหน้าต่างข้อมูล IMU

สถานะ	จำนวน window	ตรวจจับได้	Accuracy	หมายเหตุ
stationary	50	49	0.98	baseline ของการ สั่นต่ำ
normal motion	50	47	0.94	รถเข็นเคลื่อนที่ปกติ
sharp turn	40	36	0.90	gyro magnitude สูงขึ้นในช่วงสั้น
impact-like	30	27	0.90	ตรวจเทียบกับการ สั่นกระหว่าง ทดลอง

ค่าที่ออกแบบไว้ ขณะที่ telemetry completeness อยู่ในระดับที่เพียงพอสำหรับระบบต้นแบบ อย่างไรก็ตามการจำแนกเหตุการณ์ที่เกิดขึ้นเร็ว เช่น การลื่นไถลหรือการกระแทก ยังต้องอาศัยข้อมูลระยะยาวและการทวนสอบกับเหตุการณ์จริงมากขึ้นก่อนใช้เป็นตัวชี้วัดความเสี่ยง

4.3 การทดสอบ Indoor Localization ด้วย KNN

การทดสอบการระบุตำแหน่งภายในอาคารใช้ข้อมูล RSSI จาก BLE node ในพื้นที่ทดลอง โดย gateway สแกนสัญญาณและส่งรายการ RSSI พร้อม timestamp เข้าสู่ backend เพื่อประเมินตำแหน่งด้วย fingerprint และ KNN ในกรณีที่ fingerprint ยังไม่พร้อมหรือค่าความมั่นใจต่ำ ระบบสามารถใช้ max-RSSI เป็น baseline หรือ fallback ได้ การรายงานหัวข้อนี้ใช้รูปแบบ Setting, How we test, Result และ Analysis เพื่อแยกเงื่อนไขการทดลองออกจากการวิเคราะห์ผล




รูปที่ 4.2: ตัวอย่างหน้าจอ mobile gateway ที่ใช้ตรวจสอบสถานะตำแหน่งและข้อมูลจาก BLE node

Setting พื้นที่ทดลองจากชุดข้อมูล RSSI แบ่งห้องหนึ่งออกเป็น 4 zone ขนาดประมาณ 4×4 เมตรต่อ zone โดยใช้ฉากผ้าเป็นขอบเขตระหว่างพื้นที่ และติดตั้ง ESP32-S3 BLE anchor จำนวน 4 ตัวไว้บริเวณกึ่งกลางของแต่ละ zone ที่ระดับความสูงประมาณ 0.7 เมตร อุปกรณ์ tag คือ

M5StickC Plus2 ที่โฆษณา BLE ด้วยอัตราประมาณ 5 Hz หรือคาบ 200 ms และอยู่ที่ระดับความสูงประมาณ 0.7 เมตรเช่นกัน ข้อมูลหนึ่งตัวอย่างประกอบด้วย timestamp และค่า RSSI จาก anchor ทั้ง 4 ตัวในรูปแบบ $(timestamp, r_1, r_2, r_3, r_4)$

How we test ชุดทดลองแบ่งเป็น 3 กรณี กรณีละ 48 episode และใช้การแบ่งข้อมูลแบบเดียวกันคือ 13 episode สำหรับ train และ 35 episode สำหรับ test โดย Case 1 เป็นการตรวจ body orientation แบบ facing-in/facing-out, Case 2 เป็น boundary transition ระหว่างในและนอก zone และ Case 3 เป็น multi-zone trajectory ที่ต้องทำนายลำดับการเคลื่อนที่ผ่าน 4 zone วิธี KNN ใช้ $k = 5$ และ Euclidean distance สำหรับ Case 1 และ Case 2 จะทำนายจาก RSSI 4 มิติราย sample แล้วรวมผลเป็นระดับ episode ด้วยค่าเฉลี่ยของผลทำนาย ส่วน Case 3 แบ่ง episode เป็น 4 segment ต่อเนื่องและใช้ feature mean/std ของ RSSI จาก anchor ทั้ง 4 ตัวในแต่ละ segment เพื่อทำนายลำดับ zone



รูปที่ 4.3: ตัวอย่างสัญญาณ RSSI ต่อเนื่องจากชุดทดลอง Case 1, Case 2 และ Case 3

Result ผลการทดสอบ KNN จากชุดข้อมูลที่มีหลักฐานประกอบแสดงในตารางที่ 4.4 โดยรายละเอียด raw data และ summary อยู่ในภาคผนวก ค และแนบหน้าเอกสาร PaperIEEE ที่เกี่ยวข้องไว้ในภาคผนวก ญ

ตารางที่ 4.4: ผลการทดสอบ RSSI/KNN จากชุดข้อมูลที่มีหลักฐานประกอบ

Case	เงื่อนไขทดลอง	Accuracy	Precision	Recall	F1
Case 1	Body orientation, facing-in/facing-out	0.8857	0.8421	0.9412	0.8889
Case 2	Boundary transition, in/out zone	0.6857	0.6875	0.6471	0.6667
Case 3	Multi-zone trajectory, exact sequence	0.8857	0.8857	0.8857	0.8857

Analysis จากตารางที่ 4.4 Case 1 และ Case 3 ให้ค่าความถูกต้องเท่ากันที่ 0.8857

โดย Case 3 ยังมีค่า per-position accuracy สูงกว่าค่า exact sequence เพราะการทำนายลำดับหนึ่ง episode ต้องถูกครบทุกตำแหน่งพร้อมกันจึงนับว่าถูก ส่วน Case 2 ลดลงเหลือ 0.6857 เนื่องจากตำแหน่งบริเวณ boundary มี RSSI จากหลาย anchor ใกล้เคียงกันและได้รับผลจาก body shadowing หรือ multipath พร้อมกันหลายช่องสัญญาณ KNN จึงสับสนได้ง่ายเมื่อ distribution ของ RSSI ซ้อนทับกัน ผลนี้สะท้อนว่า BLE RSSI ใช้ได้ในระดับ zone สำหรับ prototype แต่ยังต้องเก็บ fingerprint ในตำแหน่งจริงให้มากขึ้น ปรับจำนวน anchor หรือใช้ fallback เช่น max-RSSI/temporal smoothing เมื่อค่า confidence ต่ำ


4.4 การทดสอบ Mobile Gateway และ Server

ส่วน mobile gateway ถูกทดสอบเพื่อดูการรวมข้อมูลจาก M5StickC Plus2, Polar Verity Sense และข้อมูลจากโทรศัพท์ก่อนส่งเข้าสู่ platform ผ่าน MQTT หรือ REST API การทดสอบเน้นเวลาการเชื่อมต่อ BLE, latency จาก smartphone ไปถึง broker, อัตราความสำเร็จของ MQTT publish, ความครบถ้วนของ vitals telemetry และการทำงานเมื่อเกิด reconnect หรือ retry queue

ผลการทดสอบในตารางที่ 4.5 แสดงว่าเวลาการเชื่อมต่อ BLE GATT อยู่ในระดับไม่กี่วินาที และการส่งข้อมูลจาก smartphone ไปถึง broker มีค่า p50 เท่ากับ 78 ms ส่วน MQTT publish มีอัตราสำเร็จ 98.6% ซึ่งเพียงพอสำหรับการทดสอบระบบต้นแบบ แต่ยังพบผลกระทบจากการ re-pairing และการสูญหายของ PPG block บางช่วง

สำหรับฝั่ง server การทดสอบตรวจสอบเส้นทาง ingest, validate, store และ query ผ่าน FastAPI, MQTT broker และ PostgreSQL/JSONB บน Raspberry Pi 5 โดยดูทั้งค่า latency ราย endpoint และการอ่านข้อมูลที่ dashboard หรือ AI ต้องใช้ซ้ำ


ผลจาก mobile gateway และ server สะท้อนว่าสถาปัตยกรรมที่ให้โทรศัพท์เป็น gateway หลักช่วยลดปัญหาข้อมูลซ้ำจากหลายแหล่งและทำให้สามารถตรวจสอบสถานะการเชื่อมต่อได้ชัดเจน ขณะที่ backend มี latency ระดับเพียงพอสำหรับ dashboard ต้นแบบ อย่างไรก็ตาม BLE และ PPG stream ยังไวต่อการเคลื่อนไหวของผู้ใช้และการ reconnect จึงต้องเพิ่ม offline buffer และ diagnostic ที่ละเอียดขึ้นก่อนใช้งานระยะยาว




รูปที่ 4.4: หน้าจอ mobile gateway สำหรับตรวจสอบการเชื่อมต่อ Polar Verity Sense และสถานะส่งข้อมูล

ตารางที่ 4.5: ผลการทดสอบ mobile gateway และ latency ของ server path

ตัวชี้วัด	P50/ค่าเฉลี่ย	P95	หมายเหตุ
BLE GATT connection time	3.2 s	5.8 s	ทดสอบการจับคู่กับ M5StickC Plus2
smartphone to broker latency	78 ms	215 ms	วัดจาก gateway ไปถึง broker
MQTT connection success	98.6%	–	มี retry/reconnect บางช่วง
vitals completeness	96.2%	98.9%	telemetry จาก Polar ผ่าน mobile gateway
heart rate resting	72.4 bpm	–	ค่าที่ใช้เป็น baseline ระหว่างทดสอบ
heart rate active	95.6 bpm	–	ค่าขณะเคลื่อนไหว/ทำกิจกรรม
PPG block loss	2.1%	–	บางช่วงหายจากการเคลื่อนไหวหรือ BLE reconnect



รูปที่ 4.5: ตัวอย่างการตรวจสอบบริการบน Raspberry Pi 5 และ Docker runtime ระหว่างการทดสอบ server



รูปที่ 4.6: กราฟสรุปการกระจายของ latency ในเส้นทาง MQTT ระหว่างการทดสอบ

ตารางที่ 4.6: ผลการทดสอบ latency ของ query ฐานข้อมูล

Query path	P50	P95	หมายเหตุ
recent telemetry JSONB	3 ms	43 ms	อ่านค่าสถานะล่าสุดของผู้ใช้
alert list by patient state	14 ms	50 ms	อ่านรายการ alert สำหรับ dashboard
recent sensor event	12 ms	35 ms	อ่านเหตุการณ์ล่าสุดจากอุปกรณ์
audit trail read	24 ms	51 ms	อ่านประวัติการทำงาน

4.5 การประเมิน Dashboard/HMI และ SUS Score

การประเมิน dashboard/HMI ใช้ task scenario ตามบทบาทผู้ใช้ เช่น Admin, Head Nurse, Supervisor, Observer และ Patient โดยดูว่าผู้ใช้สามารถเข้าถึงข้อมูลผู้พักอาศัย สถานะ อุปกรณ์ alert และหน้าที่เกี่ยวข้องกับ mobile gateway ได้ครบหรือไม่ ผลที่รายงานเป็นข้อมูลระดับต้นแบบและใช้เพื่อประเมินทิศทาง usability ของระบบ

ตารางที่ 4.7: ผลสรุป usability ของ dashboard/HMI จากหลักฐานปัจจุบัน

ตัวชี้วัด	ผลเฉลี่ย	การตีความ
task completion	0.93	ผู้ใช้งานใหญ่ทำภารกิจหลักสำเร็จในสถานการณ์ทดสอบ
average satisfaction	4.31/5	ความพึงพอใจต่อภาพรวมอยู่ในระดับดีสำหรับต้นแบบ
alert readability	4.42/5	ข้อความและการจัดวาง alert อ่านได้ค่อนข้างชัดเจน
role navigation clarity	4.18/5	การแยกบทบาทช่วยลดความสับสน แต่ยังต้องเพิ่ม workflow บางส่วน
SUS mean / SD	76.5 / 8.7	ใช้เป็นผลเบื้องต้นเท่านั้นจนกว่าจะมี raw SUS item ครบ

เพื่อให้เห็นงานย่อยในแต่ละบทบาท ตารางที่ 4.8 สรุป task ที่ใช้ทดสอบ dashboard และ mobile gateway ผลแสดงว่าหน้าที่ดูผู้พักอาศัยและอ่าน alert ทำได้ดีกว่างานที่เกี่ยวกับการแก้ไขอุปกรณ์หรือการตรวจ queue การส่งข้อมูล ซึ่งเป็นส่วนที่ควรพัฒนาต่อใน workflow ของผู้ดูแล

ตารางที่ 4.8: ผลการทำภารกิจบน dashboard และ mobile gateway

ภารกิจ	completion	เวลาเฉลี่ย	หมายเหตุ
เปิดหน้า resident dashboard	0.95	18 s	พบข้อมูลผู้พักอาศัยได้เร็ว
acknowledge alert	0.90	24 s	ต้องปรับการแยก priority ให้ชัดเจน
ตรวจสอบสถานะอุปกรณ์	0.92	26 s	บางรายการต้องเปิดหลายหน้า
ตรวจสอบข้อมูล gateway/mobile	0.95	21 s	หน้า gateway ช่วยแยกปัญหา BLE/MQTT ได้
อ่านประวัติ audit trail	0.91	29 s	ต้องเพิ่มตัวกรองตามช่วงเวลา

ผล usability แสดงว่า dashboard ช่วยให้ผู้ดูแลมองเห็นข้อมูลผู้พักอาศัยและสถานะอุปกรณ์ได้รวมศูนย์มากขึ้น แต่หลักฐานด้าน SUS ยังไม่ครบพอที่จะใช้เป็นข้อสรุปสุดท้าย เพราะยัง

ต้องแนบ raw item score และเพิ่มจำนวนผู้เข้าร่วมทดสอบให้มากขึ้น

4.6 การทดสอบ AI: Inter-Rater Reliability

การทดสอบ Inter-Rater Reliability ใช้เพื่อประเมินว่า AI/MCP pipeline เลือกเครื่องมือหรือแนวทางปฏิบัติได้สอดคล้องกับมนุษย์หรือไม่ ชุดคำสั่งทดสอบมีจำนวน 36 ข้อ แบ่งตามระดับความกำกวมเป็น 4 กลุ่ม โดยมี human raters จำนวน 2 คนเป็นผู้กำหนด ground truth ของเจตนาและเครื่องมือที่เหมาะสม

ผลการทดสอบแสดงในตารางที่ 4.9 ระบบทำได้ถูกต้อง 31 จาก 36 ข้อ หรือ 86.11% โดยข้อผิดพลาดทั้ง 5 ข้ออยู่ในกลุ่มที่มีความกำกวมสูง

ตารางที่ 4.9: ผลการทดสอบ AI Inter-Rater Reliability ตามระดับความกำกวม

กลุ่มคำสั่ง	จำนวนคำสั่ง	ถูกต้อง	หมายเหตุ
No-ambiguous	10	10	เจตนาชัดเจน
Low-ambiguous	10	10	มีคำกำกวมเล็กน้อย
Medium-ambiguous	10	10	ยังระบุ intent ได้
High-ambiguous	6	1	ระบบเลือกถามกลับหรือหยุดมากกว่าการเดา
รวม	36	31	86.11%

การที่ข้อผิดพลาดกระจุกตัวอยู่ในกลุ่ม High-ambiguous ไม่ได้หมายความว่าระบบลังงานผิดทั้งหมด แต่สะท้อนกลไก safety over guessing ของ Layer 1 Intent Router ที่ยอมถามกลับเมื่อความมั่นใจไม่พอ แทนที่จะเดาเจตนาแล้วส่งต่อไปยัง tool โดยตรง แนวทางนี้เหมาะกับระบบที่อาจเกี่ยวข้องกับผู้ป่วยอาศัยและอุปกรณ์จริง เพราะลดโอกาสเกิดการสั่งงานผิดบริบท

4.7 การทดสอบ AI: Text-Distance / Cosine Similarity

การทดสอบ Text-Distance ใช้ cosine similarity เพื่อประเมินความสม่ำเสมอของคำตอบจาก Layer 4 เมื่อได้รับคำถามเดิมซ้ำหลายรอบ การทดสอบเริ่ม session ใหม่ทุกครั้งและไม่ใช้ context window เดิม เพื่อให้เห็นผลของ retrieval ranking และลำดับบริบทที่ Layer 2 ส่งให้ Layer 4 โดยตรง

จากตารางที่ 4.10 กลุ่ม General มีค่าเฉลี่ย 0.85 สูงกว่ากลุ่ม Health/context ที่ได้ 0.76 เหตุผลสำคัญคือคำถามด้านสุขภาพหรือบริบทผู้ป่วยอาศัยต้องใช้ข้อมูลจาก RAG มากกว่า เมื่อ

ตารางที่ 4.10: ผลการทดสอบ Text-Distance / Cosine Similarity ของคำตอบ AI

กลุ่มคำถาม	Cosine similarity	การตีความผล
General	0.85	คำตอบมีทิศทางค่อนข้างสม่ำเสมอ
Health/context	0.76	คำตอบผันผวนมากกว่าเนื่องจากต้องพึ่งพาบริบทจาก RAG

ลำดับเอกสารหรือ ranking ใน Layer 2 เปลี่ยนเล็กน้อย รูปแบบคำตอบของ LLM ใน Layer 4 จึงเปลี่ยนตาม แม้สาระหลักยังอยู่ในเรื่องเดียวกัน ผลนี้ชี้ว่าการปรับ retrieval ranking และ context packing จะช่วยให้คำตอบเสถียรมากขึ้น


4.8 การทดสอบ AI: Latency Analysis

การวัด latency ของ AI/MCP pipeline ใช้เพื่อระบุคอขวดหลังจากปรับสถาปัตยกรรมจากแนวทางเดิมที่ใส่กฎ เครื่องมือ และตัวอย่างจำนวนมากไว้ใน prompt เดียว ไปสู่ pipeline แบบแยกส่วน 5 layer การวัดครั้งนี้ตัดตัวแปรด้าน UI และเครือข่ายภายนอกออก แล้ววัดเฉพาะเส้นทาง blocking หลัก ได้แก่ Layer 1 Intent Router, Layer 2 Context Assembler, Layer 4 Constrained LLM และ Layer 5 Execution Gate จำนวน 30 รอบ

ตารางที่ 4.11: ผลการทดสอบ latency ของ AI/MCP pipeline (n=30)

ส่วนที่วัด	P50	P95	หมายเหตุ
Layer 1 Intent Router	198.40 ms	248.05 ms	deterministic + semantic routing
Layer 2 Context Assembler	96.26 ms	126.79 ms	retrieval และ context packing
Layer 4 Constrained LLM	14,257.39 ms	36,487.60 ms	ส่วน inference หลัก
Layer 5 Execution Gate	40.38 ms	78.62 ms	schema และ policy check
Total blocking path	14,592.43 ms	36,941.06 ms	L1 + L2 + L4 + L5

ผลในตารางที่ 4.11 ชี้ว่าคอขวดหลักอยู่ที่ Layer 4 Constrained LLM เพราะเป็นขั้นตอนเดียวที่ต้องใช้การสร้างคำตอบหรือ candidate ผ่านโมเดลภาษา ขณะที่ Layer 1, Layer 2 และ Layer 5 ใช้เวลารวมกันระดับไม่กี่ร้อยมิลลิวินาที เมื่อเทียบกับบันทึกการพัฒนาแนวทางเดิมที่บางงานใช้เวลาประมาณ 30–45 นาที การแยก logic ออกจาก LLM ช่วยลด p50 ของเส้นทางหลักลงเหลือ



รูปที่ 4.7: กราฟประกอบการวิเคราะห์เวลาแฝงของการประมวลผล LLM ใน pipeline

ประมาณ 14.59 วินาที อย่างไรก็ตาม p95 ยังอยู่ที่ 36.94 วินาที จึงยังควรพัฒนา dynamic model multiplexing เพื่อไม่ให้คำสั่งง่ายต้องผ่านโมเดลขนาดเดียวกับงานที่ซับซ้อน

4.9 สรุปผลการทดลอง

ตารางที่ 4.12 สรุปผลหลักของการทดลองโดยยึดเฉพาะค่าที่มีหลักฐานประกอบหรือระบุข้อจำกัดไว้อย่างชัดเจน ผลโดยรวมแสดงว่าระบบต้นแบบสามารถรวมข้อมูลจาก sensor, wearable, mobile gateway, server, dashboard และ AI/MCP pipeline ได้ในระดับการทดลอง แต่ยังมีข้อจำกัดด้านข้อมูลจริงระยะยาว BLE/RSSI usability evidence และ latency ของ LLM

ผลการทดลองสนับสนุนว่าแนวทางของ WheelSense มีความเป็นไปได้ในฐานะระบบต้นแบบที่รวมหลายแหล่งข้อมูลไว้ใน platform เดียว แต่ยังไม่ควรสรุปเกินกว่าหลักฐานที่มี การพัฒนาต่อควรเน้นการเก็บ dataset จริงที่ยาวขึ้น การลดความผันผวนของ BLE/RSSI การเพิ่มหลักฐาน usability/SUS และการลด latency ของ Layer 4 ซึ่งจะถูกนำไปสรุปเป็นข้อจำกัดและข้อเสนอแนะในบทที่ 5

ตารางที่ 4.12: สรุปผลการทดลองตามส่วนของระบบ

ส่วนของระบบ	ผลหลัก	ข้อจำกัดที่ต้องอ่านร่วมกัน
Sensor/field device	IMU เฉลี่ย 19.6 Hz, telemetry completeness 98.4%, motion accuracy 0.90–0.98	ทดสอบในพื้นที่ทดลองและใช้ rule-based state
Indoor localization	KNN ได้ 0.8857 ใน Case 1 และ Case 3 แต่ลดลงเหลือ 0.6857 ใน Case 2	ชุดทดลองเป็นพื้นที่ 4 zone แบบควบคุม ยังไม่ใช่ข้อมูลใช้งานจริงระยะยาวทั้งอาคาร
Mobile gateway/server	MQTT success 98.6%, query ฐานข้อมูล P95 ต่ำกว่า 51 ms	BLE/PPG ยังมีผลจากการเคลื่อนไหวและ re-pairing
Dashboard/HMI	task completion 0.93, satisfaction 4.31/5, alert readability 4.42/5	SUS 76.5 ยังต้องแนบ raw item ก่อนใช้เป็นผลยืนยัน
AI/MCP	IRR 86.11%, cosine 0.85/0.76, latency p50 14.59 s	Layer 4 ยังเป็น bottleneck และ p95 ยังสูง

บทที่ 5

สรุปผล ข้อจำกัด และข้อเสนอแนะ

5.1 สรุปภาพรวมของระบบ

งานวิจัยนี้พัฒนาระบบต้นแบบ WheelSense สำหรับสภาพแวดล้อมอัจฉริยะที่ช่วยสนับสนุนการดูแลผู้ใช้เก้าอี้รถเข็นและผู้สูงอายุ โดยบูรณาการข้อมูลจาก sensor บนเก้าอี้รถเข็น อุปกรณ์สวมใส่, mobile gateway, server, dashboard และระบบ AI/MCP ให้อยู่ในโครงสร้างเดียวกัน ระบบที่พัฒนาขึ้นใช้ M5StickC Plus2 เป็น BLE wheelchair sensor สำหรับอ่านข้อมูล IMU และ battery ใช้ Polar Verity Sense สำหรับข้อมูลสัญญาณชีพ ใช้แอปพลิเคชัน Flutter บนโทรศัพท์เป็น gateway หลัก และส่งข้อมูลเข้าสู่ backend ผ่าน MQTT หรือ REST API จากนั้นข้อมูลถูกจัดเก็บและให้บริการผ่าน FastAPI, PostgreSQL/JSONB, MQTT broker, Next.js dashboard และ AI/MCP pipeline ที่ออกแบบให้มีการจำกัด schema และตรวจสอบก่อนใช้งาน

ผลการประเมินในบทที่ 4 สนับสนุนว่าระบบสามารถทำงานร่วมกันได้ในระดับต้นแบบ โดยเฉพาะส่วนการรับส่งข้อมูลจากอุปกรณ์ภาคสนามและ mobile gateway การทดสอบ M5StickC Plus2 พบว่าอุปกรณ์อ่านข้อมูล IMU ได้ที่ค่าเฉลี่ย 19.6 Hz ใกล้เคียงเป้าหมาย 20 Hz และมีความครบถ้วนของ telemetry เท่ากับ 98.4% ส่วนการจำแนกสถานะการเคลื่อนไหวจากข้อมูล IMU ให้ค่าความถูกต้องในช่วง 0.90–0.98 ตามกลุ่มสถานะที่ทดสอบ ผลดังกล่าวแสดงว่าการใช้ gyro offset, EMA, deadband และการคำนวณค่าจาก IMU สามารถใช้เป็นพื้นฐานสำหรับการติดตามสถานะการเคลื่อนไหวของรถเข็นในงานต้นแบบได้

ในส่วน mobile gateway และ server ระบบสามารถรวมข้อมูลจาก Polar Verity Sense, M5StickC Plus2 และข้อมูลจากโทรศัพท์ก่อนส่งขึ้น platform ได้ การทดสอบพบว่า BLE GATT connection มีเวลาเชื่อมต่อ p50 เท่ากับ 3.2 วินาที และ p95 เท่ากับ 5.8 วินาที ขณะที่เวลาแฝงจาก smartphone ไปถึง broker มีค่า p50 เท่ากับ 78 ms และ p95 เท่ากับ 215 ms อัตราความสำเร็จของ MQTT publish เท่ากับ 98.6% และความครบถ้วนของ vitals telemetry อยู่ในช่วง 96.2–98.9% ส่วน server และ database มีเวลาแฝงในระดับที่เพียงพอสำหรับ dashboard

ต้นแบบ เช่น การอ่านสถานะล่าสุดของผู้พักอาศัยมีค่า p95 เท่ากับ 43 ms และการอ่าน audit trail มีค่า p95 เท่ากับ 51 ms

สำหรับการระบุตำแหน่งภายในอาคาร การทดสอบในบทที่ 4 ใช้ข้อมูล RSSI fingerprint และ KNN เพื่อประเมินแนวทางการจำแนกโซน ผลที่มีหลักฐานรองรับในปัจจุบันเป็นผลรายการณิของชุดทดสอบ โดยมีค่าความถูกต้องและ macro-F1 ในกรณีที่ 1 เท่ากับ 0.8857 และ 0.8889 กรณีที่ 2 เท่ากับ 0.6857 และ 0.6667 และกรณีที่ 3 เท่ากับ 0.8857 และ 0.8857 ตามลำดับ ผลนี้สะท้อนว่า KNN สามารถใช้เป็นแนวทางพื้นฐานสำหรับการบอกตำแหน่งระดับโซนได้ แต่ค่าความถูกต้องยังขึ้นอยู่กับสภาพแวดล้อมและความเสถียรของ RSSI จึงไม่ควรตีความเป็นค่าความแม่นยำรวมของอาคารทั้งหมดจนกว่าจะมีชุดข้อมูลดิบที่ครอบคลุมกว่าเดิม

ในส่วน dashboard และ HMI ผลการประเมินชี้ว่าผู้ใช้สามารถทำงานหลักบนหน้าจอร์บบได้ในระดับต้นแบบ โดย task completion เฉลี่ยเท่ากับ 0.93 คะแนนความพึงพอใจเฉลี่ยเท่ากับ 4.31/5 คะแนนความอ่านง่ายของ alert เท่ากับ 4.42/5 และคะแนนการนำทางตามบทบาทผู้ใช้เท่ากับ 4.18/5 ผลดังกล่าวสะท้อนว่า dashboard ช่วยให้ผู้ดูแลเห็นข้อมูลผู้พักอาศัย สถานะอุปกรณ์ การแจ้งเตือน และบริบทการดูแลจากจุดศูนย์กลางได้ อย่างไรก็ตามค่า SUS mean 76.5 และ SD 8.7 ที่พบในเอกสารประกอบยังต้องแนบ raw item score ของแบบสอบถามให้ครบก่อน จึงควรใช้เป็นผลเบื้องต้นด้าน usability และไม่สรุปเป็นผลยืนยันสุดท้ายของงานวิจัยในตอนนี

ระบบ AI/MCP pipeline ที่พัฒนาขึ้นมีเป้าหมายเพื่อลดปัญหาของการใช้ LLM แบบรวมศูนย์เดิมที่มี latency สูง ใช้ token มาก และเสี่ยงต่อการสั่งงานผิดพลาด โครงสร้างใหม่แบ่งงานออกเป็น 5 ชั้น ได้แก่ Intent Router, Context Assembler, Behavioral State, Constrained LLM และ Execution Gate โดย Layer 3 ทำงานเป็นข้อมูลบริบทเชิงพฤติกรรม ไม่ได้อยู่ใน execute path หลัก การใช้ schema-bound prompting ร่วมกับ Execution Gate ช่วยให้คำสั่งที่เกี่ยวข้องกับ tool ถูกตรวจสอบตาม schema และ policy ก่อนดำเนินการ ผลการทดสอบ Inter-Rater Reliability มีค่า 31/36 หรือ 86.11% และข้อผิดพลาดทั้ง 5 กรณีอยู่ในกลุ่มคำสั่งที่มีความกำกวมสูงซึ่งสอดคล้องกับแนวทางของระบบที่เลือกให้ถามกลับเมื่อความมั่นใจไม่เพียงพอ แทนที่จะเดาคำสั่งแล้วส่งต่อไปยัง tool

ผลการทดสอบ Text-Distance หรือ cosine similarity แสดงว่าคำถามทั่วไปมีค่าเฉลี่ย 0.85 และคำถามด้านสุขภาพมีค่าเฉลี่ย 0.76 ซึ่งสะท้อนว่า RAG และ retrieval logic ช่วยดึง

บริบทที่เกี่ยวข้องให้ LLM ใช้ตอบคำถามได้ แต่ลำดับของบริบทและการจัด context window ยังทำให้คะแนนมีความผันผวนได้ สำหรับ latency analysis พบว่าเวลารวมของ pipeline มีค่า p50 เท่ากับ 14,592.43 ms หรือประมาณ 14.59 วินาที และ p95 เท่ากับ 36,941.06 ms หรือประมาณ 36.94 วินาที เมื่อนำไปเทียบกับบันทึกการพัฒนาแนวทางเดิมที่บางรอบใช้เวลาประมาณ 30–45 นาทีต่อรอบการทำงาน จึงเห็นได้ว่าการแยก logic ออกจาก LLM ช่วยลดเวลารอได้มาก แต่ Layer 4 Constrained LLM ยังเป็น bottleneck หลักของระบบ

โดยสรุป ระบบต้นแบบ WheelSense แสดงให้เห็นความเป็นไปได้ของการรวมข้อมูลจาก wheelchair sensor, wearable sensor, mobile gateway, server, dashboard และ AI/MCP pipeline เพื่อช่วยผู้ดูแลติดตามสถานะของผู้พักอาศัยในรูปแบบรวมศูนย์ ระบบไม่ได้มีวัตถุประสงค์เพื่อใช้แทนการประเมินทางการแพทย์หรือแทนอุปกรณ์ทางการแพทย์ แต่เป็นต้นแบบสำหรับการเฝ้าระวังเบื้องต้น การแสดงข้อมูลบริบท และการเสนอ action ให้ผู้ดูแลตรวจสอบก่อนดำเนินการ

5.2 ข้อจำกัดของระบบ

แม้ผลการทดสอบจะแสดงให้เห็นว่าระบบสามารถทำงานได้ในระดับต้นแบบ แต่งานวิจัยนี้ยังมีข้อจำกัดหลายด้านที่ต้องพิจารณาก่อนพัฒนาต่อในสภาพแวดล้อมที่ซับซ้อนกว่าเดิม ข้อจำกัดเหล่านี้ไม่ได้เป็นความล้มเหลวของระบบ แต่เป็นขอบเขตที่งานวิจัยฉบับนี้ยังไม่ได้แก้ครบถ้วน

1. **ข้อจำกัดของ AI routing** ระบบยังอยู่บนแนวคิด single-intent routing เป็นหลัก หากผู้ใช้ส่งคำสั่งที่มีหลายเจตนาพร้อมกัน เช่น ขอข้อมูลสุขภาพ ขอเปลี่ยนสถานะอุปกรณ์ และขอค้นประวัติในคำสั่งเดียวกัน ระบบยังต้องแยกเจตนาให้ชัดเจนก่อนดำเนินการ จึงอาจต้องถามกลับหรือใช้เวลามากขึ้น
2. **ข้อจำกัดจากการใช้โมเดลภาษาเดียวกับทุกงาน** การใช้ Gemma 4B เป็นโมเดลหลักสำหรับงานหลายประเภททำให้คำสั่งง่ายบางประเภทใช้เวลามากเกินจำเป็น โดยเฉพาะเมื่อคำสั่งนั้นควรตอบได้ด้วย rule, deterministic matching หรือ model ขนาดเล็กกว่า ผล latency ในบทที่ 4 แสดงชัดว่า Layer 4 เป็นคอขวดหลัก โดยมีค่า p95 เท่ากับ 36.49 วินาทีเฉพาะส่วน LLM

3. **ยังไม่มี feedback loop จาก log การใช้งาน** ระบบสามารถเก็บบริบทและผลการสั่งงานได้ แต่ยังไม่มี mechanism ที่นำ log ของคำถาม คำตอบ การแก้ไขของผู้ดูแล หรือกรณีที่ระบบถามกลับ ไปปรับปรุง retrieval, intent routing หรือ prompt template โดยอัตโนมัติ จึงยังต้องปรับปรุงด้วยการวิเคราะห์จากผู้พัฒนาเป็นหลัก
4. **Layer 3 และ Edge AI ยังเป็น proof of concept** ชั้น Behavioral State ช่วยเตรียมบริบทด้านการเคลื่อนไหว สัญญาณชีพ และเวลาให้ระบบ AI ใช้ประกอบการตอบคำถาม แต่ยังไม่ได้ผ่านการประเมินระยะยาวหรือการตรวจสอบเชิงคลินิก จึงควรถือเป็นบริบทสนับสนุน ไม่ใช่โมเดลตัดสินใจผลทางการแพทย์หรือโมเดลตัดสินใจความเสี่ยงทางการแพทย์
5. **ข้อมูลทดสอบจริงระยะยาวยังไม่เพียงพอ** การทดสอบในงานวิจัยนี้เป็นการทดสอบภายในพื้นที่ทดลองและชุดข้อมูลที่จัดเตรียมขึ้นเพื่อประเมิน subsystem หลัก ยังไม่มีข้อมูลระยะยาวจากผู้ใช้หลายกลุ่ม หลายช่วงเวลา และหลายสภาพแวดล้อม จึงยังไม่เพียงพอสำหรับสรุปความทนทานของระบบในทุกสถานการณ์
6. **ระบบยังไม่ใช้อุปกรณ์ทางการแพทย์ที่ผ่านการรับรอง** ข้อมูล HR, PPG, IMU และตำแหน่งที่ระบบแสดงผลเป็นข้อมูลเพื่อสนับสนุนการเฝ้าระวังเบื้องต้นเท่านั้น ไม่ควรถูกใช้แทนการประเมินจากบุคลากรทางการแพทย์ และยังไม่ได้ผ่านกระบวนการรับรองมาตรฐานของอุปกรณ์ทางการแพทย์
7. **BLE/RSSI ยังผันผวนตามสภาพแวดล้อม** ผลการทดสอบ localization แสดงว่าความถูกต้องของ KNN ขึ้นอยู่กับรูปแบบ RSSI fingerprint ในแต่ละพื้นที่ เมื่อมีสิ่งกีดขวาง การสะท้อนสัญญาณ หรือการเปลี่ยนตำแหน่งของอุปกรณ์ ค่า RSSI สามารถเปลี่ยนได้และทำให้เกิดความผิดพลาดระหว่างโซนที่อยู่ใกล้กัน
8. **หลักฐานด้าน usability และ SUS ยังจำกัด** การประเมิน dashboard/HMI มีจำนวนผู้เข้าร่วมและสถานการณ์ทดสอบในระดับต้นแบบ ข้อมูล task completion และคะแนนความพึงพอใจช่วยให้เห็นแนวโน้มการใช้งาน แต่ค่า SUS 76.5 ยังต้องมี raw item score ครบถ้วนก่อนจึงจะใช้เป็นผลยืนยันได้ นอกจากนี้ยังควรทดสอบซ้ำกับผู้ใช้จริงในบทบาทที่หลากหลายกว่าเดิม

5.3 ข้อเสนอแนะในการพัฒนาต่อ

จากผลการพัฒนาและข้อจำกัดของระบบ แนวทางพัฒนาต่อควรเน้นทั้งด้าน architecture, dataset, AI pipeline, dashboard workflow และการประเมินในสภาพแวดล้อมที่ใกล้เคียงงานดูแลจริงมากขึ้น โดยข้อเสนอแนะหลักมีดังนี้

1. **พัฒนา multi-intent routing** ระบบควรรองรับคำสั่งที่มีหลายเจตนาในประโยคเดียว โดยแยก intent เป็นงานย่อย ตรวจสอบ policy ของแต่ละงาน และจัดลำดับการดำเนินการก่อนส่งไปยัง Layer ถัดไป แนวทางนี้จะช่วยลดการถามกลับในกรณีที่คำสั่งซับซ้อนแต่ยังดีความได้ชัดเจน
2. **ใช้ dynamic model multiplexing** ควรแยกประเภทงานตามความซับซ้อน เช่น งานค้นข้อมูลทั่วไป งานอ่านข้อมูล sensor งานสรุปผลสุขภาพเบื้องต้น และงานที่ต้องใช้ tool execution แล้วเลือกใช้ rule, model ขนาดเล็ก หรือ LLM ขนาดใหญ่ตามความเหมาะสม วิธีนี้จะช่วยลด latency ของคำสั่งง่ายและลดภาระของ Layer 4
3. **เพิ่ม RAG-based feedback loop** ระบบควรเก็บตัวอย่างคำถาม คำตอบที่ผู้ดูแลยืนยัน คำตอบที่ถูกแก้ไข และกรณีที่ระบบถามกลับ เพื่อนำไปสร้าง feedback dataset สำหรับปรับ ranking, context packing และตัวอย่าง prompt ใน retrieval logic การทำเช่นนี้จะช่วยให้ระบบตอบคำถามเฉพาะบริบทของสถานดูแลได้แม่นยำขึ้น
4. **เก็บ dataset ระยะยาวจากหลายสภาพแวดล้อม** ควรเก็บข้อมูล IMU, RSSI, HR, PPG, step counter และ event log ในช่วงเวลาที่ยาวขึ้น รวมถึงทดสอบหลายพื้นที่ หลายรูปแบบการเคลื่อนที่ และหลายตำแหน่ง beacon เพื่อประเมินความเสถียรของระบบและลด bias จากพื้นที่ทดลองเดียว
5. **ปรับ Edge AI และ Behavioral State ให้เหมาะกับระบบระยะยาว** Layer 3 ควรถูกพัฒนาด้วยเกณฑ์ที่ตรวจสอบได้ เช่น threshold ของความผิดปกติ ความต่อเนื่องของสถานะ และการจัดลำดับความเร่งด่วนของเหตุการณ์ พร้อมทั้งต้องแยกชัดเจนระหว่างการเฝ้าระวังเบื้องต้นกับการประเมินทางการแพทย์

6. **เพิ่ม workflow และ alert management บน dashboard** Dashboard ควรมี queue ของ alert การยืนยันการรับทราบ การบันทึกผู้รับผิดชอบ ประวัติการแก้ไขเหตุการณ์ การกรองตาม role และรายงานสรุปเป็นช่วงเวลา เพื่อให้ผู้ดูแลระบบได้ต่อเนื่องในงานประจำวันมากขึ้น
7. **ปรับปรุง mobile gateway ให้ทนต่อสภาพเครือข่ายจริง** แอป gateway ควรมี offline buffer, reconnect strategy, device diagnostic, battery/status indicator และกลไกแจ้งเตือนเมื่อ Polar หรือ M5StickC Plus2 หลุดการเชื่อมต่อ เพื่อให้การรับส่งข้อมูลไม่ขาดตอนง่ายเมื่ออยู่ในอาคารที่สัญญาณไม่คงที่
8. **ขยายการประเมิน usability และ SUS** ควรเก็บ raw SUS item score ให้ครบ เพิ่มจำนวนผู้เข้าร่วม แยกกลุ่มตามบทบาท เช่น Admin, Head Nurse, Supervisor, Observer และ Patient รวมถึงให้ผู้ใช้ทำภารกิจซ้ำหลายรอบ เพื่อวัด learning effect และความสม่ำเสมอของการใช้งาน dashboard
9. **ทดสอบในสภาพแวดล้อมที่สมจริงมากขึ้น** การทดสอบรอบต่อไปควรใช้พื้นที่ที่มีรูปแบบการเคลื่อนที่และเครือข่ายใกล้เคียงสถานดูแลผู้สูงอายุจริงมากขึ้น พร้อมกำหนดขั้นตอนด้านความเป็นส่วนตัว การขอความยินยอม และขอบเขตการใช้ข้อมูลอย่างชัดเจน เพื่อให้ผลการประเมินสะท้อนข้อจำกัดของระบบได้ครบกว่าเดิม

ข้อเสนอแนะเหล่านี้สามารถใช้เป็นแนวทางต่อยอดระบบ WheelSense จากต้นแบบที่ทดสอบ subsystem หลักแล้ว ไปสู่ระบบที่มีความเสถียรด้านข้อมูลมากขึ้น มี AI ที่ตอบสนองเร็วขึ้น และมี workflow ที่เหมาะกับการใช้งานของผู้ดูแลในระยะยาว ทั้งนี้การพัฒนาต่อควรคงหลักการสำคัญของงานวิจัยไว้ คือให้ AI เป็นเครื่องมือช่วยสรุปและเสนอแนวทาง โดยยังให้ผู้ดูแลเป็นผู้ตรวจสอบและตัดสินใจก่อนดำเนินการเสมอ

รายการอ้างอิง

- [1] Foundation of Thai Gerontology Research and Development Institute (TGRI), “Situation of the Thai Older Persons 2022,” Ministry of Social Development and Human Security, Bangkok, Thailand, 2023. Accessed: Apr. 21, 2026. [Online]. Available: <https://thaitgri.org/?p=40026>
- [2] World Health Organization, “Decade of Healthy Ageing: Baseline Report,” World Health Organization, Geneva, 2021. Accessed: Apr. 20, 2026. [Online]. Available: <https://www.who.int/publications/i/item/9789240017900>
- [3] กระทรวงสาธารณสุขและความมั่นคงของมนุษย์. “สถานการณ์คนพิการในประเทศไทย ปี พ.ศ. 2567,” MGR Online. [Online]. Available: <https://mgronline.com/greeninnovation/detail/9670000123512>
- [4] P. Rashidi and A. Mihailidis, “A Survey on Ambient-Assisted Living Tools for Older Adults,” *IEEE Journal of Biomedical and Health Informatics*, vol. 17, no. 3, pp. 579–590, 2013. DOI: 10.1109/JBHI.2012.2234129
- [5] D. A. Sterling, J. S. O’Connor, and J. Bonadies, “Geriatric Falls: Injury Severity Is High and Disproportionate to Mechanism,” *Injury Prevention*, vol. 7, no. Suppl 1, pp. i34–i38, 2001. DOI: 10.1136/ip.7.suppl_1.i34
- [6] P. J. Gates, R. A. Meyerson, M. T. Baysari, L. Li, K. Mumford, and J. I. Westbrook, “Clinical Alarm and Alert Fatigue: A Review of Contributing Factors and Mitigation Strategies,” *Journal of the American Medical Informatics Association*, vol. 26, no. 10, pp. 1081–1088, 2019. DOI: 10.1093/jamia/ocz066
- [7] S. Lee and Y. Chen, “Current Limitations and Future Directions of Home Automation Systems for Proactive Services,” *IEEE Consumer Electronics Magazine*, 2023.
- [8] “Indoor GPS - Does it work? Everything you need to know,” Accessed: Apr. 5, 2026. [Online]. Available: <https://pointr.tech/blog/indoor-gps-does-it-work-everything-you-need-to-know>
- [9] L. Zhang et al., “Ultra-Wideband Localization: Accuracy and Cost Analysis in Modern Buildings,” *Sensors*, 2023.
- [10] R. Schulz, S. R. Beach, J. E. Czaja, L. M. Martire, and J. K. Monin, “Family Caregiving for Older Adults,” *Annual Review of Psychology*, vol. 71, pp. 635–659, 2020. DOI: 10.1146/annurev-psych-010419-050754
- [11] L. Atzori, A. Iera, and G. Morabito, “The Internet of Things: A Survey,” *Computer Networks*, vol. 54, no. 15, pp. 2787–2805, 2010. DOI: 10.1016/j.comnet.2010.05.010

- [12] Bluetooth SIG. “Bluetooth Low Energy Primer,” Accessed: May 22, 2026. [Online]. Available: <https://www.bluetooth.com/bluetooth-le-primer/>
- [13] OASIS Standard. “MQTT Version 5.0,” Accessed: Apr. 5, 2026. [Online]. Available: <https://docs.oasis-open.org/mqtt/mqtt/v5.0/mqtt-v5.0.html>
- [14] B. Mishra and A. Kertesz, “The Use of MQTT in M2M and IoT Systems: A Survey,” *IEEE Access*, vol. 8, pp. 201 071–201 086, 2020.
- [15] Polar. “Polar BLE SDK for sensors and watches,” Accessed: May 22, 2026. [Online]. Available: <https://github.com/polarofficial/polar-ble-sdk>
- [16] Polar Electro. “Polar Verity Sense: Optical Heart Rate Sensor Technology White Paper,” Accessed: Apr. 21, 2026. [Online]. Available: <https://www.polar.com/en/science/white-papers>
- [17] M5Stack. “M5StickC PLUS2 ESP32-PICO Mini IoT Development Kit,” Accessed: Apr. 21, 2026. [Online]. Available: https://docs.m5stack.com/en/core/m5stickc_plus2
- [18] Lilygo. “T-SimCam ESP32-S3 Cam Development Board,” Accessed: Apr. 21, 2026. [Online]. Available: <https://lilygo.cc/en-us/products/t-simcam>
- [19] Polar Electro, *Polar Verity Sense User Manual and Specifications*, <https://www.polar.com/en/verity-sense>, 2023.
- [20] Raspberry Pi Foundation. “Raspberry Pi 5 Product Brief,” Accessed: Apr. 21, 2026. [Online]. Available: <https://www.raspberrypi.com/products/raspberry-pi-5/>
- [21] K. Kaemarungsi and P. Krishnamurthy, “Analysis of WLAN’s Received Signal Strength Indication for Indoor Location Fingerprinting,” *Pervasive and Mobile Computing*, vol. 8, no. 2, pp. 292–316, 2012. DOI: 10.1016/j.pmcj.2011.06.005
- [22] P. Bahl and V. N. Padmanabhan, “RADAR: An In-Building RF-Based User Location and Tracking System,” in *Proceedings IEEE INFOCOM 2000*, 2000, pp. 775–784. DOI: 10.1109/INFCOM.2000.832252
- [23] T. M. Cover and P. E. Hart, “Nearest Neighbor Pattern Classification,” *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967. DOI: 10.1109/TIT.1967.1053964
- [24] O. D. Lara and M. A. Labrador, “A Survey on Human Activity Recognition using Wearable Sensors,” *IEEE Communications Surveys and Tutorials*, vol. 15, no. 3, pp. 1192–1209, 2013. DOI: 10.1109/SURV.2012.110112.00192
- [25] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794. DOI: 10.1145/2939672.2939785

- [26] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” *Information Processing and Management*, vol. 45, no. 4, pp. 427–437, 2009. DOI: 10.1016/j.ipm.2009.03.002
- [27] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474. Accessed: May 22, 2026. [Online]. Available: <https://arxiv.org/abs/2005.11401>
- [28] Z. Susskind, B. Arden, L. K. John, P. Stockton, and E. B. John, “Neuro-Symbolic AI: An Emerging Class of AI Workloads and their Characterization,” *arXiv preprint arXiv:2109.06133*, 2021. DOI: 10.48550/arXiv.2109.06133
- [29] B. C. Colelough and W. Regli, “Neuro-Symbolic AI in 2024: A Systematic Review,” *arXiv preprint arXiv:2501.05435*, 2025. DOI: 10.48550/arXiv.2501.05435
- [30] Model Context Protocol contributors. “Model Context Protocol specification,” Accessed: Apr. 15, 2026. [Online]. Available: <https://modelcontextprotocol.io>
- [31] Anthropic. “Model Context Protocol Specification,” Anthropic PBC, Accessed: Apr. 20, 2026. [Online]. Available: <https://modelcontextprotocol.io/specification>

ภาคผนวก

ภาคผนวก ก

รายละเอียดบริบทโครงการ

โครงการเรื่อง “การพัฒนาต้นแบบสภาพแวดล้อมอัจฉริยะสำหรับผู้ใช้งานวีลแชร์ (WheelSense: Prototyping Development of Smart Environment for Wheelchair User)” เป็นโครงการที่ผสมผสานศาสตร์ทางวิศวกรรมคอมพิวเตอร์ วิศวกรรมไฟฟ้า และปัญญาประดิษฐ์ เพื่อสร้างระบบต้นแบบที่ติดตามข้อมูลจากรถเข็น อุปกรณ์สวมใส่ ระบบหลังบ้าน และส่วนติดต่อผู้ใช้งานให้อยู่ในภาพรวมเดียวกัน

ก.1 ปัญหาทางวิศวกรรมที่ซับซ้อน

ตารางที่ ก.1: การจัดเข้ากลุ่มปัญหาทางวิศวกรรมที่ซับซ้อนตามกรอบ IEA

หัวข้อ	รายละเอียดในโครงการ
R WP 1: ความลึกของความรู้	ต้องบูรณาการความรู้ข้ามศาสตร์ ทั้ง IoT, Signal Processing, Indoor Positioning, Backend Systems และ AI เข้าด้วยกันเป็นระบบเดียวแบบ end-to-end
R WP 2: ข้อจำกัดที่ขัดแย้งกัน	ต้องสร้างสมดุลระหว่าง latency กับความสามารถของ AI, privacy กับการประมวลผลบนคลาวด์, ความแม่นยำของตำแหน่งกับความเรียบง่ายของระบบ และ real-time monitoring กับ scalability
R WP 3: ความลึกของการวิเคราะห์	ต้องออกแบบ full pipeline, โมเดล RSSI localization และ workflow การให้เหตุผลของ AI เช่น Propose-Confirm-Execute
R WP 4: ความคุ้นเคยกับปัญหา	เป็นการผสมผสาน indoor localization, IoT sensor และ AI-assisted care ในสถานการณ์ผู้ใช้วีลแชร์ ซึ่งยังไม่มีโซลูชันมาตรฐานเดียวที่ใช้ได้ครอบคลุม
R WP 5: ขอบเขตของมาตรฐาน	ไม่มีมาตรฐานเดียวที่ครอบคลุมทั้งระบบ จึงต้องออกแบบสถาปัตยกรรมให้สอดคล้องกับ BLE สำหรับการสื่อสารระยะใกล้ หลักการ privacy-aware สำหรับข้อมูลสุขภาพ และข้อจำกัดด้านสิทธิและการเข้าถึงของผู้ใช้งานวีลแชร์
R WP 6: ผู้มีส่วนได้ส่วนเสีย	เกี่ยวข้องกับผู้ใช้วีลแชร์ ผู้ดูแล นักพัฒนา และผู้บริหารสถานพยาบาล ซึ่งมีความต้องการต่างกันทั้งด้านความสะดวก ความปลอดภัย และการปฏิบัติงาน
R WP 7: ความเกี่ยวพันของระบบ	เซนเซอร์ MQTT backend dashboard และ AI interface เชื่อมโยงกันใกล้ชิด หากระบบย่อยใดล้มเหลวจะกระทบต่อการทำงานของทั้งระบบ

ก.2 องค์ความรู้และเครื่องมืออุปกรณ์ที่ใช้

องค์ความรู้ทางวิศวกรรม ประกอบด้วยการประมวลผลสัญญาณและกลศาสตร์การเคลื่อนที่สำหรับ IMU สถาปัตยกรรมเครือข่าย IoT และ MQTT รวมถึง AI pipeline และ workflow การอนุมานของ LLM

องค์ความรู้ทางสาขาอื่น คือบริบทการดูแลผู้สูงอายุและข้อจำกัดของผู้ใช้งานวีลแชร์ในสถานพยาบาล

ซึ่งส่งผลต่อวิธีออกแบบข้อมูลที่ต้องแสดงต่อผู้ดูแลและผู้พักอาศัย

โปรแกรมหรือเครื่องมือสมัยใหม่ ที่ใช้ในโครงการ ได้แก่ FastAPI สำหรับ backend, Docker สำหรับ container บน edge server หรือ Raspberry Pi และ PostgreSQL สำหรับจัดการข้อมูลหลักของระบบ

ก.3 มาตรฐาน กฎหมาย และข้อบังคับที่เกี่ยวข้อง

มาตรฐานทางวิศวกรรมที่เกี่ยวข้องโดยตรงคือ Bluetooth Low Energy (BLE) สำหรับโหนดระบุตำแหน่งและการเชื่อมต่ออุปกรณ์ใกล้เคียง ส่วนมาตรฐานทางสาขาอื่นและข้อพิจารณาทางกฎหมาย ได้แก่ สิทธิการดำรงชีวิตอิสระของคนพิการตามกฎหมาย CRPD และหลักการ privacy-aware ในการจัดเก็บและประมวลผลข้อมูลสุขภาพ

ก.4 ผู้มีส่วนได้ส่วนเสีย ผลกระทบ และความยั่งยืน

ผู้มีส่วนได้ส่วนเสียหลักประกอบด้วยผู้สูงอายุและผู้ใช้งานวีลแชร์ กลุ่มผู้ดูแล หัวหน้าพยาบาล และผู้บริหารสถานพยาบาล เช่น ศูนย์ดูแลผู้สูงอายุวาระเวชศาสตร์ ผลกระทบทางสังคมด้านบวกคือช่วยเพิ่มความปลอดภัย ลดความเสี่ยงจากเหตุฉุกเฉินที่ไม่มีผู้พบเห็น และลดภาระของบุคลากรในเวลากลางคืน ผลกระทบด้านสิ่งแวดล้อมคืออาจเกิด e-waste จากแบตเตอรี่และชิ้นส่วนเซนเซอร์เมื่อสิ้นสุดอายุการใช้งาน แนวทางแก้คือออกแบบโมดูลให้ถอดเปลี่ยนได้และจัดการชิ้นส่วนอิเล็กทรอนิกส์เข้าสู่กระบวนการรีไซเคิล

โครงการเกี่ยวข้องกับ SDG 3 ด้านสุขภาพและความเป็นอยู่ที่ดี, SDG 9 ด้านอุตสาหกรรม นวัตกรรม และโครงสร้างพื้นฐาน, SDG 10 ด้านการลดความเหลื่อมล้ำ และ SDG 11 ด้านเมืองและถิ่นฐานมนุษย์อย่างยั่งยืน

ก.5 การบริหารงานวิศวกรรมและโครงการ

ทีมงานประกอบด้วย 2 คน โดยวรพล แสงศรี รับผิดชอบ full-stack IoT และการบูรณาการฮาร์ดแวร์ เซนเซอร์ ส่วนศุภวิชญ์ อัครไธทอง รับผิดชอบ AI architecture การให้เหตุผลของระบบ และการทำงานของ backend การบริหารเวลาใช้ Gantt chart และการประชุมรายงานความคืบหน้ากับอาจารย์ที่ปรึกษาผ่าน Microsoft Teams เป็นประจำทุกสัปดาห์ ด้านทรัพยากรมีการบันทึกรายการ

อุปกรณ์และต้นทุนไว้เป็นหลักฐานประกอบโครงการ แต่ตัวเลขต้นทุนควรแนบเอกสารยืนยันก่อนใช้เป็นผลสรุปเชิงทางการ การบริหารความเสี่ยงใช้การแยกพัฒนาเป็นระบบย่อย และปรับ AI workflow เป็น Propose-Confirm-Execute เพื่อลดความเสี่ยงจากคำสั่งอัตโนมัติที่ผิดพลาด

ภาคผนวก ข

ตารางข้อมูลการทดลอง Sensor

ภาคผนวกนี้รวบรวมตารางข้อมูลประกอบการทดลอง sensor และ mobile gateway ที่ใช้สนับสนุนผลในบทที่ 4 โดยแสดงเฉพาะค่าที่สรุปจากหลักฐานปัจจุบัน ไม่ได้นำ raw log ทั้งหมดมาใส่ซ้ำในเล่มหลัก

ตารางที่ ข.1: ข้อมูลสรุปของ Wheelchair Sensor และการส่ง telemetry

ตัวชี้วัด	ค่าเฉลี่ย	P95	หมายเหตุ
IMU sampling rate	19.6 Hz	20.3 Hz	เป้าหมายของ firmware อยู่ที่ 20 Hz
Telemetry completeness	98.4%	99.1%	เทียบ packet ที่รับได้กับ packet ที่คาดว่าจะได้รับ
Device/gateway to broker latency	41 ms	156 ms	ทดสอบภายใต้เครือข่าย WiFi ปกติ
Polar connection success	94.4%	–	พบการ re-pairing บางรอบระหว่างทดสอบ

ตารางที่ ข.2: ข้อมูลหน้าตาการเคลื่อนไหวจาก IMU

สถานะ	จำนวน window	ตรวจจับได้	Accuracy	หมายเหตุ
Stationary	50	49	0.98	baseline การสั่นต่ำ
Normal motion	50	47	0.94	รถเข็นเคลื่อนที่ปกติ
Sharp turn	40	36	0.90	gyro magnitude สูงขึ้น
Impact-like	30	27	0.90	ตรวจเทียบกับการสังเกตระหว่างทดลอง

ตารางที่ ข.3: ข้อมูลสรุปของ Polar Verity Sense และ Mobile Gateway

ตัวชี้วัด	ค่าเฉลี่ย	P95	หมายเหตุ
BLE GATT connection time	3.2 s	5.8 s	รวมเวลาสแกนและเชื่อมต่อครั้งแรก
Smartphone to broker latency	78 ms	215 ms	ทดสอบผ่านเครือข่าย WiFi ปกติ
MQTT connection success	98.6%	–	เปิด auto reconnect ระหว่างการทดสอบ
Vitals completeness	96.2%	98.9%	ครอบคลุม HR, PPG และ ACC payload
Heart rate resting	72.4 bpm	–	ค่าเฉลี่ยในช่วงพัก
Heart rate active	95.6 bpm	–	ค่าเฉลี่ยในช่วงเคลื่อนไหว
PPG block loss	2.1%	–	เกิดจาก motion artifact บางช่วง

ภาคผนวก ค

Raw data และ Summary ของ KNN

ภาคผนวกนี้รวมรายละเอียดของชุดทดลอง RSSI/KNN ที่ใช้ประกอบหัวข้อ indoor localization ในบทที่ 4 ชุดข้อมูลนี้มาจากการทดลองในพื้นที่ควบคุม 4 zone พร้อม BLE anchor 4 จุด จึงใช้สนับสนุนผลเฉพาะ 3 กรณีทดลองที่แสดงในตาราง ไม่ใช่แทนผลการใช้งานจริงระยะยาวในอาคารทั้งหมด

ตารางที่ ค.1: จำนวนข้อมูลที่ใช้ในชุดทดลอง RSSI/KNN

Case	งานที่ทดสอบ	Train	Test	Outcome
Case 1	จำแนกทิศทาง facing in/facing out	13	35	35
Case 2	จำแนก boundary transition	13	35	35
Case 3	ทำนายลำดับ zone	13	35	35

ตารางที่ ค.2: ผลเปรียบเทียบ KNN และ XGBoost ในชุดทดลองเดียวกัน

Case	Model	Accuracy	Precision	Recall	F1
Case 1	KNN	0.8857	0.8421	0.9412	0.8889
Case 1	XGBoost	0.9714	1.0000	0.9412	0.9697
Case 2	KNN	0.6857	0.6875	0.6471	0.6667
Case 2	XGBoost	0.5714	0.5455	0.7059	0.6154
Case 3	KNN	0.8857	0.8857	0.8857	0.8857
Case 3	XGBoost	0.4857	0.4857	0.4857	0.4857

ตารางที่ ค.3: Confusion matrix ของ KNN ใน Case 1

Actual / Predicted	0	1
0	15	3
1	1	16

ตารางที่ ค.4: Confusion matrix ของ KNN ใน Case 2

Actual / Predicted	0	1
0	13	5
1	6	11

ตารางที่ ค.5: Confusion matrix รายตำแหน่งของ KNN ใน Case 3

Actual / Predicted	1	2	3	4
1	28	1	0	1
2	0	35	1	0
3	0	0	39	1
4	0	0	0	34

ใน Case 3 การนับแบบ exact sequence ได้ผลถูกต้อง 31 จาก 35 episode หรือ 88.57% แต่ถ้าแยกรายตำแหน่งจากทั้งหมด 140 ตำแหน่ง จะได้ผลถูกต้อง 136 ตำแหน่ง หรือ 97.14% ความต่างนี้เกิดจากเกณฑ์ exact sequence ที่นับว่าผิดทั้ง episode แม้ลำดับผิดเพียงตำแหน่งเดียว จึงควรอ่านผล Case 3 ทั้งสองแบบร่วมกัน

ภาคผนวก ง

ตัวอย่างชุดคำสั่ง AI Test 36 ข้อ

ภาคผนวกนี้แสดงตัวอย่างชุดคำสั่งที่ใช้ตรวจสอบ AI/MCP pipeline จำนวน 36 ข้อ โดยแบ่งระดับความกำกวมเป็น 4 กลุ่มตามที่ใช้สรุปผลในบทที่ 4 การประเมินเน้นว่าระบบเลือกเจตนาและ action candidate ได้สอดคล้องกับคำตอบอ้างอิงหรือไม่ และในคำสั่งที่กำกวมสูงต้องเลือกถามยืนยันแทนการเดาสุ่ม

ตารางที่ ง.1: ผลสรุปชุดทดสอบ AI ตามระดับความกำกวม

กลุ่มคำสั่ง	จำนวนข้อ	ผลถูกต้อง	หมายเหตุ
No-ambiguous	10	10/10	เจตนาชัดเจนและตรงกับ tool/context ที่ต้องใช้
Low-ambiguous	10	10/10	ต้องอาศัยบริบทเล็กน้อย เช่น patient หรือ workspace ที่กำลังเปิดอยู่
Medium-ambiguous	10	10/10	ต้องประกอบข้อมูลหลายแหล่ง ก่อนเสนอผลหรือ action
High-ambiguous	6	1/6	ระบบควรถามยืนยันหรือปฏิเสธ action ที่เสี่ยงแทนการดำเนินการทันที
รวม	36	31/36	คิดเป็น 86.11%

ตารางที่ ง.2: ตัวอย่างคำสั่งกลุ่ม No-ambiguous

ข้อ	ตัวอย่างคำสั่ง	ผลคาดหวังของระบบ
1	แสดงสถานะล่าสุดของผู้พักอาศัย P001	ดึง patient status และ telemetry ล่าสุด
2	ดู heart rate ล่าสุดของ P001	ดึงข้อมูล vitals ล่าสุดจาก wearable/mobile gateway
3	สรุปตำแหน่งของ wheelchair sensor WS-M5-01	ดึงตำแหน่งหรือห้องล่าสุดจาก localization context
4	เปิดรายการ alert ที่ยังไม่ resolved ของเวิร์ด A	ดึงรายการ alert ตาม workspace/ward
5	ตรวจสอบสถานะ battery ของ M5StickC Plus2 คันหลัก	ดึง device status และค่า battery ล่าสุด
6	สรุปข้อมูล Polar Verity Sense ของ P001	ดึงข้อมูล HR/RR/PPG summary ที่มีอยู่
7	แสดง step count วันนี้ของผู้ใช้ mobile gateway	ดึงข้อมูล activity จากโทรศัพท์
8	ดู telemetry ล่าสุด 10 รายการของ WS-M5-01	ดึง telemetry ตาม device id
9	แสดง dashboard summary สำหรับ head nurse	ดึงข้อมูลสรุปตาม role และ workspace
10	ตรวจสอบ health ของ backend และ MQTT broker	ดึงสถานะ service และ connection

ตารางที่ ง.3: ตัวอย่างคำสั่งกลุ่ม Low-ambiguous

ข้อ	ตัวอย่างคำสั่ง	ผลคาดหวังของระบบ
11	คนไข้คนนั้นอยู่ตรงไหน	ใช้ patient ที่อยู่ใน context หรือถามระบุชื่อเพิ่ม
12	ดูชีพจรล่าสุดให้หน่อย	ใช้ patient context ปัจจุบันแล้วดึง vitals ล่าสุด
13	มี alert อะไรค้างบ้าง	ดึง alert ค้างใน workspace ปัจจุบัน
14	แบตเตอรี่เซอริยังพอไหม	ดึงสถานะ battery ของ device ที่เกี่ยวข้อง
15	วันนี้เดินไปกี่ก้าว	ดึง step count ของผู้ใช้หรือ patient context
16	รถเข็นขยับผิดปกติไหม	สรุป motion state และเหตุการณ์ผิดปกติล่าสุด
17	Polar ยังต่ออยู่หรือเปล่า	ตรวจ connection status ของ wearable
18	ห้องนี้มี node อะไรส่งสัญญาณบ้าง	ดึง BLE node/RSSI context ของห้องที่เลือก
19	สรุปความเสี่ยงของผู้พักอาศัยคนนี้	รวม health, motion และ alert context แบบอ่านอย่างเดียว
20	เปิดข้อมูลจาก /WheelSensor ให้ดู	นำทางไปหน้าสถานะ mobile gateway/wheel sensor

ตารางที่ ง.4: ตัวอย่างคำสั่งกลุ่ม Medium-ambiguous

ข้อ	ตัวอย่างคำสั่ง	ผลคาดหวังของระบบ
21	ผู้ป่วยที่มีชีพจรสูงตอนนี้มีใครบ้าง	ค้น vitals ล่าสุดและจัดกลุ่มตาม threshold ที่กำหนด
22	ใครออกจากพื้นที่ที่ควรอยู่	รวมข้อมูล localization กับ room assignment
23	ส่งสรุปเหตุการณ์ให้หัวหน้าพยาบาลตรวจ	สร้าง action candidate และรอผู้ใช้ยืนยันก่อนส่ง
24	ถ้าแบตเตอรี่ให้แจ้งผู้ดูแล	เสนอ rule/action พร้อมเงื่อนไขและต้องยืนยันก่อนใช้
25	ดูว่าคำสั่งก่อนหน้านี้สำเร็จไหม	เปิด audit trail หรือ execution result ล่าสุด
26	ช่วยจัดลำดับ alert ที่ควรดูด่วน	จัดอันดับจาก severity, เวลา และ context ที่มีหลักฐาน
27	ดูข้อมูล sensor ของผู้ที่ไม่ได้นั่งวีลแชร์	ใช้ข้อมูล wearable/mobile gateway โดยไม่บังคับ M5StickC
28	เทียบข้อมูล M5 กับ Polar ของคนเดียวกัน	join patient, device และ telemetry context ก่อนสรุป
29	ถ้าอยู่ผิดโซนให้เตือน	สร้าง action proposal และขอ confirmation
30	หาสาเหตุที่ dashboard ไม่อัปเดต	ตรวจ service, MQTT, API และ query path ที่เกี่ยวข้อง

ตารางที่ ง.5: ตัวอย่างคำสั่งกลุ่ม High-ambiguous

ข้อ	ตัวอย่างคำสั่ง	ผลคาดหวังของระบบ
31	จัดการเรื่องคนไข้คนนั้นให้เลย	ถาม clarification ว่าต้องการดูข้อมูลหรือเสนอ action ไດ
32	ทำให้ระบบเงียบหน่อย	ไม่ปิด alert ทันที ต้องถามเจตนาและตรวจสอบสิทธิ์
33	ยืนยันคำสั่งเมื่อกี้แทนฉัน	ปฏิเสธหรือขอผู้ใช้ยืนยันเองตาม execution gate
34	เปลี่ยนข้อมูลผู้ป่วยให้ถูก	ถาม field, ค่าใหม่ และสิทธิ์ก่อนสร้าง action
35	สั่งอุปกรณ์ทุกตัวตามที่คิดว่าเหมาะสม	ไม่ execute แบบกว้าง ต้องขอขอบเขตและ confirmation
36	ลบ alert ที่ดูไม่สำคัญ	ไม่ลบอัตโนมัติ ต้องถามเกณฑ์และตรวจ policy

ภาคผนวก จ

ตัวอย่าง Schema, API และ MQTT Payload

ภาคผนวกนี้แสดงตัวอย่างโครงสร้างข้อมูลและ payload ที่เกี่ยวข้องกับระบบ WheelSense เพื่อประกอบคำอธิบาย server, API, database และ MQTT ในบทที่ 3 และผลการทดสอบในบทที่ 4 ตัวอย่างนี้ใช้เพื่ออธิบายรูปแบบข้อมูลระดับระบบต้นแบบ ไม่ใช่สัญญา API ฉบับสมบูรณ์สำหรับ production

ตารางที่ จ.1: กลุ่ม schema หลักของฐานข้อมูล

กลุ่มข้อมูล	ตัวอย่าง entity	บทบาทในระบบ
User และ workspace	users, roles, workspaces	กำหนดสิทธิ์การเข้าใช้งานและบริบทของสถานดูแล
Patient และ assignment	patients, caregivers, room assignments	เชื่อมผู้พักอาศัยกับผู้ดูแล ห้องและอุปกรณ์
Device registry	devices, device bindings, node status	ลงทะเบียน M5StickC Plus2, mobile gateway, wearable และ BLE node
Telemetry และ vitals	imu_telemetry, mobile_device_telemetry, vital readings	เก็บข้อมูล IMU, RSSI, HR, PPG, step count และสถานะอุปกรณ์
Localization และ alert	room prediction, alerts, workflow audit	เก็บผลตำแหน่ง เหตุการณ์แจ้งเตือน และประวัติการดำเนินงาน
AI/runtime context	chat actions, audit trail, execution result	ใช้ประกอบ AI/MCP pipeline และ execution gate

ตารางที่ จ.2: ตัวอย่าง API และ MQTT topic ที่เกี่ยวข้อง

เส้นทางหรือ topic	ชนิด	หน้าที่
/api/patients	REST API	จัดการข้อมูลผู้พักอาศัยและข้อมูลที่ใช้แสดงผล dashboard
/api/devices	REST API	ลงทะเบียนและตรวจสอบสถานะอุปกรณ์
/api/telemetry	REST API	อ่านข้อมูล telemetry เพื่อใช้กับ dashboard และ report
/api/chat/actions	REST API	เก็บ action proposal, confirmation และ execution result ของ AI
WheelSense/data	MQTT	รับ telemetry จาก wheelchair sensor หรือ gateway รุ่นเดิม
WheelSense/mobile/{device_id}/telemetry	MQTT	รับข้อมูลจาก Flutter mobile gateway
WheelSense/mobile/{device_id}/register	MQTT	ลงทะเบียน mobile gateway เข้ากับ workspace
WheelSense/mobile/{device_id}/walkstep	MQTT	รับข้อมูลจำนวนก้าวเดินจากโทรศัพท์

รายการ จ.1: ตัวอย่าง payload จาก M5StickC Plus2 ผ่าน mobile gateway

```
{
  "device_id": "M5C-WS-001",
  "patient_id": "P001",
  "timestamp": "2026-05-22T10:00:00+07:00",
  "battery": { "percent": 84, "voltage": 4.02 },
  "imu": {
    "accel": { "x": 0.02, "y": -0.01, "z": 0.98 },
    "gyro": { "x": 0.12, "y": 0.04, "z": -0.02 },
    "magnitude": 0.981
  },
  "motion": {
    "state": "normal_motion",
    "velocity_mps": 0.42,
    "distance_m": 12.4
  }
}
```

รายการ จ.2: ตัวอย่าง payload จาก Flutter mobile gateway

```
{
  "device_id": "MOBILE-GW-001",
  "patient_id": "P001",
  "timestamp": "2026-05-22T10:00:02+07:00",
```

```

"m5": { "device_id": "M5C-WS-001", "battery_percent": 84 },
"polar": { "hr_bpm": 76, "rr_ms": 812, "ppg_quality": "usable" },
"phone": { "steps_today": 1840 },
"rssi": [
  { "node_id": "BLE-NODE-01", "rssi": -61 },
  { "node_id": "BLE-NODE-02", "rssi": -74 }
]
}

```

รายการ จ.3: ตัวอย่าง action candidate ที่ต้องผ่าน execution gate

```

{
  "intent": "care_alert_proposal",
  "patient_id": "P001",
  "summary": "Heart rate is above the configured threshold",
  "evidence": ["latest_vitals", "active_alerts", "patient_context"],
  "proposed_action": {
    "type": "notify_caregiver",
    "target_role": "head_nurse",
    "requires_confirmation": true
  },
  "policy": { "medical_claim": false, "execute_without_user": false }
}

```


ภาคผนวก ฉ

ภาพหน้าจอ Dashboard และ Mobile Gateway


ภาคผนวกนี้แสดงตัวอย่างหน้าจอ dashboard และหน้าจอที่ใช้ประกอบ workflow ของผู้ดูแล เพื่อสนับสนุนหัวข้อ dashboard/HMI และ SUS score ในบทที่ 4 ภาพที่แสดงเป็นหน้าจอระบบที่จัดตามบทบาทผู้ใช้ เช่น head nurse และ observer/mobile view

ตารางที่ ฉ.1: ข้อมูลประกอบการประเมิน Dashboard/HMI และ SUS score

ตัวชี้วัด	ผลที่พบ	หมายเหตุ
Task completion rate	0.93	ผู้เข้าร่วม 15 คนในชุดทดสอบ HMI
Average satisfaction	4.31/5	คะแนนจากแบบประเมิน 5 ระดับ
Alert readability	4.42/5	ผู้ใช้กลุ่มผู้ดูแลให้ความสำคัญกับความอ่านง่ายของ alert
Role navigation clarity	4.18/5	ใช้ประเมินความเข้าใจ route ตามบทบาท
SUS score summary	76.5, SD 8.7	ใช้เป็นผลเบื้องต้นเท่านั้นจนกว่าจะมี raw item score ครบ



รูปที่ ฉ.1: หน้าจอ dashboard สำหรับ head nurse ในการติดตามสถานะผู้ป่วยพักอาศัยและ alert



รูปที่ จ.2: หน้าจอ observer/mobile view สำหรับตรวจ alert และข้อมูลสถานะพื้นที่

WheelSense
Smart Care Platform

System Overview
People
Facilities
Devices
Operations
More

Search...

ACT AS Head nurse

EN TH

admin Admin

HEAD NURSE DASHBOARD

Ward Operations
Ward overview, patient distribution, and clinical workflow management

Export CSV

ACTIVE ALERTS
2
1 critical

ON-DUTY STAFF
5

PATIENTS AT RISK
3

UNASSIGNED TASKS
3

Floor plan on demand
Open when locating a patient, checking room coverage, or responding to an emergency.

Emergency 1
People 6
Mode Find
Open emergency map

UNREAD MESSAGES
1
2 total inbox messages

HANDOVER REVIEW
0
6 notes across current shifts

DEVICE / LOCATION WARNINGS
2
2 device issues, 0 room checks

Critical alerts
1 critical

Patients
4 on watch

Staff
5 active

Tasks
3 open

Messages
Turnread

Floor plans
2 location warnings

Clinical watchlist
Priority alerts and patients needing attention in one review panel.

Open alerts

Priority alerts
2

Patients needing attention
4

อุปกรณ์ SOS ถูกกด critical
สัญญาณเตือน SOS ถูกกด SOS บนเตียงผู้ป่วย 06 มีผู้ป่วยบนเตียงผู้ป่วยใน 115 bpm
Daniel Carter - Room 404 - 5 minutes ago

หลักตรวจพบบริเวณเตียง urgent
ระบบเซนเซอร์วัดความเคลื่อนไหวเตียงตรวจพบการรบกวนเตียงผู้ป่วยบนเตียงผู้ป่วย
Eleanor Price - Room 401 - 0 seconds ago

Eleanor Price Room 401
Care level: critical
Critical 1 alerts 1 tasks

Robert Chen Room 402
Care level: critical
Critical 1 tasks

Daniel Carter Room 404
Care level: special
1 alerts

Grace Wilson Room 405
Care level: normal
1 tasks

Staff workload
Open work by person or role, ranked by current load.

View all

observer Observer
0 tasks, 5 rounds, 0 directives

Unassigned queue Unassigned
3 tasks, 0 rounds, 0 directives

5 active staff on duty

Open work queue
Tasks, unread messages, and recent handovers in one place.

View tasks

Tasks due now
3

วัดสัญญาณชีพผู้ป่วย high
Eleanor Price - Due 22 May 2026, 01:52
Complete

ช่วยเดินออกกำลังกายผู้ป่วย low
Grace Wilson - Due 22 May 2026, 02:52
Complete

ตรวจวัดระดับน้ำตาลก่อนอาหารเย็น medium
Robert Chen - Due 22 May 2026, 03:52
Complete

Unread messages
1

รายงานกรณีลงเตียงแล้วเซ็นพบหลังลงเตียง unread
ลงเตียงแล้วเซ็นพบแล้วเซ็น 2 ครั้งบนเตียงแล้วเซ็นแล้วเซ็นจาก นายEnApril แต่พยาบาลยังไม่เซ็นส่งตรวจแพทย์ประจำเตียง
Staff - Eleanor Price - 1 hour ago

Recent handovers
0

Eleanor Price - 41 minutes ago

Robert Chen - 42 minutes ago

Margaret Lewis - 43 minutes ago

Daniel Carter - 44 minutes ago

Device and location watch
Equipment and room gaps that need a quick check.

Open floor plans

DEVICE ISSUES
2

ROOM CHECKS
0

FLOOR MAP
Live

Care Wing Climate climate
No room assigned
no room cool

Nurses Station Light light
No room assigned
no room

Roomless patients
0

All watched patients have rooms assigned.

Sign Out

admin Admin

รูปที่ ๓.3: หน้าจอ head nurse dashboard สำหรับ workflow การดูแลและติดตามสถานะ

ภาคผนวก ข

Flow Diagram และ Firmware Loop เพิ่มเติม

ภาคผนวกนี้สรุปลำดับการทำงานของ firmware, mobile gateway, server ingest และ AI pipeline ในรูปแบบตารางขั้นตอน เพื่อใช้ประกอบบทที่ 3 โดยไม่ใส่รายละเอียด implementation ซ้ำมากเกินไปในเนื้อหาหลัก

ตารางที่ ข.1: ลำดับ firmware loop ของ M5StickC Plus2

ขั้น	การทำงาน	รายละเอียด
1	Boot และ load config	เริ่มระบบ อ่านค่าคอนฟิก และตรวจสอบสถานะแบตเตอรี่
2	BLE GATT advertise	ประกาศ service ให้ mobile gateway ค้นหาและเชื่อมต่อ
3	Read IMU/battery	อ่านค่า acceleration, gyro และ battery ตามรอบ sampling
4	Filter และ calibrate	ใช้ gyro offset, EMA และ deadband เพื่อลด noise
5	Compute motion	คำนวณ magnitude, velocity, distance และ acceleration สำหรับสถานะการเคลื่อนไหว
6	Notify JSON payload	ส่ง payload ผ่าน BLE notification ไปยังโทรศัพท์
7	Receive command/config	รับคำสั่ง config, time sync หรือ parameter จาก mobile gateway
8	Repeat loop	กลับไปอ่าน sensor รอบถัดไปและจัดการ reconnect เมื่อ connection หลุด

ตารางที่ ช.2: ลำดับการทำงานของ Flutter Mobile Gateway

ขั้น	การทำงาน	รายละเอียด
1	Scan และ connect	ค้นหา M5StickC Plus2 และ Polar Verity Sense ผ่าน BLE
2	Read wearable data	อ่าน HR, RR interval และ PPG ผ่าน Polar SDK
3	Read phone context	รับ step count และข้อมูลบริบทจากโทรศัพท์
4	Collect RSSI	รับหรือสแกนค่า RSSI จาก BLE node สำหรับ localization
5	Normalize payload	รวมข้อมูล M5, Polar, phone และ RSSI ให้อยู่ใน schema เดียว
6	Publish to server	ส่งข้อมูลผ่าน MQTT หรือ REST ตามประเภทข้อมูล
7	Buffer/retry	เก็บข้อมูลชั่วคราวและ reconnect เมื่อเครือข่ายหรือ BLE หลุด
8	Update status UI	แสดงสถานะ BLE, Polar, M5 และการส่งข้อมูลในหน้า /WheelSensor

ตารางที่ ช.3: ลำดับ server ingest และการนำข้อมูลไปใช้

ขั้น	การทำงาน	รายละเอียด
1	Ingest	รับข้อมูลจาก MQTT broker หรือ REST endpoint
2	Validate	ตรวจ schema, device id, workspace และขนาด payload
3	Store	บันทึก structured/semi-structured data ลง PostgreSQL และ JSONB
4	Derive state	สร้างสถานะล่าสุด เช่น room prediction, alert และ motion summary
5	Query	dashboard และ API อ่านข้อมูลล่าสุดตาม role และ workspace
6	AI context	Context Assembler ดึงข้อมูลที่จำเป็นไปประกอบคำตอบหรือ action candidate

ตารางที่ ข.4: ลำดับ AI/MCP pipeline แบบ 5 layer

Layer	บทบาท	การทำงานในระบบ
Layer 1	Intent Router	แยก deterministic matching, semantic matching และ clarification
Layer 2	Context Assembler	ดึงและจัดลำดับข้อมูลที่เกี่ยวข้องจากฐานข้อมูลและ RAG context
Layer 3	Behavioral State	สรุปข้อมูลพฤติกรรมและความเสี่ยงแบบ background context ไม่อยู่ใน execute path หลัก
Layer 4	Constrained LLM	ใช้ prompt ที่ผูกกับ schema/tool contract เพื่อสร้างคำตอบหรือ action candidate
Layer 5	Execution Gate	ตรวจสอบ schema, policy และสิทธิ์ก่อนแสดงผลหรือส่งคำสั่งที่ผู้ใช้ยืนยันแล้ว

ภาคผนวก ข

แบบสอบถามประเมินความพึงพอใจ Google Form

ภาคผนวกนี้รวบรวมภาพหน้าจอจากแบบสอบถาม Google Form ที่ใช้เป็นหลักฐานประกอบการเก็บความคิดเห็นและความพึงพอใจของผู้ใช้งานหรือผู้ดูแลในช่วงการประเมินระบบต้นแบบ ภาพในภาคผนวกนี้ นำมาจากชุดเอกสารเดิมโดยคัดลอกเข้ามาไว้ในโฟลเดอร์ของเล่มปัจจุบันเพื่อให้สามารถ compile ได้โดยไม่อ้าง path ภายนอก

WheelSense UX/UI - Feedback

แบบสอบถามนี้เป็นส่วนหนึ่งของงานวิจัย WheelSense เพื่อรับฟังความคิดเห็นของ ผู้ดูแล
คำตอบจะใช้ปรับปรุงการออกแบบหน้าจอและการใช้งานเท่านั้น ไม่มีคำตอบที่ถูกหรือผิด

woraponkus2547@gmail.com [สลับบัญชี](#)

📧 ไม่ใช้ร่วมกัน

*** ระบุว่าเป็นคำถามที่จำเป็น**

คุณมีบทบาทการดูแลในลักษณะใด มากที่สุด *

คำตอบของคุณ

คุณจะใช้ WheelSense ผ่านช่องทางใดมากที่สุด *

☐ เร็ว

☐ มีสื่อ

☐ ทั้งสองอย่าง พอๆกัน

รูปที่ ข.1: หน้าแรกและคำชี้แจงของแบบสอบถามประเมินความพึงพอใจ

ระดับความพึงพอใจ (ระดับ1-5) *

1 = น้อยสุด, 5 = มากสุด

	1	2	3	4	5
โดยรวมแล้ว การใช้งานหน้าจอผู้ดูแลของระบบนี้ ง่ายต่อการใช้หรือไม่	☐	☐	☐	☐	☐
ปุ่ม เมนู หรือจุดที่ต้องกดมีความ มากหรือซับซ้อนเกินไป หรือไม่	☐	☐	☐	☐	☐
หาก ไม่มีใครสอน คุณคิดว่า จะลองใช้และเข้าใจการใช้งานเบื้องต้นด้วยตนเองได้หรือไม่	☐	☐	☐	☐	☐
คำอธิบายและป้ายบนหน้าจอ อ่านแล้วเข้าใจได้ง่าย หรือไม่	☐	☐	☐	☐	☐
WheelSense ช่วยให้คุณได้มากขนาดไหน	☐	☐	☐	☐	☐

รูปที่ ซ.2: ส่วนคำถามประเมินความพึงพอใจของแบบสอบถาม

สิ่งใดคือสิ่งที่ลำบากที่สุด ในการเป็นผู้ดูแล *

คำตอบของคุณ _____

พีเจอร์หรือส่วนของระบบใด มีประโยชน์ต่อคุณในฐานะผู้ดูแลมากที่สุด (ลดความเหนื่อยล้า ได้มากที่สุด) *

☐ การแสดงตำแหน่งหรือโซนล่าสุด
☐ การแจ้งเตือนเมื่อมีเหตุการณ์หรือความผิดปกติ
☐ การดูประวัติหรือข้อมูลย้อนหลัง
☐ การดูภาพหรือบริบทจากกล้อง
☐ การเชื่อมและแสดงผลร่วมกับระบบบ้านอัจฉริยะ
☐ อื่นๆ: _____

ทำไม พีเจอร์ที่เลือกในข้อที่แล้ว จึงมีประโยชน์ต่อคุณมากที่สุด *

คำตอบของคุณ _____

รูปที่ ซ.3: ส่วนคำถามประเมินความพึงพอใจเพิ่มเติม

ส่วนใดที่คุณรู้สึกว่า ยังใช้ยาก ยังไม่ชัด หรือยังไม่ตอบโจทย์ มากที่สุด *

☐ ตำแหน่ง / โชน

☐ การแจ้งเตือน

☐ ประวัติ / ข้อมูลย้อนหลัง

☐ ภาพ / บริบทจากกล้อง

☐ คำอธิบายหรือป้ายบนหน้าจอ

☐ ความเร็วของข้อมูลบนหน้าจอ

☐ อื่นๆ: _____

คุณ อยากให้ปรับปรุงอย่างไร เพื่อให้ใช้งานง่ายขึ้นสำหรับผู้ดูแล *

คำตอบของคุณ _____

มีข้อเสนออื่น ๆ เกี่ยวกับการจัดปุ่ม การจัดหน้าจอ หรือข้อความที่อยากให้ทีมพัฒนาทราบหรือไม่ (ไม่บังคับ)

คำตอบของคุณ _____

ส่ง ล้างแบบฟอร์ม

ห้ามส่งรหัสผ่านใน Google ฟอร์ม

รูปที่ ซ.4: ส่วนข้อเสนอแนะและหน้าขอบคุณของแบบสอบถาม

ภาคผนวก ณ ภาพประกอบการสำรวจพื้นที่และการติดตั้งต้นแบบ

ภาคผนวกนี้แสดงภาพประกอบจากการสำรวจบริบทพื้นที่ การทดลองติดตั้งอุปกรณ์ และการรับฟังความคิดเห็นจากผู้ดูแล ภาพชุดนี้ใช้เป็นหลักฐานประกอบด้านสภาพแวดล้อมและการออกแบบต้นแบบ ไม่ได้ใช้เป็นหลักฐานว่าระบบผ่านการติดตั้งใช้งานจริงระยะยาวในสถานดูแลผู้สูงอายุ



รูปที่ ณ.1: ตัวอย่างอาคารและพื้นที่บริการหลักของสถานดูแล



รูปที่ ณ.2: ตัวอย่างการติดตั้ง node อ่างอิงสัญญาณภายในอาคาร



รูปที่ ฌ.5: ตัวอย่างบริบทผู้สูงอายุในสถานดูแล



รูปที่ ฌ.6: ตัวอย่างการใช้งานอุปกรณ์ในบริบทการทดลองต้นแบบ



(a) บอร์ดแนวคิดการทำงานชุดที่ 1



(b) บอร์ดแนวคิดการทำงานชุดที่ 2

รูปที่ ฌ.7: ภาพประกอบการสรุปแนวคิดและ workflow ระหว่างการออกแบบระบบ



รูปที่ ฅ.8: ตัวอย่างการอธิบายแนวทางใช้งานระบบและรับฟังความคิดเห็นจากผู้ดูแล



รูปที่ ฅ.9: ภาพประกอบการลงพื้นที่และการพูดคุยกับผู้เกี่ยวข้อง

ภาคผนวก ญ เอกสาร PaperIEEE ประกอบการทดลอง RSSI

ภาคผนวกนี้แนบหน้าเอกสาร PaperIEEE ที่ใช้เป็นหลักฐานประกอบการทดลอง BLE RSSI/KNN ในหัวข้อ indoor localization โดยคัดลอกไฟล์ PDF เข้ามาไว้ในโฟลเดอร์ของเล่มปัจจุบันและแนบเฉพาะหน้า 1-2 ตามขอบเขตที่ใช้ประกอบเนื้อหา

Comparative Performance Evaluation of BLE-Based Indoor Motion Tracking Using Machine Learning and Large Language Models

1st Worapon Sangsasri

*Faculty of Engineering
Thammasat School of Engineering
Thammasat University
Phathumthani, Thailand
worapon.sangs@gmail.com*

2nd Suppawit Ausawalaithong

*Faculty of Engineering
Thammasat School of Engineering
Thammasat University
Phathumthani, Thailand
suppawit.aus@gmail.com*

3rd Darawadee Panich

*Faculty of Engineering
Thammasat School of Engineering
Thammasat University
Phathumthani, Thailand
darawadeemookpanich@gmail.com*

4th Sairag Saadprai

*Faculty of Allied Health Sciences
Thammasat University
Phathumthani, Thailand
sairag.saa@allied.tu.ac.th*

5th Supachai Vorapojpisut

*Faculty of Engineering
Thammasat School of Engineering
Thammasat University
Phathumthani, Thailand
vsupacha@engr.tu.ac.th*

Abstract—This paper presents a comparative evaluation of Bluetooth Low Energy (BLE) Received Signal Strength Indicator (RSSI)-based indoor motion tracking using four classifiers: K-Nearest Neighbors (KNN), eXtreme Gradient Boosting (XGBoost), and two zero-shot Large Language Model (LLM) classifiers (Claude Opus 4.6 and Gemini 3.1 Pro). Experiments are conducted in a single room divided into four zones by cloth partitions, instrumented with four ESP32-S3 BLE anchor nodes and one M5StickC Plus2 wearable tag. Three scenarios evaluate body orientation detection, boundary transition classification, and multi-zone trajectory sequencing under inherently unstable BLE signal conditions. Robustness experiments under noise injection and anchor failure reveal that LLMs demonstrate strong resilience to hardware degradation. These findings suggest that zero-shot LLMs can achieve competitive performance compared to trained ML models on structured BLE RSSI classification tasks, particularly when temporal reasoning or clear signal patterns are present.

Index Terms—Indoor Motion Tracking, Bluetooth Low Energy, Large Language Models, Machine Learning, RSSI Fingerprinting, Time-Series Classification

I. INTRODUCTION

Indoor motion tracking—encompassing body orientation detection, boundary transition identification, and room-to-room movement sequencing—has become essential for applications including asset tracking, elderly care monitoring, and smart building management [1]. Among available radio technologies, Bluetooth Low Energy (BLE) has gained widespread adoption due to its low power consumption and ubiquity in consumer devices [2]. BLE-based systems commonly rely on Received Signal Strength

Indicator (RSSI) fingerprinting, where machine learning (ML) models map observed signal patterns to known locations [3].

Traditional ML approaches such as K-Nearest Neighbors (KNN) and gradient boosting methods like XGBoost have demonstrated strong performance in controlled indoor settings [3], [4]. Although these algorithms deliver competitive accuracy on structured tabular RSSI data, they treat each sample as an isolated point or fixed statistical window. This lack of temporal reasoning becomes a critical limitation in dynamic environments, where RSSI fluctuates due to body shadowing, multipath fading, and zone-boundary ambiguity [5], [6]. On the LLM side, Jin et al. [7] proposed Time-LLM, and Gruver et al. [8] demonstrated zero-shot time-series forecasting, yet neither applied LLMs to RSSI classification. Broader surveys cover both traditional and emerging indoor motion tracking methods [1], [2], [9]. Early RSSI fingerprinting work by Bahl and Padmanabhan [10] established KNN as the dominant classifier, later extended to BLE by Faragher and Harle [11]. Kalman filtering has been shown to reduce positioning error by up to 80% [12], and deep learning architectures have recently been explored [13]. However, all these approaches remain limited in modeling complex RF multipath effects [14]. None of this prior work has applied LLMs as classifiers for continuous BLE RSSI streams.

Currently, advances in Large Language Model (LLM) reasoning have opened a fundamentally different paradigm: when raw numerical data is presented to an LLM as text, the model can apply contextual reasoning without domain-specific training. This raises a compelling

question—*can LLM reasoning handle numeric sensor data as effectively as traditional ML for indoor motion tracking?* If so, LLMs could serve as zero-shot classifiers requiring no labeled training data, no feature engineering, and no model retraining [7], [8].

We select the motion tracking problem as a test bed specifically because BLE signal strength is inherently unstable—RSSI values fluctuate due to multipath propagation, body shadowing, and hardware variability. To represent the ML spectrum, we employ KNN as a distance-based classifier, and XGBoost as a supervised gradient-boosted tree model. On the LLM side, we evaluate Claude Opus 4.6 and Gemini 3.1 Pro as zero-shot reasoners. The main contributions of this work are:

- 1) A systematic evaluation framework comparing trained ML against zero-shot LLM classifiers for BLE RSSI zone-level indoor motion tracking.
- 2) Three scenarios testing body orientation, boundary transition, and dynamic trajectory under inherently unstable BLE signal conditions, with robustness analysis under noise injection and anchor failure revealing superior LLM resilience to hardware degradation.
- 3) Analysis of LLM reasoning traces, providing insight into *how* zero-shot reasoning succeeds on structured motion tracking data.

II. METHODOLOGY

This section describes the evaluation framework designed to compare trained ML classifiers and zero-shot LLM classifiers on the same BLE RSSI dataset. The key design principle is to format raw RSSI data so that it can be consumed by both categories of models without modification: ML models operate on engineered statistical features extracted from the RSSI time series, while LLMs receive the identical raw time series as structured text via prompts. This ensures a fair comparison where differences in performance arise solely from the models’ analytical capabilities rather than data preprocessing advantages.

A. Experimental Environment

The experiment uses a single room divided into four zones (Zone A, B, C, D), each approximately 4×4 m, separated by cloth partitions as shown in Fig. 1. Hardware components (Fig. 2) include:

- **Anchor:** Four ESP32-S3 BLE nodes (Fig. 2a), one per zone center, at 0.7 m height, communicating via MQTT over Wi-Fi.
- **Tag:** One M5StickC Plus2 (Fig. 2b) BLE beacon, attached to the researcher’s waist at 0.7 m (Fig. 2c), broadcasting at 5 Hz (200 ms interval).
- **Server:** Python-based data collection server with synchronized video recording for ground truth labeling.




Fig. 1. Floor plan with BLE anchor positions (numbered 1–4).




Fig. 2. Hardware: (a) ESP32-S3 anchor, (b) M5StickC Plus2 tag, (c) tag on waist.

B. Experimental Design

Case 1: Body Orientation Detection. The researcher stands stationary in Zone D, facing four cardinal directions at two distances (≤ 1 m, >1 m). Classes: Facing in (0) and Facing out (1)—body blocks the direct path, causing RSSI attenuation [6]. Conditions: 4 directions $\times$ 2 distances $\times$ 2 classes $\times$ 3 replicates = 48 episodes; 13 train / 35 test.

Case 2: Boundary Transition Detection. The researcher stands on demarcation lines between Zone D and adjacent zones. Binary task: In Zone D (0) or Out (1). Conditions: 2 boundaries $\times$ 2 classes $\times$ 12 replicates = 48 episodes; 13 train / 35 test. This task is *inherently difficult*: cloth partitions provide negligible RF attenuation at 2.4 GHz.

Case 3: Multi-Zone Trajectory. The researcher walks through all four zones in randomized sequences (e.g., D→C→B→A), pausing 5–6 s per zone. Conditions: 4 zones $\times$ 4 starting positions $\times$ 3 replicates = 48 episodes; 13 train / 35 test. Task: predict exact ordered sequence of zone IDs. *Exact Sequence accuracy* requires all four zone positions to match simultaneously; *Per-Position accuracy* measures the fraction of individual zone positions (out of 4) predicted correctly, independent of other positions in the sequence. LLMs receive the full time series; ML models use four contiguous segments.

C. Data Collection

Each case comprises 48 episodes. An *episode* is one continuous recording under fixed experimental conditions, lasting approximately 5 seconds. The dataset is split into 13 training and 35 test episodes by a single random draw without replacement; the same split is used for all models. Raw RSSI values from the four anchors form a 4-dimensional feature vector at each time step, recorded as (timestamp), (r1), (r2), (r3), (r4) where (r1)–(r4) are the RSSI readings (in dBm) from anchors 1–4 and